충북대학교

자율주행 위치인식 · PART 2. KALMAN FILTER · CHAPTER 8

Designing Kalman Filters

충북대학교 지능로봇공학과 **문성태 교수**

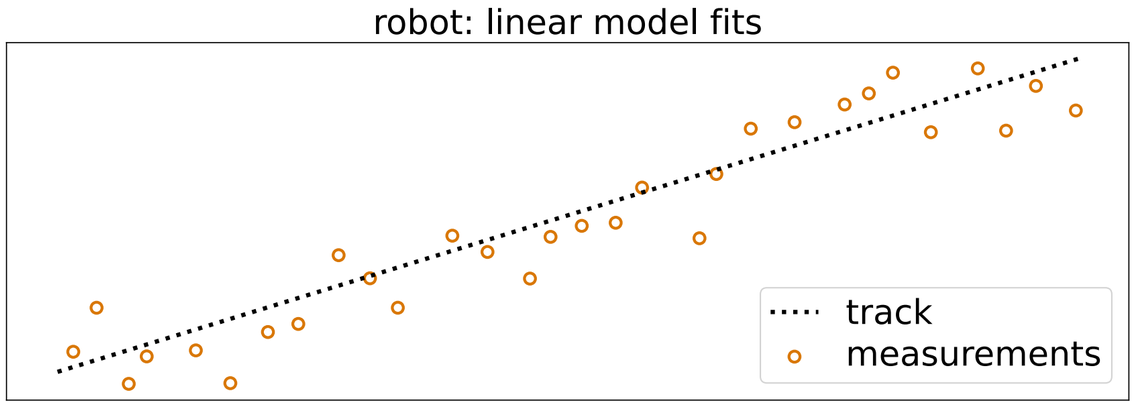
Contents

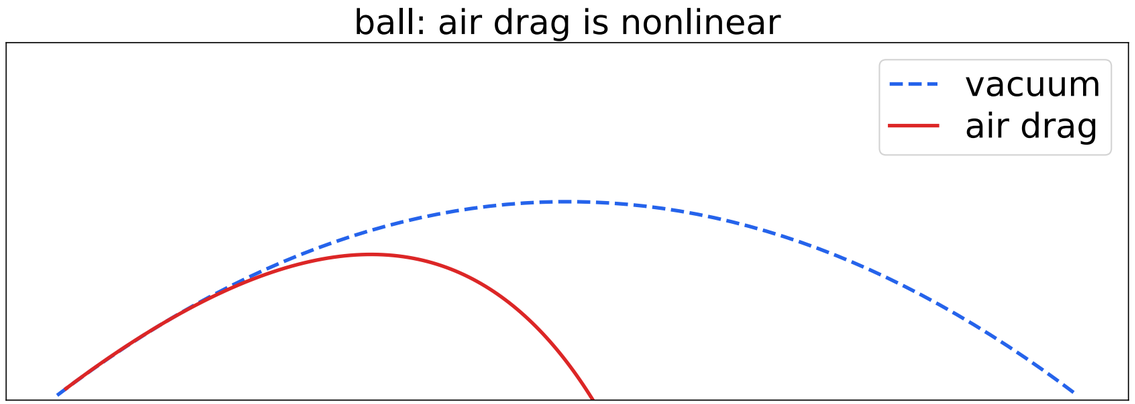
- Introduction
- Tracking a Robot
- Filter Order
- Evaluating Filter Order
- Exercise: State Variable Design
- Detecting and Rejecting Bad Measurement
- Evaluating Filter Performance
- Control Inputs
- Sensor Fusion
- Nonstationary Processes
- Tracking a Ball
- Tracking a Ball in Air

From Textbook Problems to Real Problems

- **지금까지**: 몇 줄의 코드로 쉽게 풀리는 교과서형 문제, 실제 문제는 이보다 훨씬 복잡
- **이번 내용**: 2D 로봇 추적에서 시작해 센서 추가, 제어 입력, 필터 성능 평가 방법까지 확장
- **한계**: 실제 세계는 비선형, Kalman filter 는 선형, 약한 비선형은 견디지만 항상 통하지는 않음

> **핵심**: 실제 문제의 필터 설계와 성능 평가, 선형 필터가 통하는 경우와 실패하는 경우의 구분

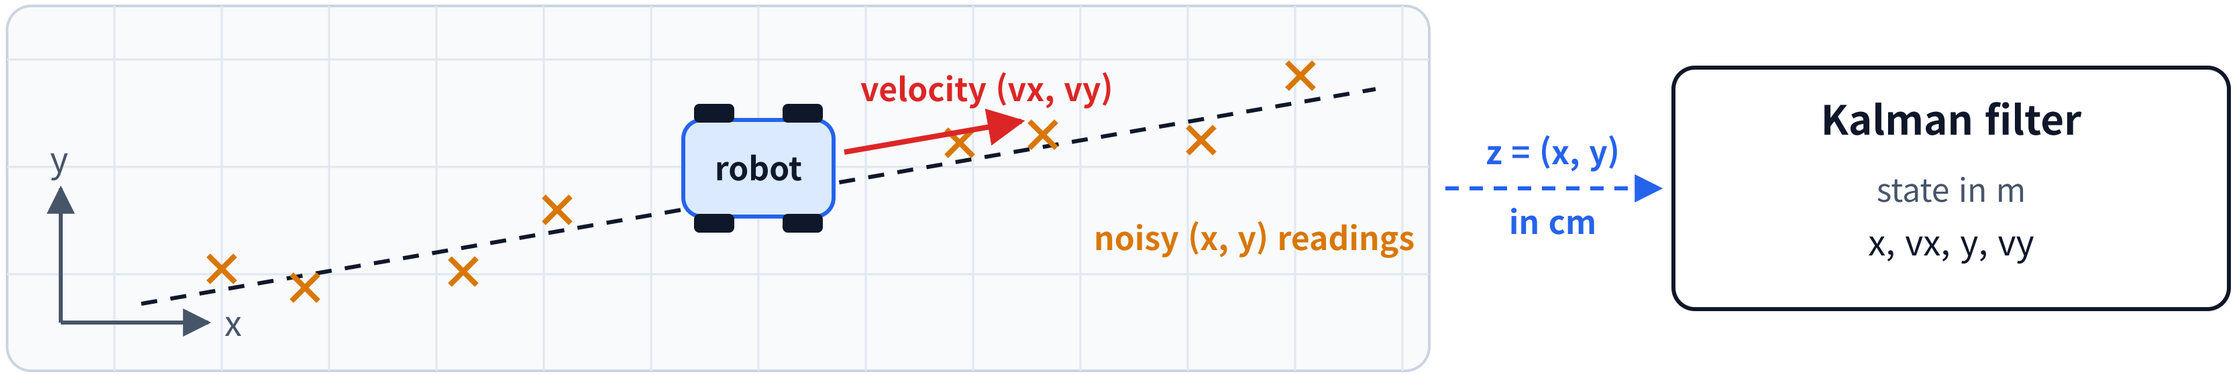




Robot in a 2D Field

- **상황**: 들판이나 창고 같은 2D 공간에서 직선으로 이동하는 로봇 추적
- **센서**: 매 시각 t 마다 잡음 섞인 위치 (x, y) 를 cm 단위로 출력, 필터 상태는 m 단위
- **설계 순서**: 상태 변수, F, Q, B, H, R, 초기 조건을 차례로 정한 뒤 필터 구현

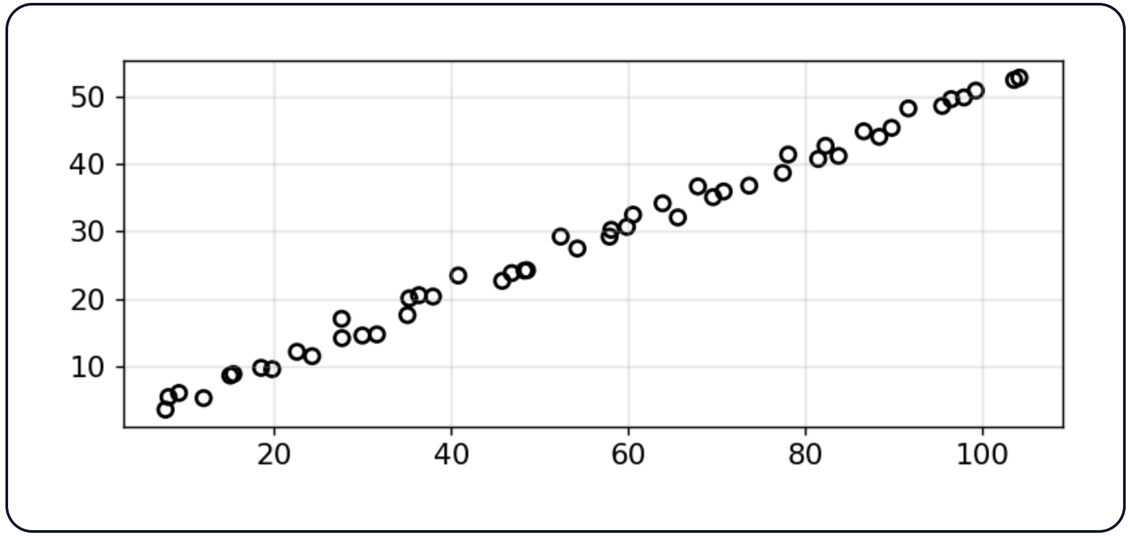
> **핵심**: 1 차원 개 추적과 같은 구조, 측정과 상태가 2 차원으로 늘어난 문제



Simulating the Position Sensor

- 초기 위치, 속도, 잡음 표준편차로 센서를 만들고 read() 를 부를 때마다 한 단계 이동 후 측정 반환
- 측정 50 개가 기울기 1/2 의 직선 위에 퍼짐, 속도 (2, 1) 과 일치하고 시작점도 (6, 4) 근처
- 아직 교과서형 데이터, 실제 세계의 복잡한 거동은 이후 예제에서 차례로 추가
- **조건**: pos = (4, 3), vel = (2, 1), noise_std = 1, 측정 50 개

```
class PosSensor(object):
    def __init__(self, pos=(0, 0), vel=(0, 0), noise_std=1.):
        self.vel = vel
        self.noise_std = noise_std
        self.pos = [pos[0], pos[1]]
    def read(self):
        self.pos[0] += self.vel[0]
        self.pos[1] += self.vel[1]
        return [self.pos[0] + randn() * self.noise_std,
                self.pos[1] + randn() * self.noise_std]
pos, vel = (4, 3), (2, 1)
sensor = PosSensor(pos, vel, noise_std=1)
ps = np.array([sensor.read() for _ in range(50)])
plots.plot_measurements(ps[:, 0], ps[:, 1]);
```



Choose the State Variables

- **관측 변수**: 센서가 주는 x, y 두 값
- **숨은 변수**: 속도, 고정 주기 측정이면 연속 측정의 차이가 곧 속도
- **순서**: 위치와 속도를 이웃하게 두면 x 와 $\dot{x}$ 의 공분산이 P 의 같은 블록에 위치
- **검증**: 필터는 주어진 모델을 그대로 실행, 숨은 변수 결과는 반드시 시험으로 확인

$$\mathbf{x} = \begin{bmatrix} x & \dot{x} & y & \dot{y} \end{bmatrix}^T$$

	x	$\dot{x}$	y	$\dot{y}$
x	var	cov	0	0
$\dot{x}$	cov	var	0	0
y	0	0	var	cov
$\dot{y}$	0	0	cov	var

x with its velocity
correlated

y with its velocity
correlated

x terms vs y terms
0, independent

> **핵심**: 적절한 상태 변수 선택이 필터 성능을 좌우, 숨은 변수의 물리적 의미를 먼저 생각

Design F and Q

8.2.2 State transition F

$$
\begin{aligned}
x &= x + \Delta t\,\dot{x} \\
\dot{x} &= \dot{x} \\
y &= y + \Delta t\,\dot{y} \\
\dot{y} &= \dot{y}
\end{aligned}
\qquad
\begin{bmatrix} x \\ \dot{x} \\ y \\ \dot{y} \end{bmatrix} =
\begin{bmatrix} 1 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & \Delta t \\ 0 & 0 & 0 & 1 \end{bmatrix}
\begin{bmatrix} x \\ \dot{x} \\ y \\ \dot{y} \end{bmatrix}
$$

- 이전 상태에 F 를 곱해 다음 상태 계산
- 행과 열의 배치는 상태 변수 순서를 그대로 따름

8.2.3 Process noise Q

$$
q = \begin{bmatrix} \frac{\Delta t^4}{4} & \frac{\Delta t^3}{2} \\ \frac{\Delta t^3}{2} & \Delta t^2 \end{bmatrix} \sigma^2 \quad Q = \begin{bmatrix} q & 0 \\ 0 & q \end{bmatrix}
$$

- discrete white noise, 한 주기 동안 잡음 일정 가정
- x, y 잡음은 독립, q 를 block_diag 로 배치
- 분산 하나로 단계 사이 모델 변화량 지정

핵심: x 와 y 사이 공분산은 0, 위치와 속도 사이만 상관이 있는 블록 대각 구조

Design B, H, R, and Initial Conditions

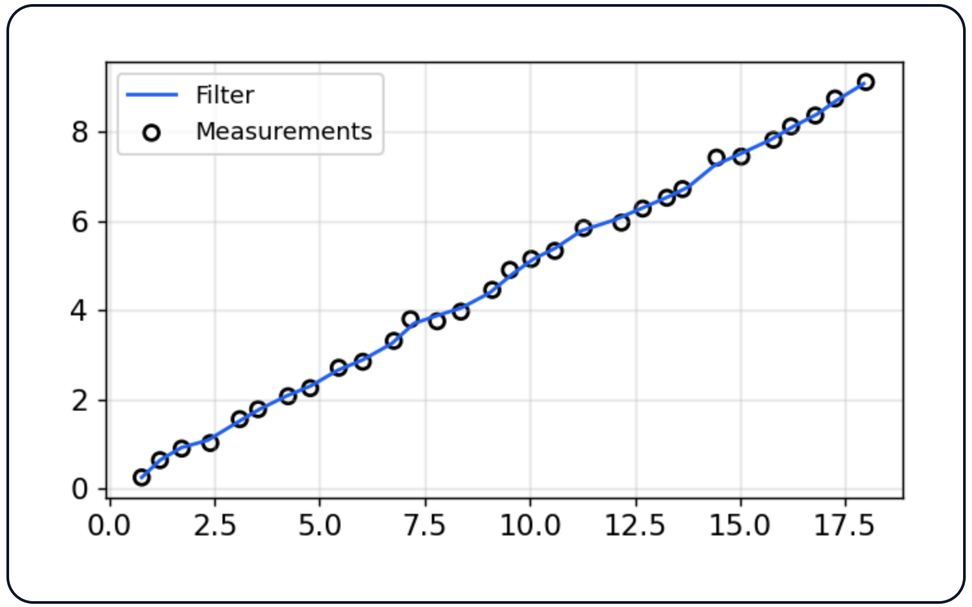
	Design	의미
8.2.4 B	$B = 0$	아직 제어 입력이 없음, 기본값 0 을 그대로 사용
8.2.5 H	$H = \begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 0 & 100 & 0 \end{bmatrix}$	(2×1) = (2×4)(4×1) 로 크기 결정, 상태 m 를 측정 cm 로 변환
8.2.6 R	$R = \begin{bmatrix} \sigma_x^2 & \sigma_y\sigma_x \\ \sigma_x\sigma_y & \sigma_y^2 \end{bmatrix} = \begin{bmatrix} 100 & 0 \\ 0 & 100 \end{bmatrix}$	x, y 잡음은 서로 독립인 white Gaussian, σ = 10 cm
8.2.7 x, P	$\mathbf{x} = \begin{bmatrix} 0 & 0 & 0 & 0 \end{bmatrix}^T,\ P = 500I$	위치 (0, 0), 속도 (0, 0) 은 추측값이므로 P 를 크게

> **핵심**: 행렬 크기가 맞지 않으면 설계를 다시 확인, 차원 분석이 설계의 길잡이

Implement the Filter

- 설계한 행렬을 tracker1() 로 묶고 직선으로 이동하는 로봇의 cm 측정 zs 30 개를 batch_filter 로 처리
- 필터 출력(파란 선)이 잡음 섞인 측정 위를 매끄럽게 따라감, 측정은 cm 이므로 100 으로 나눠 m 로 표시
- **조건**: zs: PosSensor((0, 0), (60, 30), noise_std=10) 의 측정, R_std = 10 cm, Q_std = 0.04 m, dt = 1 s

```python
def tracker1():
    tracker = KalmanFilter(dim_x=4, dim_z=2)
    dt = 1.0   # time step
    tracker.F = np.array([[1, dt, 0,  0],
                          [0,  1, 0,  0],
                          [0,  0, 1, dt],
                          [0,  0, 0,  1]])
    tracker.H = np.array([[100, 0, 0, 0],    # m to cm
                          [0, 0, 100, 0]])
    tracker.R = np.eye(2) * R_std**2
    q = Q_discrete_white_noise(dim=2, dt=dt, var=Q_std**2)
    tracker.Q = block_diag(q, q)
    tracker.x = np.array([[0, 0, 0, 0]]).T
    tracker.P = np.eye(4) * 500.
    return tracker
robot_tracker = tracker1()
mu, cov, _, _ = robot_tracker.batch_filter(zs)
plots.plot_filter(mu[:, 0], mu[:, 2])
plots.plot_measurements(zs[:, 0]/100, zs[:, 1]/100); plt.legend(loc=2);
```

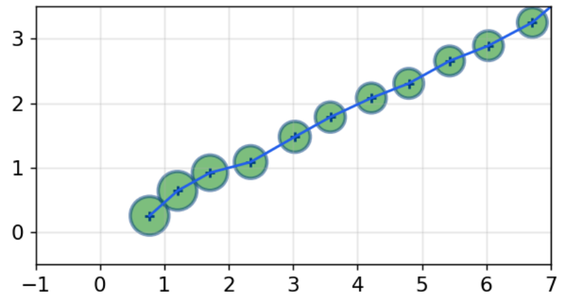


Covariance Ellipses

- 각 단계의 x, y 공분산으로 3σ 공분산 타원(초록)을 그리고 최종 P 의 대각과 x, $\dot{x}$ 블록을 출력
- 처음 몇 단계를 확대, 타원이 기울지 않은 원 모양, x 와 y 는 서로 독립이고 두 축의 측정 잡음이 같기 때문
- P 대각은 x, $\dot{x}$, y, $\dot{y}$ 의 분산, 위치와 속도 블록만 값이 있고 x 와 $\dot{y}$ 처럼 독립인 항의 블록은 0
- **조건**: tracker1() 의 결과 mu, cov, std = 3

```python
for x, P in zip(mu, cov):
    # covariance of x and y
    cov = np.array([[P[0, 0], P[2, 0]],
                    [P[0, 2], P[2, 2]]])
    mean = (x[0, 0], x[2, 0])
    plot_covariance_ellipse(mean, cov=cov, fc='g', std=3, alpha=0.5,
                            axis_equal=False)
plots.plot_filter(mu[:, 0], mu[:, 2])
plt.gca().set_aspect('equal'); plt.xlim(-1, 7); plt.ylim(-0.5, 3.5);
P = robot_tracker.P
print(np.diag(P).round(4))
print(P[0:2, 0:2].round(4))
```

```
[0.0059 0.0029 0.0059 0.0029]
[[0.0059 0.0026]
 [0.0026 0.0029]]
```

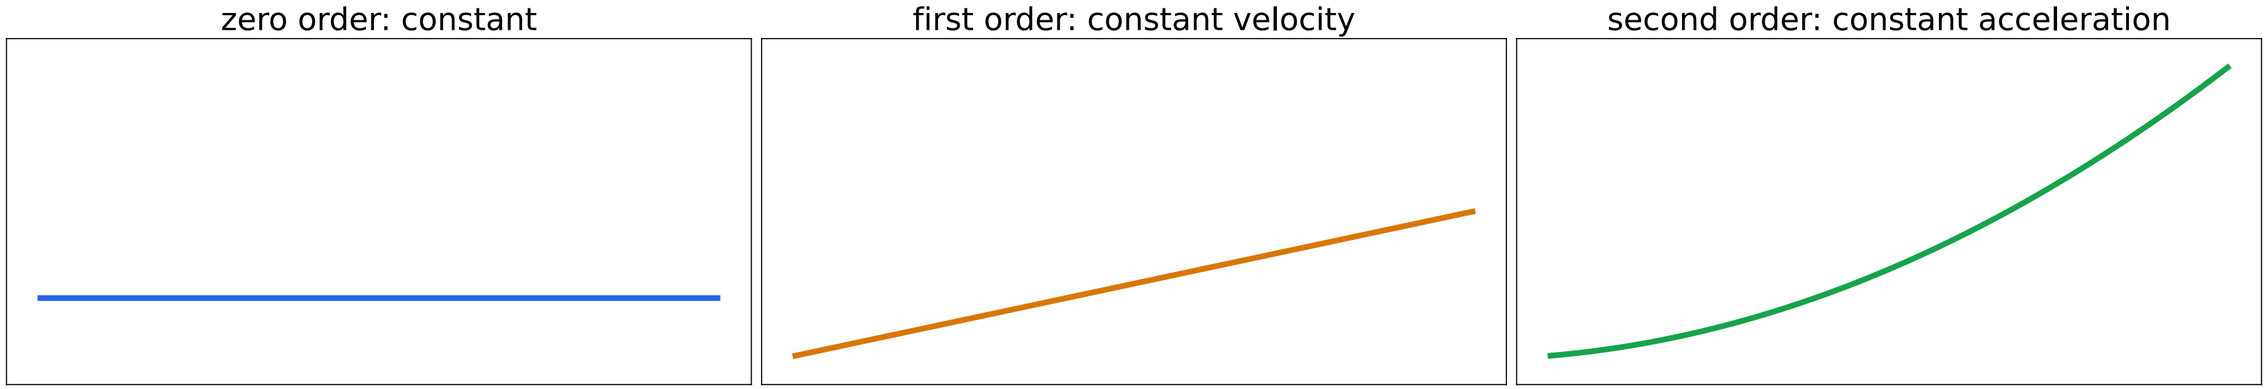


Filter Order

- **차수**: 시스템을 정확히 모델링하는 데 필요한 미분의 개수, 다항식의 차수와 같음
- **0, 1, 2 차**: 변하지 않는 시스템(예: 건물 높이), constant velocity 모델, constant acceleration 모델

$$x = 312.5 \qquad v = \frac{dx}{dt},\ x = vt + x_0 \qquad a = \frac{d^2x}{dt^2},\ x = \frac{1}{2}at^2 + v_0t + x_0$$

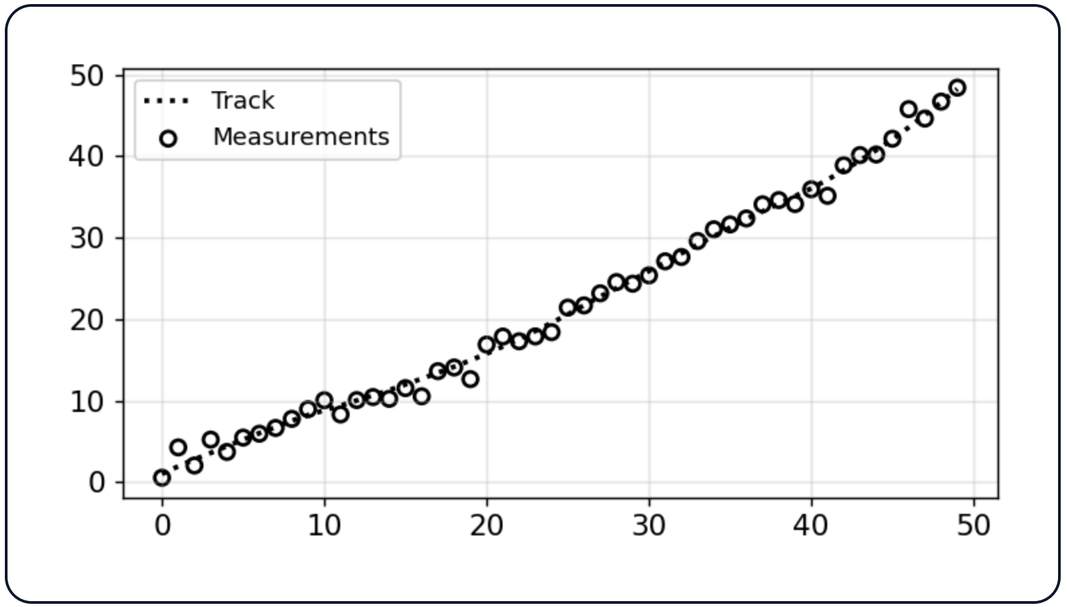
> **질문**: 등속 물체도 속도가 조금씩 흔들림, 가속도까지 추적하는 2 차 필터가 더 나은지



Constant Velocity Object

- 매 단계 속도에 작은 잡음을 더하는 등속 물체와 표준편차 1 m 의 위치 센서를 시뮬레이션
- 궤적(검은 점선)이 완전한 직선이 아님, 길을 걷는 사람이나 바람에 흔들리는 항공기에 해당하는 등속 시스템
- **조건**: x0 = 0, vel = 1 m/s, 속도 잡음 0.06, 측정 잡음 1 m, 50 단계, seed 124

```python
class ConstantVelocityObject(object):
    def __init__(self, x0=0, vel=1., noise_scale=0.06):
        self.x, self.vel, self.noise_scale = x0, vel, noise_scale
    def update(self):
        self.vel += randn() * self.noise_scale
        self.x += self.vel
        return (self.x, self.vel)
def sense(x, noise_scale=1.):
    return x[0] + randn()*noise_scale
np.random.seed(124)
obj = ConstantVelocityObject()
xs, zs = [], []
for i in range(50):
    x = obj.update()
    xs.append(x)
    zs.append(sense(x))
xs = np.asarray(xs)
plots.plot_track(xs[:, 0])
plots.plot_measurements(range(len(zs)), zs)
plt.legend(loc='best');
```



Zero, First, and Second Order Kalman Filters

8.3.1 Zero order

$$\mathbf{x} = \begin{bmatrix} x \end{bmatrix}$$

$$F = \begin{bmatrix} 1 \end{bmatrix}$$

$$H = \begin{bmatrix} 1 \end{bmatrix}$$

- 위치만 추적, 다음 위치 = 현재 위치

8.3.2 First order

$$\mathbf{x} = \begin{bmatrix} x \\ \dot{x} \end{bmatrix}$$

$$F = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}$$

$$H = \begin{bmatrix} 1 & 0 \end{bmatrix}$$

- 위치와 속도, 등속 모델

8.3.3 Second order

$$\mathbf{x} = \begin{bmatrix} x \\ \dot{x} \\ \ddot{x} \end{bmatrix}$$

$$F = \begin{bmatrix} 1 & \Delta t & 0.5\Delta t^2 \\ 0 & 1 & \Delta t \\ 0 & 0 & 1 \end{bmatrix}$$

$$H = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix}$$

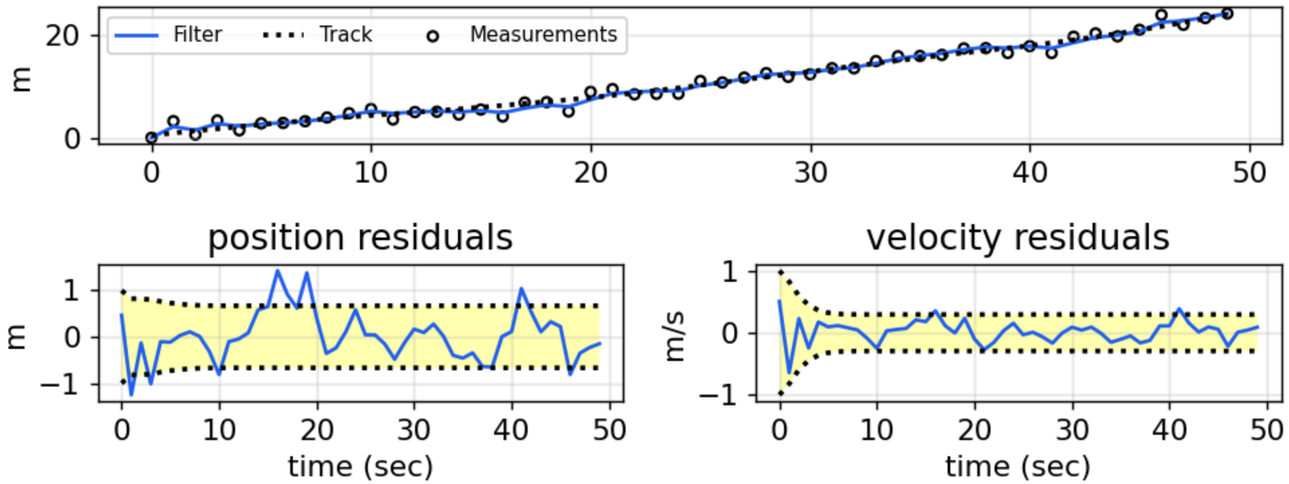
- 위치, 속도, 가속도, 등가속 모델

핵심: 세 필터는 상태 크기와 F, H 만 다르고 센서는 모두 위치만 측정, 같은 측정에 그대로 적용

First Order Filter

- 잔차 = 실제 상태 - 추정을 P 대각의 σ 와 비교, Gaussian 이면 약 68% 가 ±1σ, 99% 가 ±3σ 안, 실제 센서는 5σ 까지 고려
- 1 차 필터는 위치(왼쪽 아래), 속도(오른쪽 아래) 잔차가 모두 0 중심으로 노란 ±1σ 띠 안에 머묾, 발산하지 않음
- **조건**: R = 1, Q = 0.03, vel = 0.5 m/s, 50 단계, 위: 필터 출력, 아래: 잔차와 ±1σ

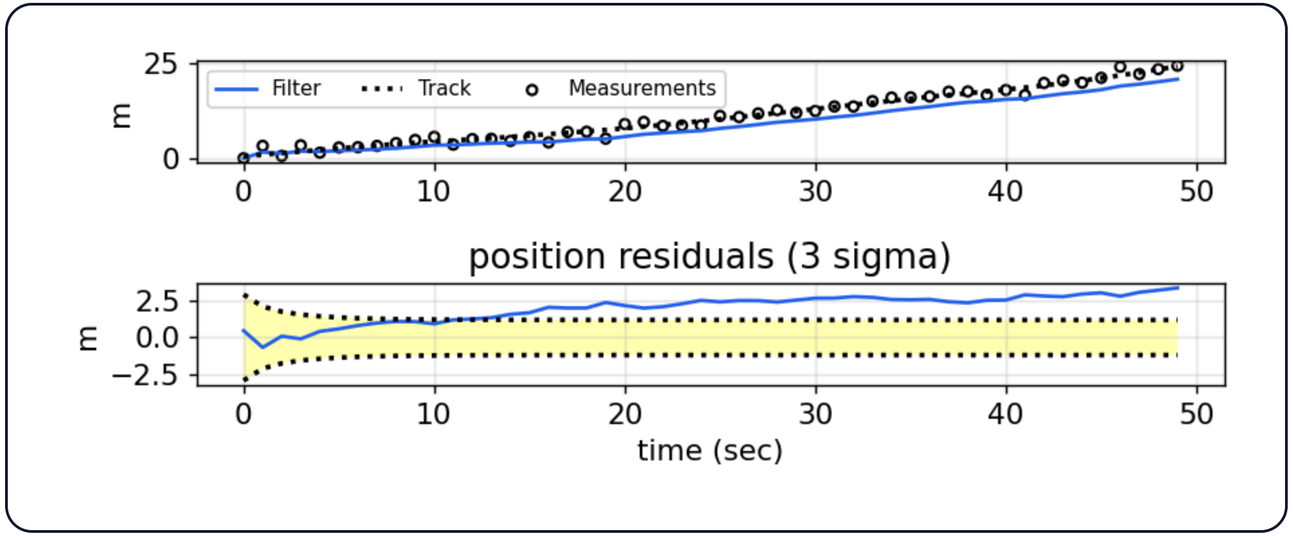
```
R, Q = 1, 0.03
np.random.seed(124)
xs, zs = simulate_system(Q=Q, count=50)
kf = FirstOrderKF(R, Q, dt=1)
data1 = filter_data(kf, zs)
plt.subplot(211)
plots.plot_kf_output(xs, data1.x, data1.z)
plt.subplot(223)
plot_residuals(xs[:, 0], data1, 0,
               'position residuals', 'm')
plt.subplot(224)
plot_residuals(xs[:, 1], data1, 1,
               'velocity residuals', 'm/s')
```



Zero Order Filter

- 같은 데이터에 위치만 추적하는 0 차 필터 적용, 매 예측이 위치 변화가 없다고 가정해 추정이 실제 위치를 계속 뒤따라감
- 잔차가 몇 초 만에 ±3σ 밖으로 발산하는데 P 는 점점 작아져 성능이 좋다고 보고, 모델이 틀린 줄 모르는 smug filter
- 상수 가정은 샘플 사이에서만 성립, 출력은 시간에 따라 변할 수 있음, P 만 믿으면 안 됨
- **조건**: R = 1, Q = 0.03, 위: 필터 출력, 아래: 위치 잔차와 ±3σ

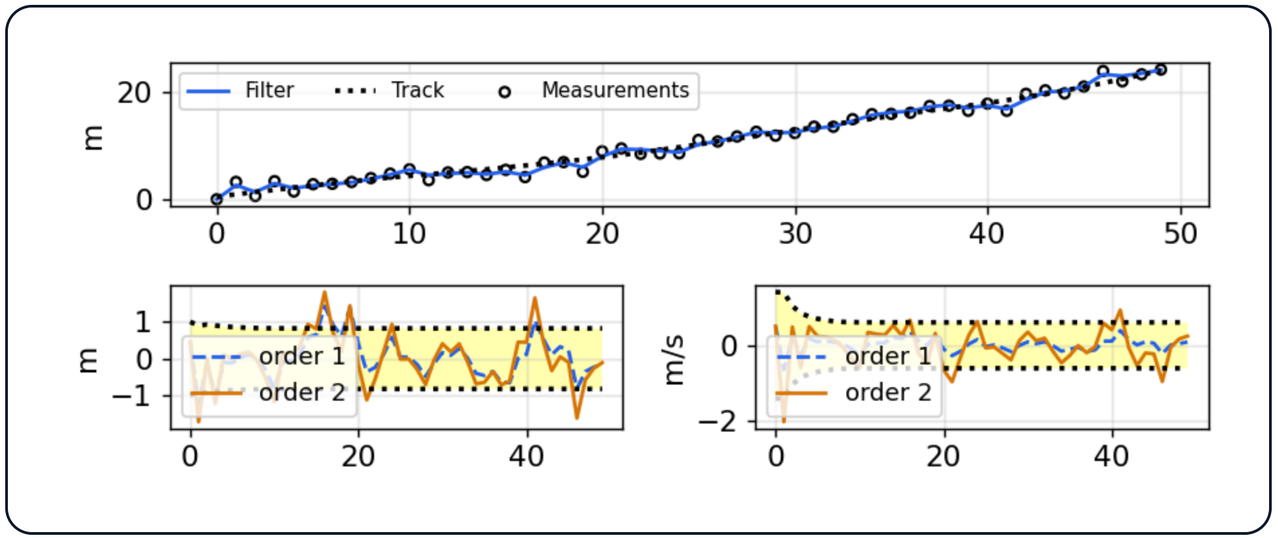
```python
kf0 = ZeroOrderKF(R, Q)
data0 = filter_data(kf0, zs)
plt.subplot(211)
plots.plot_kf_output(xs, data0.x, data0.z)
plt.subplot(212)
plot_residuals(xs[:, 0], data0, 0,
               title='position residuals (3 sigma)',
               y_label='m', stds=3)
```



Second Order Filter

- 같은 데이터에 가속도까지 추적하는 2 차 필터 적용, 잔차를 1 차 필터(점선)와 비교, 노란 띠는 2 차 필터의 ±1σ
- 위치 잔차(왼쪽 아래)는 이론 한계 안이지만 속도 잔차(오른쪽 아래)가 1 차보다 훨씬 큼, 측정 잡음을 가속도로 오인
- 없는 가속도가 매 예측마다 속도 추정에 더해져 잡음을 따라가고 곳곳에서 overshoot
- **조건**: R = 1, Q = 0.03, 같은 측정 50 개

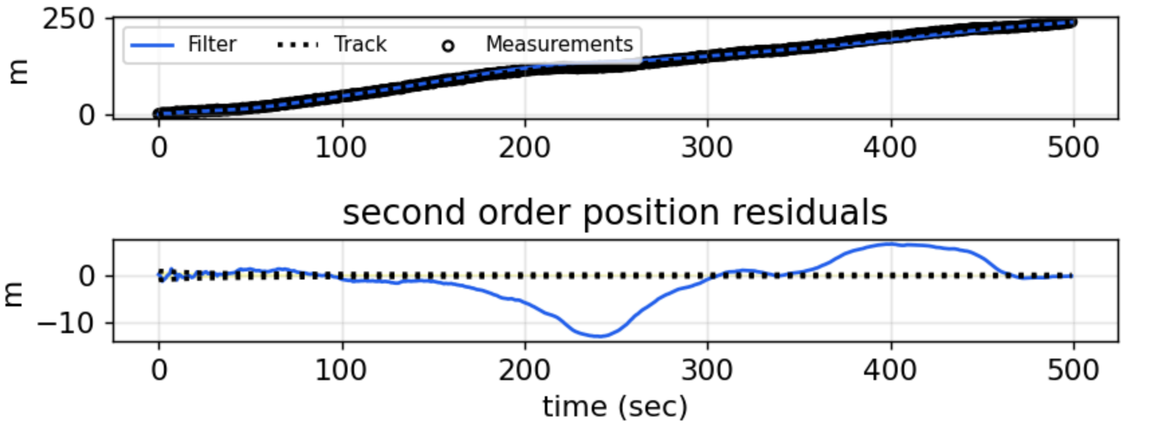
```
kf2 = SecondOrderKF(R, Q, dt=1)
data2 = filter_data(kf2, zs)
plt.subplot(211)
plots.plot_kf_output(xs, data2.x, data2.z)
for col, unit in ((0, 'm'), (1, 'm/s')):
    res2 = xs[:, col] - data2.x[:, col]
    res1 = xs[:, col] - data1.x[:, col]
    plt.subplot(223 + col)
    plt.plot(res1, ls='--', label='order 1')
    plt.plot(res2, label='order 2')
    plots.plot_residual_limits(data2.P[:, col, col])
    plots.set_labels(y=unit)
    plt.legend();
```



Second Order Filter with Q = 0

- 2 차 필터가 속도 변화를 모델링하므로 process noise 를 0 으로 둔 경우를 500 단계로 확인
- 처음엔 실제 궤적에 수렴하는 듯 보이지만 100 번째 갱신 전후로 이론 성능을 크게 벗어나 발산
- Q = 0 은 모델이 완벽하다는 뜻, 측정이 무시되어 불완전한 실제 거동에 적응하지 못함
- **조건**: SecondOrderKF(R, 0), R = 1, 시뮬레이션 Q = 0.03, 500 단계, seed 25944

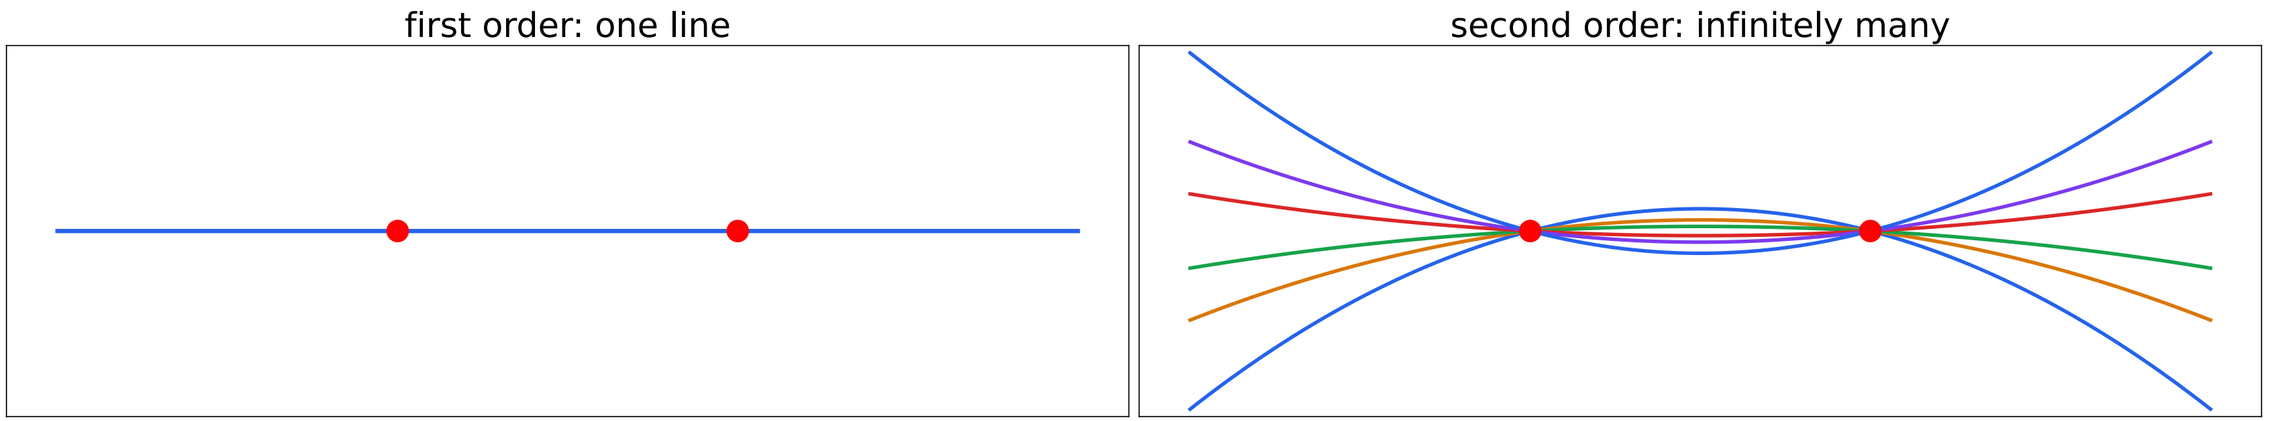
```
np.random.seed(25944)
xs500, zs500 = simulate_system(Q=Q, count=500)
kf2 = SecondOrderKF(R, 0, dt=1)
data500 = filter_data(kf2, zs500)
plt.subplot(211)
plots.plot_kf_output(xs500, data500.x, data500.z)
plt.subplot(212)
plot_residuals(xs500[:, 0], data500, 0,
               'second order position residuals', 'm')
```



Matching the Order of the System

- **데이터 맞춤**: 두 점을 지나는 직선은 유일하고 최적, 2 차 곡선은 무수히 많아 최적이 아니고 발산 가능
- **필터 차수**: 물리 시스템보다 높은 차수의 필터도 같은 문제, 시스템 차수에 맞출 것
- **예**: 냉동고 온도계는 0 차, 직진 차량은 1 차, 회전, 가감속하는 차량은 2 차가 유리

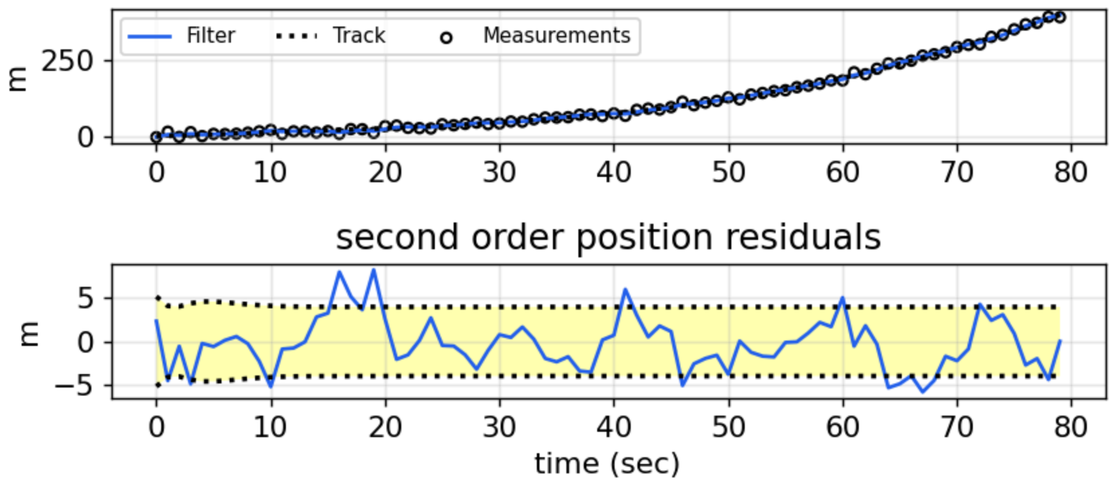
> **핵심**: 낮은 차수 필터도 process noise 를 키우고 샘플 주기를 짧게 하면 높은 차수 거동 추적 가능



Accelerating Object

- 매 단계 가속도에 잡음을 더하는 ConstantAccelerationObject 로 등가속 시스템을 만들고 2 차 필터로 추적
- 시스템과 차수가 맞는 필터, 위치 잔차가 이론 한계 안에 머묾
- **조건**: R = 6, Q = 0.02, 초기 vel = 1, acc = 0.1, 80 단계, seed 124, 위: 필터 출력, 아래: 위치 잔차

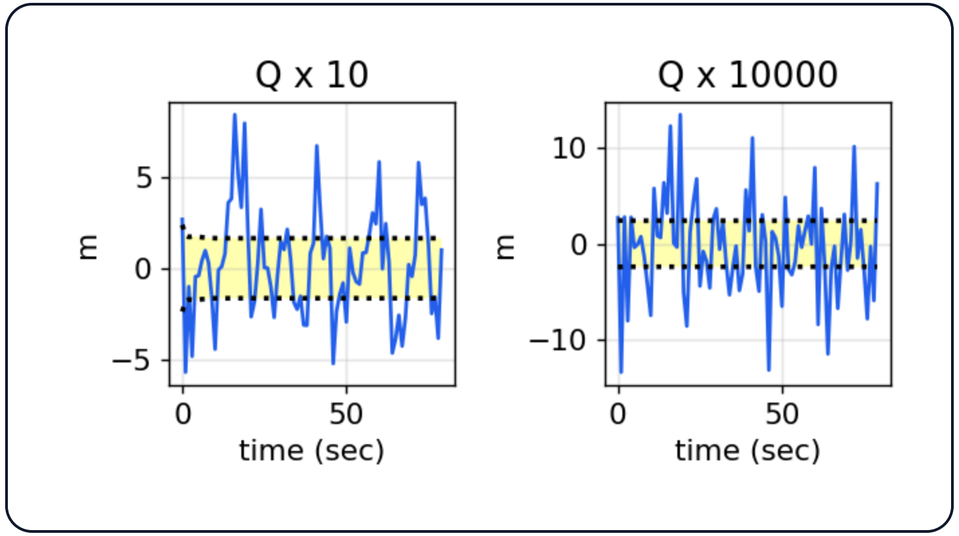
```python
R, Q = 6., 0.02
np.random.seed(124)
xs, zs = simulate_acc_system(R=R, Q=Q, count=80)
kf2 = SecondOrderKF(R, Q, dt=1)
data2 = filter_data(kf2, zs)
plt.subplot(211)
plots.plot_kf_output(xs, data2.x, data2.z)
plt.subplot(212)
plot_residuals(xs[:, 0], data2, 0,
               'second order position residuals', 'm')
```



Lower Order Filter with More Process Noise

- 같은 등가속 데이터를 Q 를 키운 1 차 필터로 추적, 가속도를 process noise 로 취급
- Q × 10 (왼쪽)은 준최적이지만 발산하지 않음, Q × 10000 (오른쪽)은 측정을 지나치게 신뢰해 잡음을 그대로 따라감
- 추가할 Q 의 크기는 정확한 답이 없음, 대표 데이터로 실험해 결정
- **조건**: R = 6, Q = 0.02, 같은 측정 80 개, 그래프는 위치 잔차와 ±1σ

```python
for i, scale in enumerate((10, 10000)):
    kf = FirstOrderKF(R, Q * scale, dt=1)
    data = filter_data(kf, zs)
    plt.subplot(1, 2, i + 1)
    plot_residuals(xs[:, 0], data, 0, 'Q x {}'.format(scale), 'm')
```



Exercise: State Variable Design

- **과제**: 2D 로봇의 상태를 [x y $\dot{x}$ $\dot{y}$] 순서로 바꾼 필터 설계
- **영향**: 상태 순서가 바뀌면 F, Q, H, P 의 행과 열 배치도 함께 바뀜, 측정 z 가 그대로이므로 R 은 동일
- **선택 기준**: P 에서 어떤 상관관계를 쉽게 보고 싶은지에 따라 순서 결정

F

$$\begin{bmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Q

$$\begin{bmatrix} \sigma_x^2 & 0 & \sigma_{x\dot{x}} & 0 \\ 0 & \sigma_y^2 & 0 & \sigma_{y\dot{y}} \\ \sigma_{\dot{x}x} & 0 & \sigma_{\dot{x}}^2 & 0 \\ 0 & \sigma_{\dot{y}y} & 0 & \sigma_{\dot{y}}^2 \end{bmatrix}$$

H

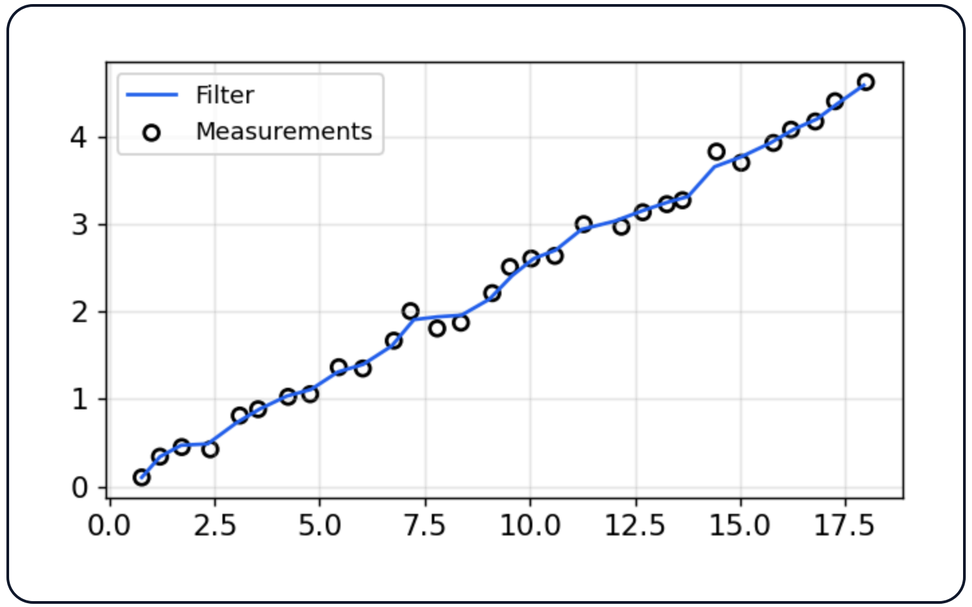
$$\begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 100 & 0 & 0 \end{bmatrix}$$

방법: 상태 변수를 행렬의 행과 열에 나란히 적어 보면 각 항의 짝이 바로 보임, x 와 y 가 섞인 항은 0

Exercise: State Variable Design

- 바꾼 순서에 맞춰 F, H, Q 를 다시 배치, Q 는 1 차원 q 의 항을 해당 위치로 복사
- 필터 출력(파란 선)이 측정을 따라 직선 궤적을 추정, 행렬 배치만 달라지고 결과는 동일
- **조건**: zs: PosSensor((0, 0), (60, 15), noise_std=10) 의 cm 측정 30 개, R_std = 10 cm, Q_std = 0.04 m, dt = 1 s

```
tracker = KalmanFilter(dim_x=4, dim_z=2)
tracker.F = np.array([[1, 0, dt,  0],
                      [0, 1,  0, dt],
                      [0, 0,  1,  0],
                      [0, 0,  0,  1]])
tracker.H = np.array([[100, 0, 0, 0],    # m to cm
                      [0, 100, 0, 0]])
tracker.R = np.eye(2) * R_std**2
q = Q_discrete_white_noise(dim=2, dt=dt, var=Q_std**2)
tracker.Q[0, 0] = tracker.Q[1, 1] = q[0, 0]
tracker.Q[2, 2] = tracker.Q[3, 3] = q[1, 1]
tracker.Q[0, 2] = tracker.Q[2, 0] = q[0, 1]
tracker.Q[1, 3] = tracker.Q[3, 1] = q[0, 1]
tracker.x = np.array([[0, 0, 0, 0]]).T
tracker.P = np.eye(4) * 500.
mu, _, _, _ = tracker.batch_filter(zs)
plots.plot_filter(mu[:, 0], mu[:, 1])
plots.plot_measurements(zs[:, 0]/100, zs[:, 1]/100); plt.legend(loc=2);
```

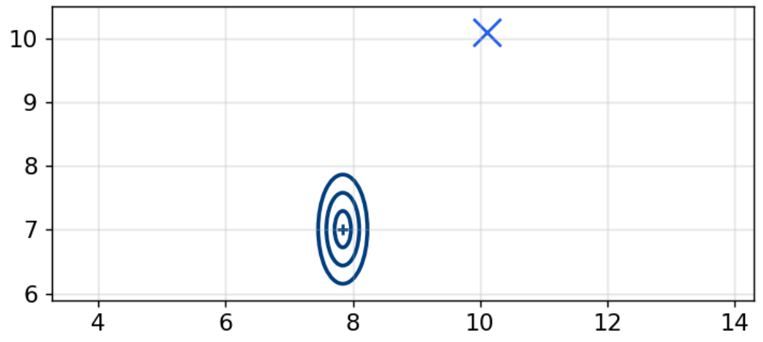


A Bad Measurement

- 약 200 km/h 로 101 번 추적한 항공기 필터 kf 에 현재 위치의 두 배인 측정으로 update
- 추정이 3.4 km 이동, prior 와 측정의 거리는 7.1 km, Kalman filter 자체에는 나쁜 측정을 거르는 기능이 없음
- 1, 2, 3σ 타원(P)에 비해 측정(x 표시)이 99% 영역을 크게 벗어남
- **조건**: kf: 2D 등속 필터, R = diag(0.03, 0.21) km^2, Q 의 속도 항 0.003, 단위 km, dt = 1 s

```python
p0 = kf.x[0:2]
kf.predict()
prior = kf.x
z = kf.x[0:2]*2
kf.update(z)
p1 = kf.x[0:2]
x, P = kf.x[0:2], kf.P[0:2, 0:2]
y = np.abs(z - np.dot(kf.H, prior))  # error from prior
shift = np.linalg.norm(p1 - prior[:2])
print('estimate shift: {:.1f} km'.format(shift))
print('distance from prior: {:.1f} km'.format(np.linalg.norm(y)))
plot_covariance_ellipse(x, P, std=[1, 2, 3])
plt.scatter(z[0], z[1], marker='x', s=200)
plt.ylim(5.9, 10.5);
```

```
estimate shift: 3.4 km
distance from prior: 7.1 km
```

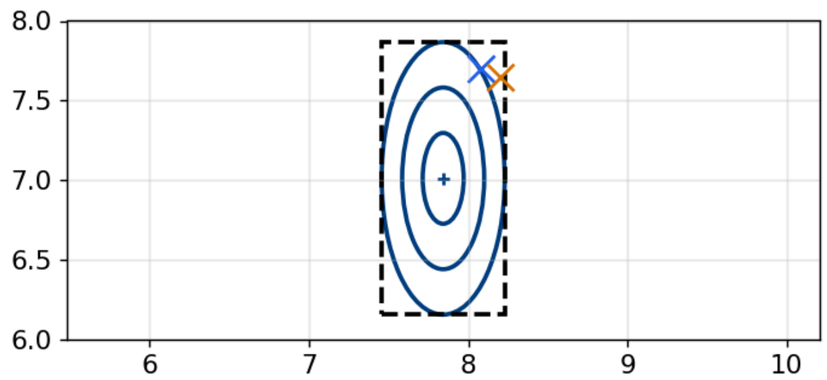


Rectangular Gate

- gate: 측정이 좋은지 나쁜지 판정하는 식, 실제 측정은 순수 Gaussian 이 아니므로 3σ 대신 4σ 사용
- 잔차를 x, y 각각의 σ 와 비교, 나쁜 측정은 39σ, 18σ 떨어져 버려짐
- if 문 두 조건은 타원을 감싼 사각형 영역, 3σ 사각형(점선) 안이지만 3σ 타원 밖인 측정도 통과
- **조건**: GATE_LIMIT = 4, 점 (8.08, 7.7) 은 3σ 경계, (8.2, 7.65) 는 3σ 타원 밖

```
GATE_LIMIT = 4.
std_x = np.sqrt(P[0, 0])
std_y = np.sqrt(P[1, 1])
y = kf.residual_of(z)[:, 0]
if y[0] > GATE_LIMIT * std_x or y[1] > GATE_LIMIT * std_y:
    print('discarding measurement, error is {:.0f} std, {:.0f} std'
          .format(y[0]/std_x, y[1]/std_y))
plot_covariance_ellipse(x, P, std=[1, 2, 3])
plt.ylim(6.0, 8.0);
plt.gca().add_patch(plt.Rectangle(
    (x[0, 0] - 3*std_x, x[1, 0] - 3*std_y), 6*std_x, 6*std_y,
    fill=False, ls='--', lw=2))
plt.scatter(8.08, 7.7, marker='x', s=150)
plt.scatter(8.2, 7.65, marker='x', s=150);
```

```
discarding measurement, error is 39 std, 18 std
```



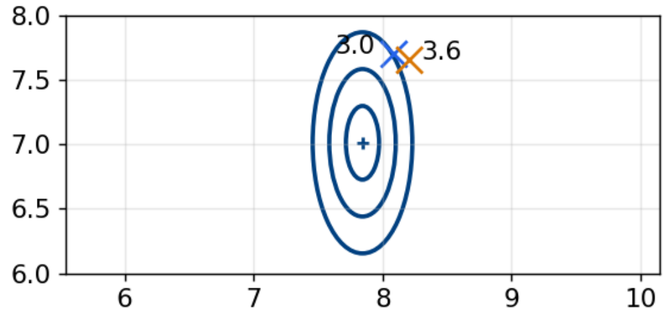
Mahalanobis Distance

$$D_m = \sqrt{(\mathbf{x}-\mu)^T S^{-1}(\mathbf{x}-\mu)} \qquad D_e = \sqrt{(\mathbf{x}-\mathbf{y})^T(\mathbf{x}-\mathbf{y})} \qquad D_m = \sqrt{\sum_{i=1}^{N} \frac{(x_i-\mu_i)^2}{\sigma_i^2}}$$

- 점과 분포 사이의 거리를 표준편차 단위의 스칼라로 계산, S 가 단위행렬이면 Euclidean 거리, 대각이면 각 축을 σ 로 나눈 거리
- 나쁜 측정은 20.6, 3σ 경계의 점은 3.0, 타원 밖의 점은 3.6, 사각형과 달리 타원 모양을 그대로 반영
- **조건**: 갱신 후 x, P 사용, 3 보다 크면 3σ 타원 밖

```python
print('distance of z = {:.1f}'.format(mahalanobis(x=z, mean=x, cov=P)))
plot_covariance_ellipse(x, P, std=[1, 2, 3])
plt.ylim(6.0, 8.0);
for pt, dx in (([8.08, 7.7], -.45), ([8.2, 7.65], .1)):
    d = mahalanobis(x=pt, mean=x, cov=P)
    plt.scatter(pt[0], pt[1], marker='x', s=150)
    plt.text(pt[0] + dx, pt[1], '{:.1f}'.format(d))
```

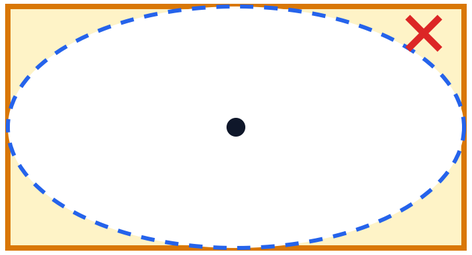
```
distance of z = 20.6
```



Gate Shapes

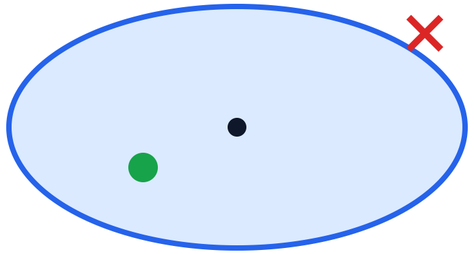
- **Rectangular**: 계산이 가장 싸지만 타원 밖 모서리 영역도 통과, 5 차원에서 나쁜 측정 통과 확률이 약 2 배
- **Ellipsoidal**: Mahalanobis 거리로 판정, 고차원에서 계산 비용 증가
- **Maneuver**: 현재 속도와 기동 능력으로 이동 가능한 영역만 허용, 전투기는 원뿔, 차량은 부채꼴, 배는 좁은 부채꼴
- **Two gates**: 큰 사각형 gate 로 명백한 오류를 먼저 버리고 통과한 측정만 Mahalanobis 거리 계산

Rectangular gate



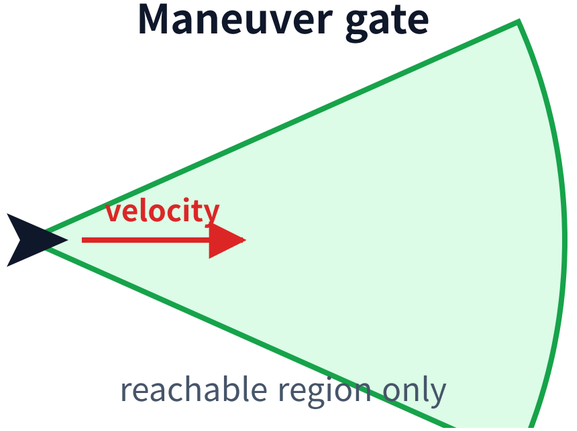
cheap, corners also pass

Ellipsoidal gate



Mahalanobis distance

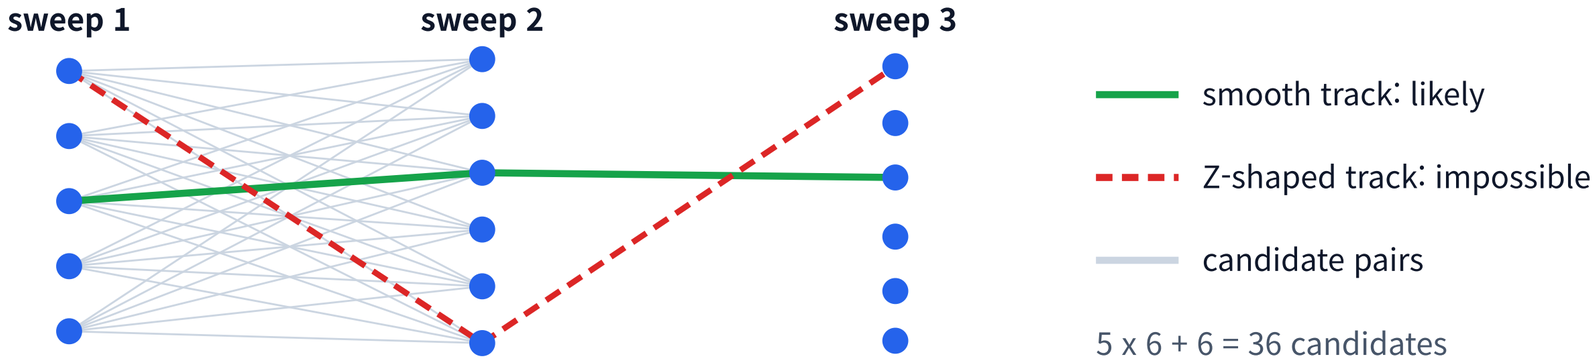
Maneuver gate



reachable region only

Data Association

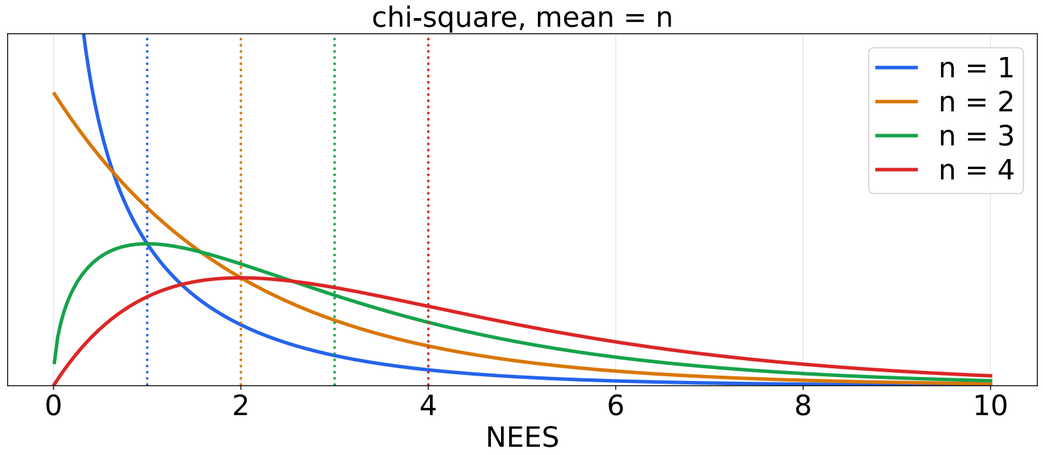
- **문제**: 레이더 sweep 마다 여러 신호, 어느 측정이 어느 항공기 track 인지 결정
- **조합 폭발**: 측정 5 개, 다음 sweep 6 개면 30 개 조합에 새 track 6 개, 몇 sweep 만에 수십억 개 후보
- **가지치기**: Z 자 track, 10000 km/h 를 요구하는 track 은 확률이 매우 낮음, 이런 후보를 적극 제거
- **단일 물체**: gate 를 통과하지 못한 측정은 버리고 update 생략, predict 를 연속 호출해도 무방
- **gate 크기**: 이론은 3σ, 실제는 데이터로 실험해 결정, 예: 4.5σ, 5 ~ 6σ



Evaluating Filter Performance

- **실제 설계**: 센서와 모델이 불완전, 시험 데이터로 행렬 조정
- **최적 필터**: 추정 오차의 평균이 0, 오차의 공분산이 P 와 일치
- **NEES**: 참값을 아는 시뮬레이션에서 오차를 P 로 정규화한 제곱
- **판정**: chi-square 분포를 따르므로 평균 NEES 가 상태 차원 n 보다 작으면 통과

$$\tilde{\mathbf{x}} = \mathbf{x} - \hat{\mathbf{x}} \qquad \epsilon = \tilde{\mathbf{x}}^T P^{-1} \tilde{\mathbf{x}} \qquad n = 1: \ \epsilon = \frac{\tilde{x}^2}{P}$$



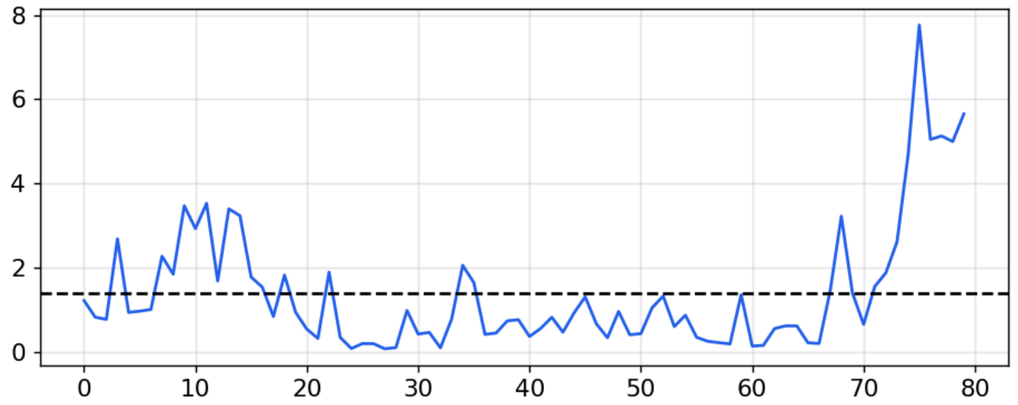
> **핵심**: 같은 오차에서 P 가 작을수록 NEES 가 커짐, 필터가 자기 오차를 과소평가하는지 검사

NEES

- 등가속 시스템을 2 차 필터로 추적한 결과의 단계별 NEES 와 그 평균(점선)을 계산
- 평균 NEES 가 상태 차원 3 보다 작아 통과, 실행 중에도 계산 가능하지만 참값을 아는 시뮬레이션에서만 사용 가능
- **조건**: R = 6, Q = 0.02, 80 단계, dim_x = 3

```python
def NEES(xs, est_xs, Ps):
    est_err = xs - est_xs
    err = []
    for x, p in zip(est_err, Ps):
        err.append(np.dot(x.T, inv(p)).dot(x))
    return err
R, Q = 6., 0.02
xs, zs = simulate_acc_system(R=R, Q=Q, count=80)
kf2 = SecondOrderKF(R, Q, dt=1)
est_xs, ps, _, _ = kf2.batch_filter(zs)
nees = NEES(xs, est_xs, ps)
eps = np.mean(nees)
print('mean NEES is: {:.3f}'.format(eps))
print('passed' if eps < kf2.dim_x else 'failed')
plt.plot(nees)
plt.axhline(eps, ls='--', color='k');
```

```
mean NEES is: 1.398
passed
```

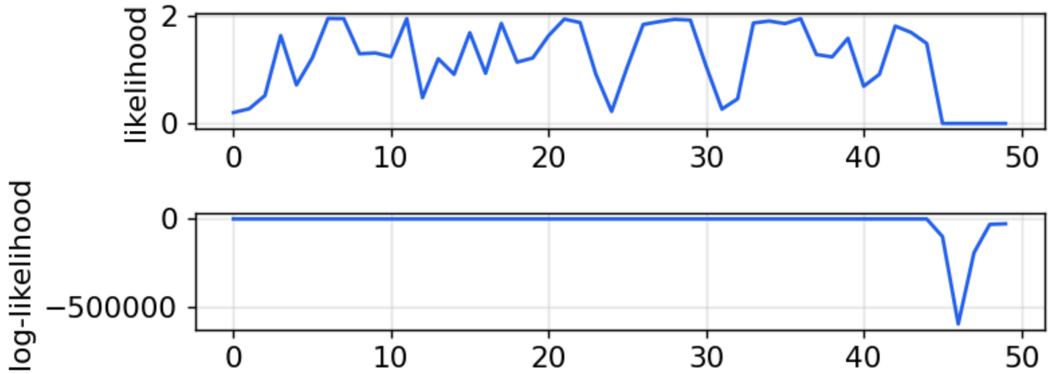


Likelihood Function

$$\mathbf{y} = \mathbf{z} - H\bar{\mathbf{x}} \qquad S = H\bar{P}H^T + R \qquad L = \frac{1}{\sqrt{2\pi S}} \exp\left[-\frac{1}{2}\mathbf{y}^T S^{-1}\mathbf{y}\right]$$

- likelihood: 현재 상태에서 그 측정이 나올 가능성, 낮으면 Gaussian 잡음, 선형 거동 가정 중 무엇인가 틀림
- 큰 측정 4 개에서 likelihood 가 0, log-likelihood 는 급락, 끝에서는 필터가 새 측정 쪽으로 옮겨가 잔차가 작아져 다시 회복
- **조건**: R = 0.05, Q = 0.02, 50 단계, 끝에서 5 ~ 2 번째 측정을 100, 200, 200, 200 으로 교체

```
R, Q = .05, 0.02
xs, zs = simulate_acc_system(R=R, Q=Q, count=50)
zs[-5:-1] = [100, 200, 200, 200]  # bad measurements, bad!
kf = SecondOrderKF(R, Q, dt=1, P=1)
s = Saver(kf)
kf.batch_filter(zs, saver=s);
plt.subplot(211)
plt.plot(s.likelihood)
plots.set_labels(y='likelihood')
plt.subplot(212)
plt.plot(s.log_likelihood)
plots.set_labels(y='log-likelihood');
```



Control Inputs

- **아이디어**: 물체가 이전처럼 계속 움직인다고 가정하는 대신 알고 있는 제어 입력으로 다음 상태 예측
- **u, B**: u 는 제어 입력 벡터, B 는 제어 입력을 상태 변화로 바꾸는 행렬
- **예**: 상태 [x $\dot{x}$] 인 로봇, 제어 입력은 명령 속도, 명령에 즉시 반응한다고 가정
- **실제**: 보통 조향각, 가속도의 변화가 제어 입력, 비선형이 생김

$$\bar{\mathbf{x}} = F\mathbf{x} + B\mathbf{u}$$

$$x = x + \dot{x}_{cmd}\Delta t$$

$$\dot{x} = \dot{x}_{cmd}$$

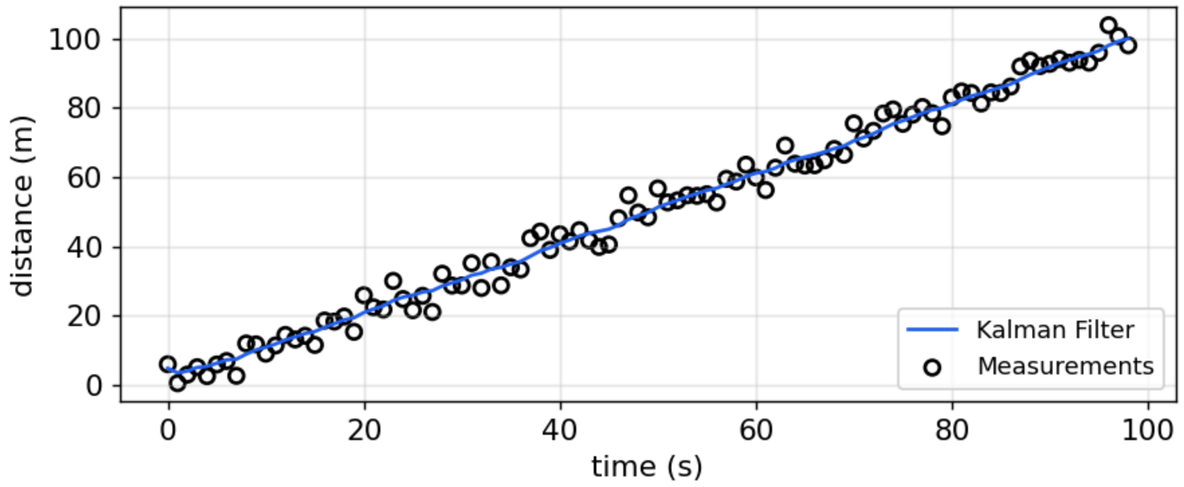
$$\begin{bmatrix} x \\ \dot{x} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \end{bmatrix} + \begin{bmatrix} \Delta t \\ 1 \end{bmatrix} \begin{bmatrix} \dot{x}_{cmd} \end{bmatrix}$$

> **핵심**: Fx 는 위치만 가져오고 Bu 가 명령 속도에 의한 이동량과 새 속도를 채움

Commanded Velocity

- 명령 속도 1 m/s 를 제어 입력으로 predict 에 넣고 잡음 큰 위치 측정으로 update
- 측정 잡음이 커도 필터 출력이 제어 입력을 따라 매끄러운 직선, 제어 입력 외의 설계는 평소와 같음
- **조건**: u = 1 m/s, dt = 1 s, R = 3, Q 분산 0.1, P = 10 I, 측정 99 개

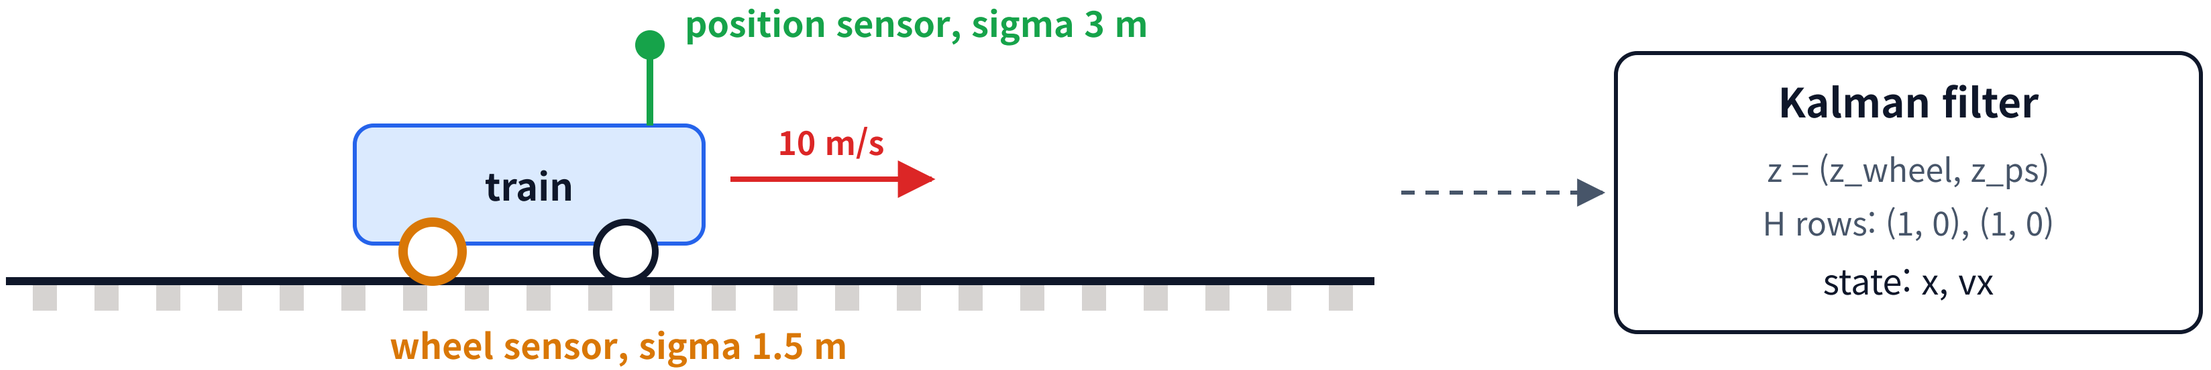
```python
dt, R = 1., 3.
kf = KalmanFilter(dim_x=2, dim_z=1, dim_u=1)
kf.P *= 10
kf.R *= R
kf.Q = Q_discrete_white_noise(2, dt, 0.1)
kf.F = np.array([[1., 0], [0., 0.]])
kf.B = np.array([[dt], [1.]])
kf.H = np.array([[1., 0]])
zs = [i + randn()*R for i in range(1, 100)]
xs = []
cmd_velocity = np.array([[1.]])
for z in zs:
    kf.predict(u=cmd_velocity)
    kf.update(z)
    xs.append(kf.x[0])
plt.plot(xs, label='Kalman Filter')
plots.plot_measurements(zs)
plt.xlabel('time (s)'); plt.ylabel('distance (m)')
plt.legend(loc=4);
```



Sensor Fusion

- **상황**: 레일 위 열차, 바퀴 회전수로 거리를 재는 wheel 센서와 위치를 보고하는 position 센서
- **원칙**: 부정확한 센서의 정보도 버리지 않음, 항공기는 GPS, INS, Doppler radar 등을 융합
- **설계**: 두 측정을 z 로 묶고 H 로 상태를 각 측정으로 변환, 바퀴 1 회전 = 2 m 면 첫 행이 0.5

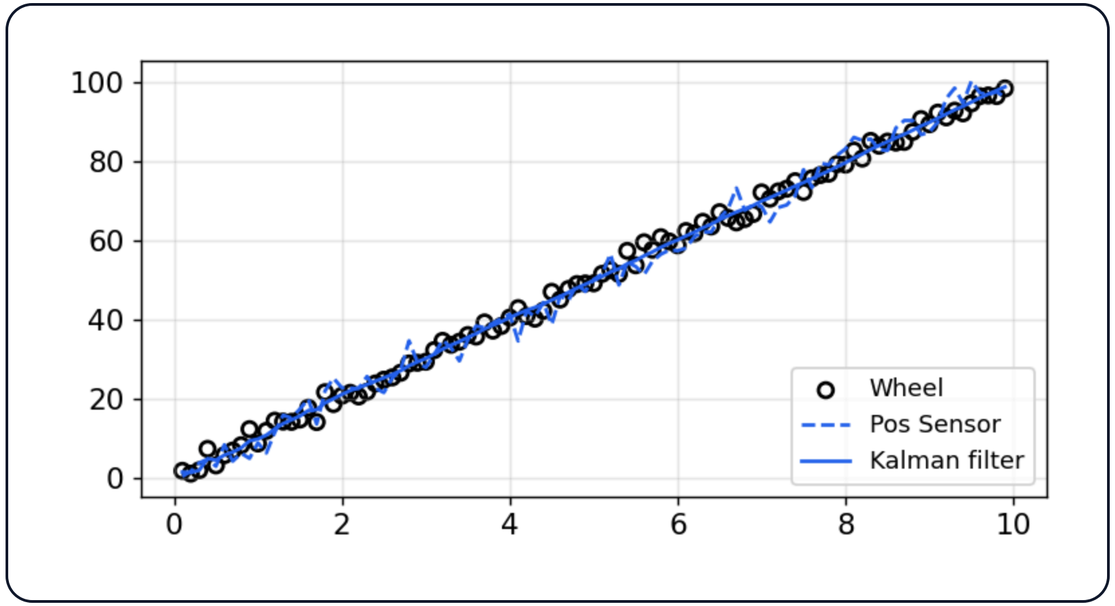
$$\begin{bmatrix} z_{wheel} \\ z_{ps} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \end{bmatrix} \qquad \begin{bmatrix} z_{rot} \\ z_{ps} \end{bmatrix} = \begin{bmatrix} 0.5 & 0 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \end{bmatrix} \qquad R = \begin{bmatrix} 1.5^2 & 0 \\ 0 & 3^2 \end{bmatrix}$$



Wheel and Position Sensor

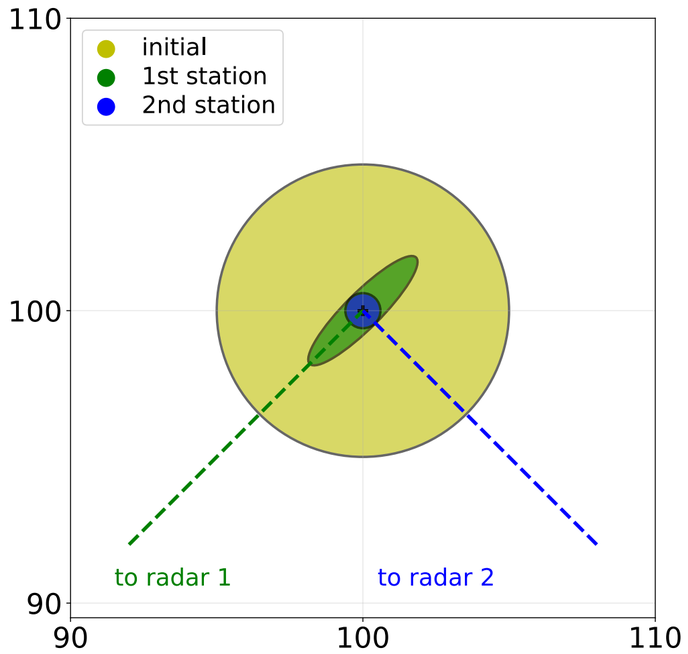
- wheel 센서(σ = 1.5 m)와 position 센서(σ = 3 m)의 측정을 두 행의 H 로 한 번에 update
- 필터 출력(파란 선)이 두 측정보다 매끄럽게 실제 이동을 따라감, Q 는 센서 융합과 무관하게 임의 설정
- **조건**: 속도 10 m/s, dt = 0.1 s, 측정 99 쌍, P = 100 I, Q 분산 0.02, seed 1123

```
dt = 0.1
wheel_sigma, ps_sigma = 1.5, 3.0
kf = KalmanFilter(dim_x=2, dim_z=2)
kf.F = array([[1., dt], [0., 1.]])
kf.H = array([[1., 0.], [1., 0.]])
kf.x = array([[0.], [1.]])
kf.Q *= array([[(dt**3)/3, (dt**2)/2],
               [(dt**2)/2,  dt]]) * 0.02
kf.P *= 100
kf.R = np.diag([wheel_sigma**2, ps_sigma**2])
random.seed(1123)
zs = np.array([[i + randn()*wheel_sigma, i + randn()*ps_sigma]
               for i in range(1, 100)])
mu, _, _, _ = kf.batch_filter(zs)
ts = np.arange(0.1, 10, .1)
plots.plot_measurements(ts, zs[:, 0], label='Wheel')
plt.plot(ts, zs[:, 1], ls='--', label='Pos Sensor')
plots.plot_filter(ts, mu[:, 0], label='Kalman filter')
plt.legend(loc=4);
```



Two Radar Stations

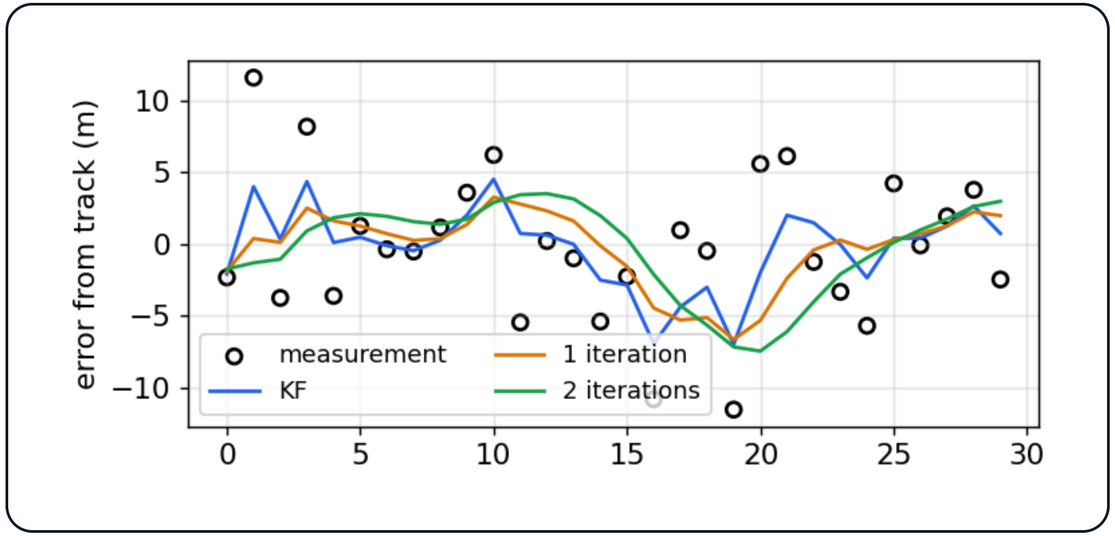
- **상황**: (100, 100) m 의 표적을 (50, 50), (150, 50) 의 두 레이더가 거리와 방위로 측정
- **초기**: x, y 불확실성이 같아 원 모양(노랑)
- **1 번 레이더**: 방위 σ = 0.5° 는 정확, 거리 σ = 3 m 는 부정확, 시선 방향으로 긴 타원(초록)
- **2 번 레이더**: 시선이 1 번과 직교, 오차 방향이 서로 바뀌어 타원(파랑)이 훨씬 작아짐
- **의미**: 공분산은 문제의 기하를 포함한 모든 정보를 반영, 위치 센서와 속도 센서의 조합에서도 같음



Exercise: Can you Filter GPS outputs?

- 상용 GPS 출력은 내부 Kalman filter 의 추정, 그 출력을 다시 필터의 측정으로 넣으면 좋아지는지 확인
- 그래프는 실제 궤적 대비 오차, 반복할수록 매끄러워지지만 궤적에서 벗어나고 지연이 생김
- 필터 출력은 시간 상관이라 Markov 가정 위반, 최적 해를 다시 필터링해 더 최적이 될 수 없음
- **조건**: R = 5, Q = 0.02, 30 단계, seed 124, 이전 필터의 위치 추정을 다음 필터의 측정으로 사용

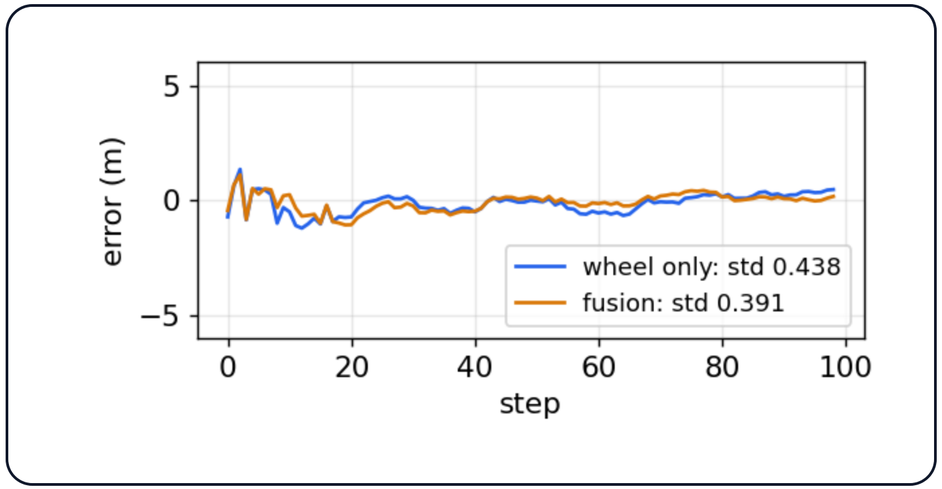
```
np.random.seed(124)
R, Q = 5., 0.02
xs, zs = simulate_acc_system(R=R, Q=Q, count=30)
kf0 = SecondOrderKF(R, Q, dt=1)
kf1 = SecondOrderKF(R, Q, dt=1)
kf2 = SecondOrderKF(R, Q, dt=1)
# Filter measurements
fxs0, ps0, _, _ = kf0.batch_filter(zs)
# filter twice more, using the state as the input
fxs1, ps1, _, _ = kf1.batch_filter(fxs0[:, 0])
fxs2, _, _, _ = kf2.batch_filter(fxs1[:, 0])
plots.plot_measurements(zs - xs[:, 0], label='measurement')
for fx, name in ((fxs0, 'KF'), (fxs1, '1 iteration'),
                 (fxs2, '2 iterations')):
    plt.plot(fx[:, 0] - xs[:, 0], label=name)
plt.ylabel('error from track (m)'); plt.legend(loc=3, ncol=2);
```



Exercise: Prove that the Position Sensor Improves the Filter

- 같은 융합 필터를 fusion_test(wheel_sigma, ps_sigma) 로 묶고 position 센서 잡음을 1e40 으로 키워 사실상 무시
- 참값 대비 오차의 표준편차가 융합한 경우 더 작음, 부정확한 센서도 정보를 더함
- **조건**: wheel σ = 1.5 m, position σ = 3 m 또는 1e40, 같은 seed 의 측정, 참값 위치 = 단계 번호

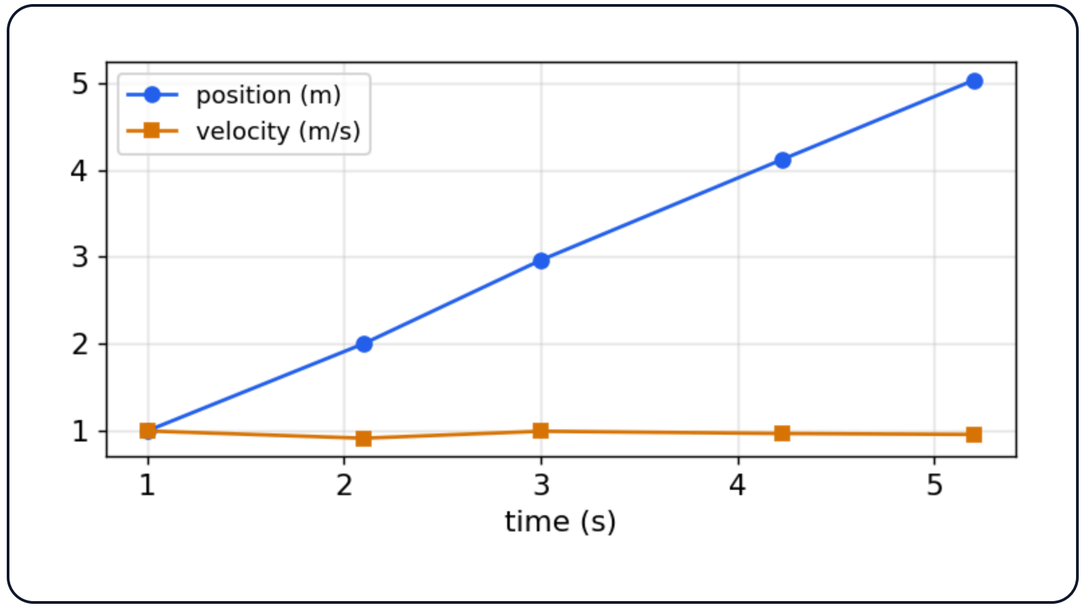
```
nom = np.arange(1, 100)
for ps_sigma, name in ((1.e40, 'wheel only'), (3.0, 'fusion')):
    s = fusion_test(1.5, ps_sigma)
    res = nom - s.x[:, 0, 0]
    plt.plot(res, label='{}: std {:.3f}'.format(name, np.std(res)))
plt.ylim(-6, 6);
plt.xlabel('step'); plt.ylabel('error (m)')
plt.legend(loc=4);
```



Nonstationary Processes

- 데이터 주기가 불규칙하면 Δt 에 의존하는 F = [[1, Δt], [0, 1]] 과 Q 를 측정마다 다시 계산한 뒤 predict, update
- 각 측정 시각의 추정을 그래프로 표시, 위치는 측정 1 ~ 5 m 를 따르고 속도는 약 1 m/s 로 유지
- **조건**: (측정, 경과 시간) 5 쌍, Δt 0.9 ~ 1.23 s, P = 50 I, R = 1, q_var = 0.02

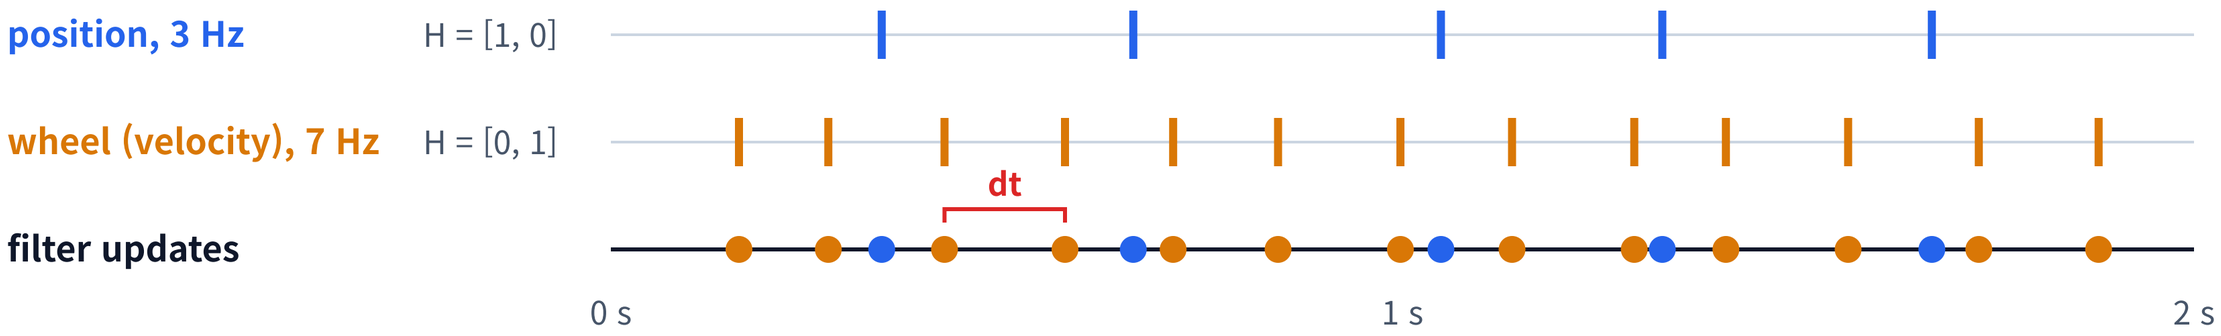
```python
kf = KalmanFilter(dim_x=2, dim_z=1)
kf.x = array([0., 1.])
kf.H = array([[1, 0]])
kf.P = np.eye(2) * 50
kf.R = np.eye(1)
q_var = 0.02
# measurement tuple: (value, time)
zs = [(1., 1.), (2., 1.1), (3., 0.9), (4.1, 1.23), (5.01, 0.97)]
t, ts, xs = 0., [], []
for z, dt in zs:
    kf.F = array([[1, dt], [0, 1]])
    kf.Q = Q_discrete_white_noise(dim=2, dt=dt, var=q_var)
    kf.predict()
    kf.update(z)
    t += dt
    ts.append(t); xs.append(kf.x.copy())
xs = np.array(xs)
plt.plot(ts, xs[:, 0], 'o-', label='position (m)')
plt.plot(ts, xs[:, 1], 's-', label='velocity (m/s)')
plt.xlabel('time (s)'); plt.legend();
```



Different Data Rates

- **상황**: position 센서 3 Hz, wheel 센서 7 Hz, 시각에 약간의 jitter, wheel 은 위치 대신 속도 측정
- **처리**: 어느 센서든 데이터가 오면 지난 update 이후 경과 시간 Δt 로 F, Q 를 수정
- **측정별 H, R**: position: $H = \begin{bmatrix} 1 & 0 \end{bmatrix}$, $R = \sigma_{ps}^2$, wheel: $H = \begin{bmatrix} 0 & 1 \end{bmatrix}$, $R = \sigma_{wheel}^2$

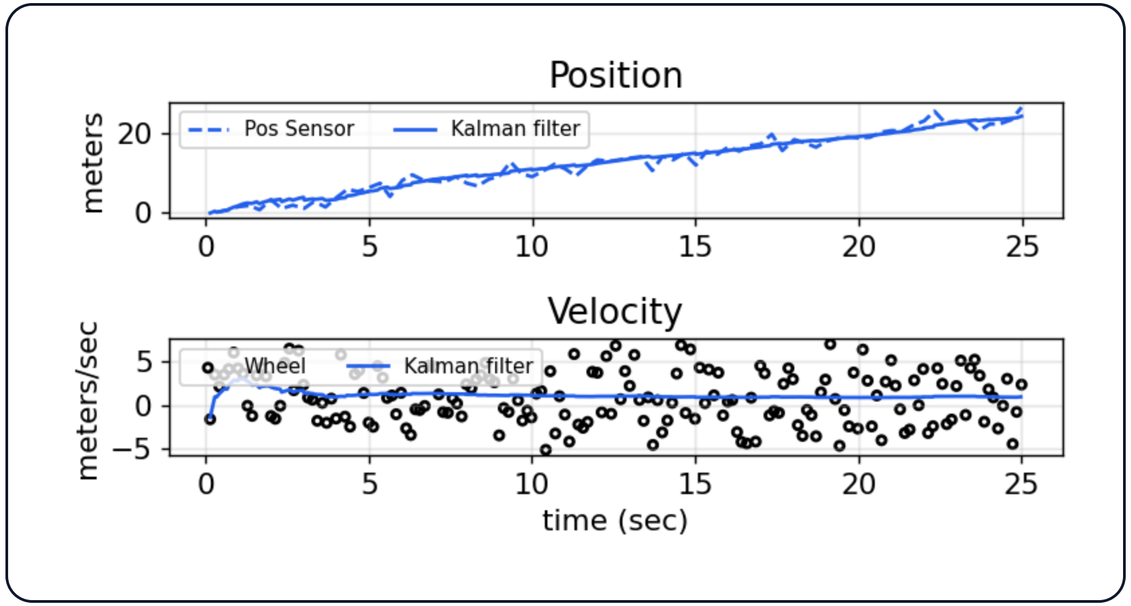
> **핵심**: 센서마다 H, R 을, 시간 간격마다 F, Q 를 바꾸는 것만으로 서로 다른 주기의 센서 융합 가능



Fusing Sensors at Different Rates

- 두 센서 데이터를 시각 순서로 꺼내 센서 종류에 따라 H, R 을 바꾸고 Δt 로 F, Q 를 다시 계산
- 위: 위치 추정이 position 측정(점선)보다 매끄러움, 아래: 속도 추정이 wheel 측정의 잡음을 걸러냄
- **조건**: pos_data, vel_data: [시각, 측정] 목록, 25 초, position 3 Hz σ = 1.5 m, wheel 7 Hz σ = 3 m/s, 실제 속도 1 m/s

```python
ps_std, wheel_std = 1.5, 3.0
kf = KalmanFilter(dim_x=2, dim_z=1)
kf.F = array([[1., 1.], [0., 1.]])
kf.x = array([[0.], [1.]])
kf.P *= 100
xs, ts, last_t = [], [], 0
while len(pos_data) > 0 and len(vel_data) > 0:
    if pos_data[0][0] < vel_data[0][0]:
        t, z = pos_data.pop(0)
        kf.H, kf.R[0, 0] = np.array([[1., 0.]]), ps_std**2
    else:
        t, z = vel_data.pop(0)
        kf.H, kf.R[0, 0] = np.array([[0., 1.]]), wheel_std**2
    dt, last_t = t - last_t, t
    kf.F[0, 1] = dt
    kf.Q = Q_discrete_white_noise(2, dt=dt, var=.02)
    kf.predict()
    kf.update(np.array([z]))
    xs.append(kf.x.T[0]); ts.append(t)
plot_fusion(xs, ts, zs_ps, zs_wheel)
```

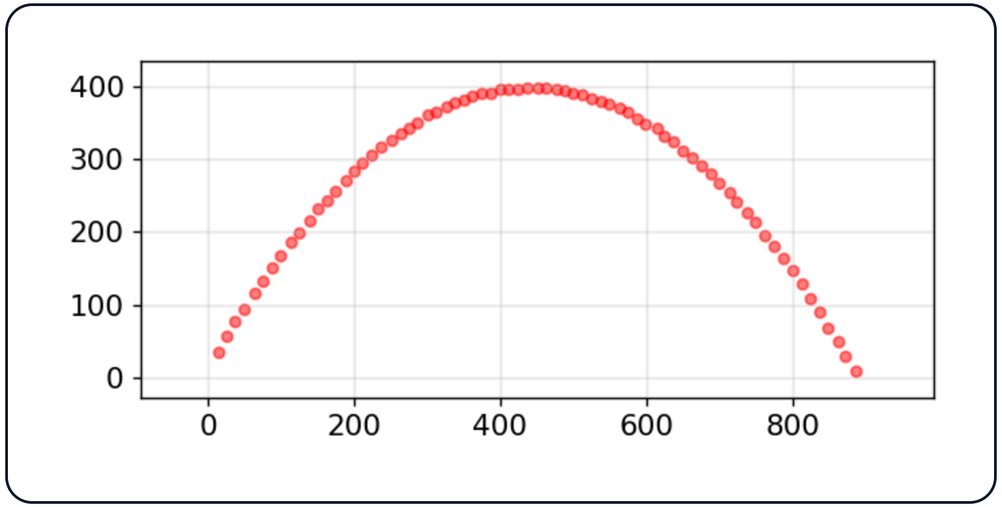


Ball in a Vacuum

$$y = -\frac{g}{2}t^2 + v_{y0}t + y_0 \qquad x = v_{x0}t + x_0 \qquad v_{x0} = v\cos\theta,\ v_{y0} = v\sin\theta$$

- 진공에서 던진 공은 Newton 법칙대로 포물선 이동, 4 차 Runge-Kutta 로 위치를 적분하는 시뮬레이터로 측정 생성
- (0, 15) m 에서 100 m/s, 60° 로 던진 공, 잡음 섞인 측정이 매끄러운 포물선을 그림
- **조건**: BallTrajectory2D, dt = 0.25 s, 측정 잡음 [1, 1] m, y < 0 이면 종료

```
def test_ball_vacuum(noise):
    y = 15
    x = 0
    ball = BallTrajectory2D(x0=x, y0=y,
                            theta_deg=60., velocity=100.,
                            noise=noise)
    dt = 0.25
    while y >= 0:
        x, y = ball.step(dt)
        if y >= 0:
            plt.scatter(x, y, color='r', marker='.', s=75, alpha=0.5)
    plt.axis('equal');
test_ball_vacuum([1, 1]) # plot with noise
```



State Variables and State Transition

- **8.11.1 Euler**: 매 Δt 동안 속도가 일정하다고 가정, 매 단계 측정이 있어 충분히 정확
- **상태**: x 는 등속, y 는 중력으로 가속, 상수인 중력은 제어 입력으로 처리
- **8.11.2 F**: g 를 포함하지 않는 등속 F, 중력은 Bu 로 반영
- **Runge-Kutta**: predict 를 직접 작성, P 는 FPF^T + Q

$$
\begin{aligned}
x_t &= x_{t-1} + v_{x(t-1)}\Delta t \\
v_{xt} &= v_{x(t-1)} \\
y_t &= y_{t-1} + v_{y(t-1)}\Delta t \\
v_{yt} &= -g\Delta t + v_{y(t-1)}
\end{aligned}
$$

$$
\mathbf{x} = \begin{bmatrix} x \\ \dot{x} \\ y \\ \dot{y} \end{bmatrix}, \quad F = \begin{bmatrix} 1 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & \Delta t \\ 0 & 0 & 0 & 1 \end{bmatrix}
$$

> **핵심**: 알려진 방식으로 시스템을 바꾸는 힘은 추적할 상태가 아니라 제어 입력

Control Input: Gravity

- **목표**: $B\mathbf{u} = \begin{bmatrix} 0 & 0 & 0 & -g\Delta t \end{bmatrix}^T$ 가 되도록 B, u 설계, 중력은 y 속도만 변화
- **원칙**: u 는 실제 제어 입력, 시간은 제어 입력을 상태 변화로 바꾸는 B 의 몫

B	u	평가
$\mathrm{diag}(0, 0, 0, \Delta t)$	$\begin{bmatrix} 0 & 0 & 0 & -g \end{bmatrix}^T$	가능하지만 과함
$\begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \Delta t \end{bmatrix}^T$	$\begin{bmatrix} 0 & -g \end{bmatrix}^T$	x, y 두 방향의 제어 입력
$\begin{bmatrix} 0 & 0 & 0 & \Delta t \end{bmatrix}^T$	$\begin{bmatrix} -g \end{bmatrix}$	**실제 존재하는 입력만, 이 예제의 선택**
$\mathrm{diag}(0, 0, 0, 1)$	$\begin{bmatrix} 0 & 0 & 0 & -g\Delta t \end{bmatrix}^T$	결과는 같지만 u 에 시간이 들어가 부적절

Design H, R, Q, and Initial Conditions

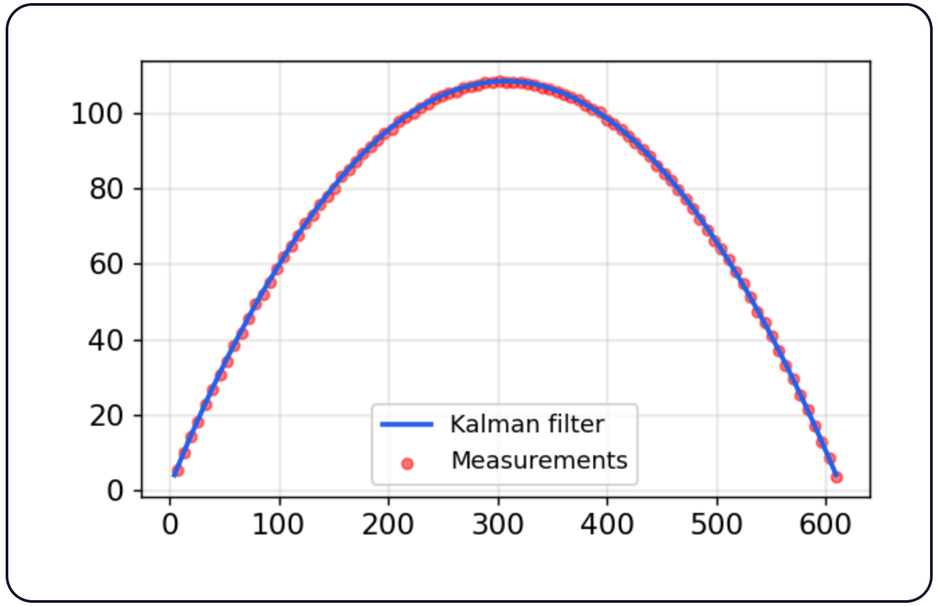
	Design	의미
8.11.4 H	$H = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$	센서는 공의 위치 (x, y) 만 측정, 속도와 가속도는 측정 불가
8.11.5 R	$R = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}$	x, y 오차는 서로 독립, 분산 0.5 m^2
8.11.6 Q	$Q = 0_{4\times 4}$	진공을 가정하므로 process noise 없음
8.11.7 x	$\mathbf{x} = \begin{bmatrix} x & v\cos\omega & y & v\sin\omega \end{bmatrix}^T$	발사 각도 ω 와 속도 v 로 초기 속도 계산

구현: ball_kf(x, y, omega, v0, dt, r, q) 가 위 설계로 F, H, B, R, Q, x 를 설정한 KalmanFilter 를 반환

Tracking a Ball in a Vacuum

- ball_kf 로 만든 필터에 시뮬레이터 측정을 넣고 매 단계 update 후 중력 u = -9.8 로 predict, 출력이 포물선을 정확히 추적
- process noise 가 없는 사소한 예, 진공 궤적은 정밀하게 예측 가능해 최소제곱 곡선 맞춤과 같은 결과
- **조건**: (0, 1) m 에서 80 m/s, 35°, dt = 0.1 s, 측정 잡음 0.2 m, R = 0.5, Q = 0

```python
dt = 1./10
x, y = 0., 1.
theta, v0 = 35., 80.   # launch angle, speed
g = np.array([[-9.8]])   # gravitational constant
ball = BallTrajectory2D(x0=x, y0=y, theta_deg=theta, velocity=v0,
                        noise=[.2, .2])
kf = ball_kf(x, y, theta, v0, dt)
xs, ys = [], []
while kf.x[2] > 0:
    x, y = ball.step(dt)
    z = np.array([[x, y]]).T
    kf.update(z)
    xs.append(kf.x[0]); ys.append(kf.x[2])
    kf.predict(u=g)
    p1 = plt.scatter(x, y, color='r', marker='.', s=75, alpha=0.5)
p2, = plt.plot(xs, ys, lw=2)
plt.legend([p2, p1], ['Kalman filter', 'Measurements'], scatterpoints=1);
```

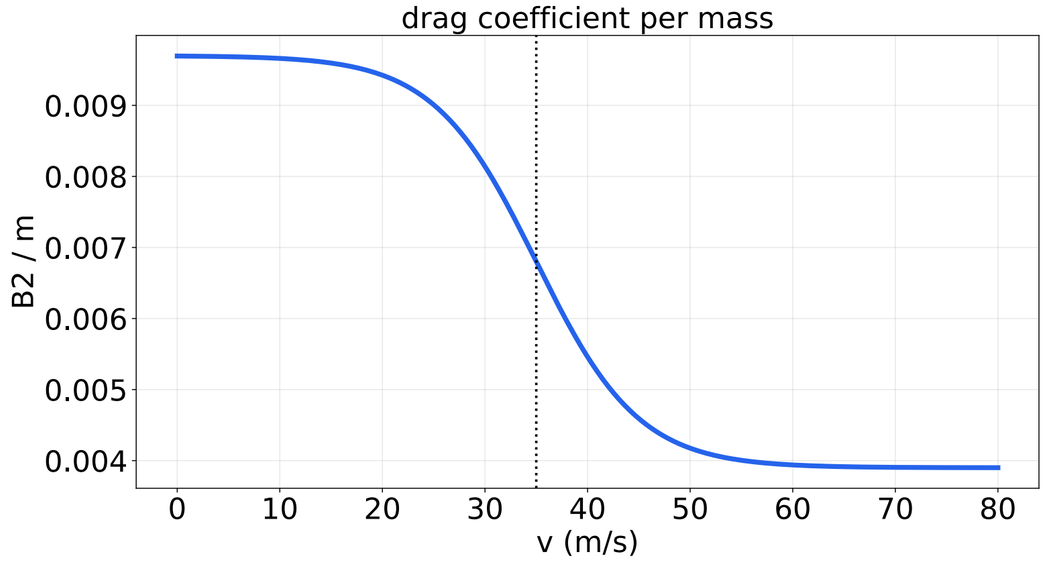


Implementing Air Drag

- **상황**: 공기 중의 공은 바람, 항력, 회전의 영향, 카메라 blob detection 으로 위치 측정, 2D 로 단순화
- **항력**: 속도의 제곱에 비례하고 속도 반대 방향, 질량으로 나눠 가속도
- **B2/m**: 풍동 실험 기반의 근사식, 35 m/s 부근에서 급변, SI 단위
- **목적**: 진공 모델과 다른 실제적 거동으로 필터를 시험

$$F_{drag} = -B_2 v^2 \qquad a_x = -\frac{B_2}{m} v v_x,\ a_y = -\frac{B_2}{m} v v_y$$

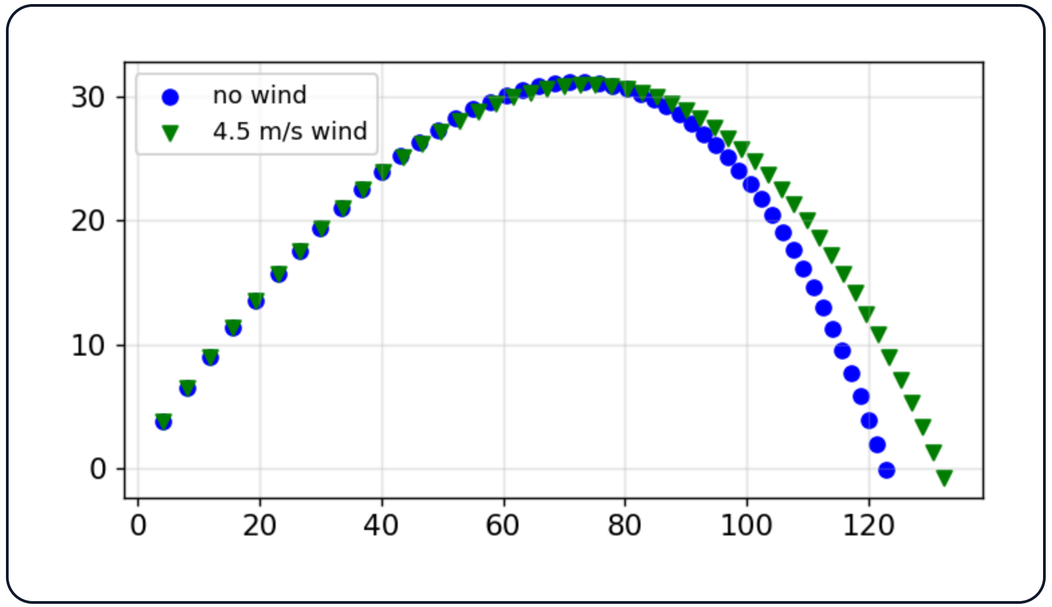
$$\frac{B_2}{m} = 0.0039 + \frac{0.0058}{1+\exp[(v-35)/5]}$$



Air Drag and Wind

- Euler 방법으로 항력과 바람을 포함한 공의 궤적을 단계별로 계산(항력이 비선형이라 해석해 없음), 무풍과 4.5 m/s 뒷바람 비교
- 진공에서 약 230 m 날아갈 공이 공기 중에서는 약 120 m, 홈런 타구로 현실적인 거리
- **조건**: 초기 속도 49.2 m/s (홈런 타구 속도), 35°, (0, 1) m, dt = 0.1 s, drag_force(v) = v B2/m

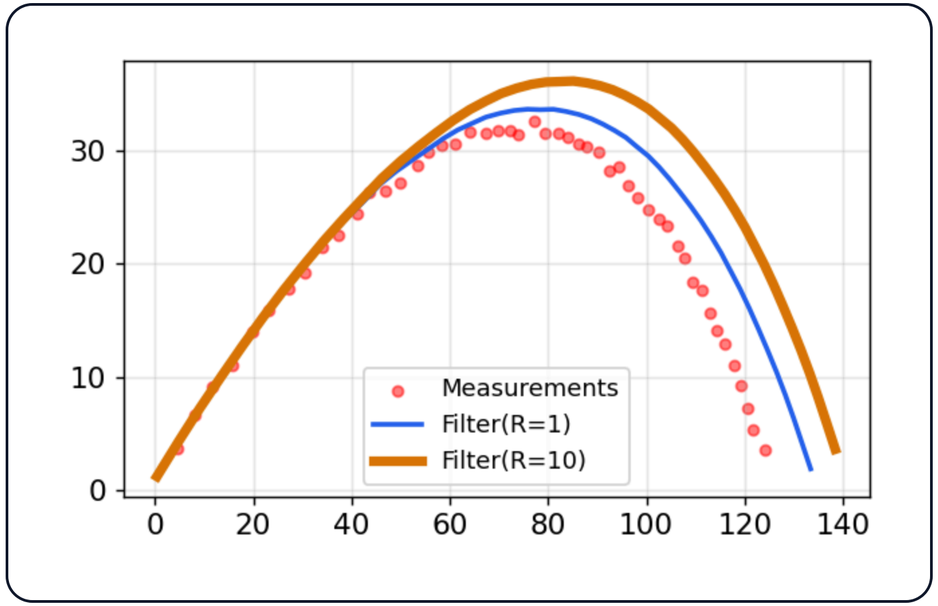
```
v, dt, theta = 49.2, .1, radians(35)   # m/s, s, rad
def solve(x, y, vel, v_wind, launch_angle):
    xs, ys = [], []
    v_x, v_y = vel*cos(launch_angle), vel*sin(launch_angle)
    while y >= 0:
        # Euler equations for x and y
        x += v_x*dt
        y += v_y*dt
        # force due to air drag
        velocity = sqrt((v_x-v_wind)**2 + v_y**2)
        F = drag_force(velocity)
        v_x = v_x - F*(v_x-v_wind)*dt
        v_y = v_y - 9.8*dt - F*v_y*dt
        xs.append(x); ys.append(y)
    return xs, ys
x, y = solve(x=0, y=1, vel=v, v_wind=0, launch_angle=theta)
plt.scatter(x, y, color='blue', label='no wind')
x, y = solve(x=0, y=1, vel=v, v_wind=4.5, launch_angle=theta)
plt.scatter(x, y, color='green', marker='v', label='4.5 m/s wind')
plt.legend(scatterpoints=1);
```



Tracking a Ball in Air

- 항력이 있는 공(BaseballPath)을 진공 모델의 필터(Q = 0)로 추적, 처음엔 측정을 잘 따르지만 점점 발산
- 항력에 의한 감속을 모델이 몰라 공보다 계속 앞서 나감, 가속이 이어지는 한 선형 모델은 따라잡을 수 없음
- **조건**: (0, 1) m 에서 50 m/s, 35°, dt = 0.1 s, 측정 잡음 0.3 m, Q = 0, R = 1 과 10 은 측정 잡음의 영향을 보이기 위한 값

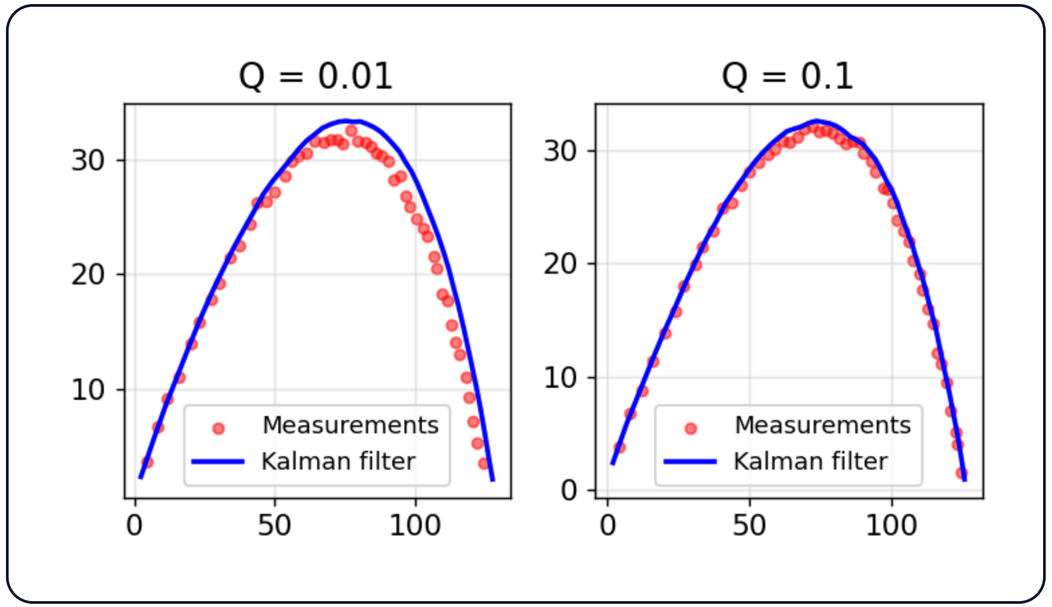
```
x, y, theta, v0, dt = 0, 1., 35., 50., 1/10.
g = np.array([[-9.8]])
ball = BaseballPath(x0=x, y0=y, launch_angle_deg=theta,
                    velocity_ms=v0, noise=[.3, .3])
f1 = ball_kf(x, y, theta, v0, dt, r=1.)
f2 = ball_kf(x, y, theta, v0, dt, r=10.)
xs, ys, xs2, ys2 = [], [], [], []
while f1.x[2] > 0:
    x, y = ball.update(dt)
    z = np.array([[x, y]]).T
    f1.update(z); f2.update(z)
    xs.append(f1.x[0]); ys.append(f1.x[2])
    xs2.append(f2.x[0]); ys2.append(f2.x[2])
    f1.predict(u=g); f2.predict(u=g)
    p1 = plt.scatter(x, y, color='r', marker='.', s=75, alpha=0.5)
p2, = plt.plot(xs, ys, lw=2)
p3, = plt.plot(xs2, ys2, lw=4)
plt.legend([p1, p2, p3], ['Measurements', 'Filter(R=1)', 'Filter(R=10)'],
           loc='best', scatterpoints=1);
```



Air Force as Process Noise

- 공기가 공에 가하는 힘을 process noise 로 간주하는 공학적 해법, Q = 0.01 과 Q = 0.1 로 같은 추적 반복
- Q = 0.1 은 약간의 lag 만 남고 측정을 잘 따라감, 다만 이 힘은 Gaussian 이 아니고 계산 가능한 힘이라 최적 해법은 아님
- **조건**: R = 1, 측정 잡음 0.3 m, 왼쪽: Q = 0.01, 오른쪽: Q = 0.1

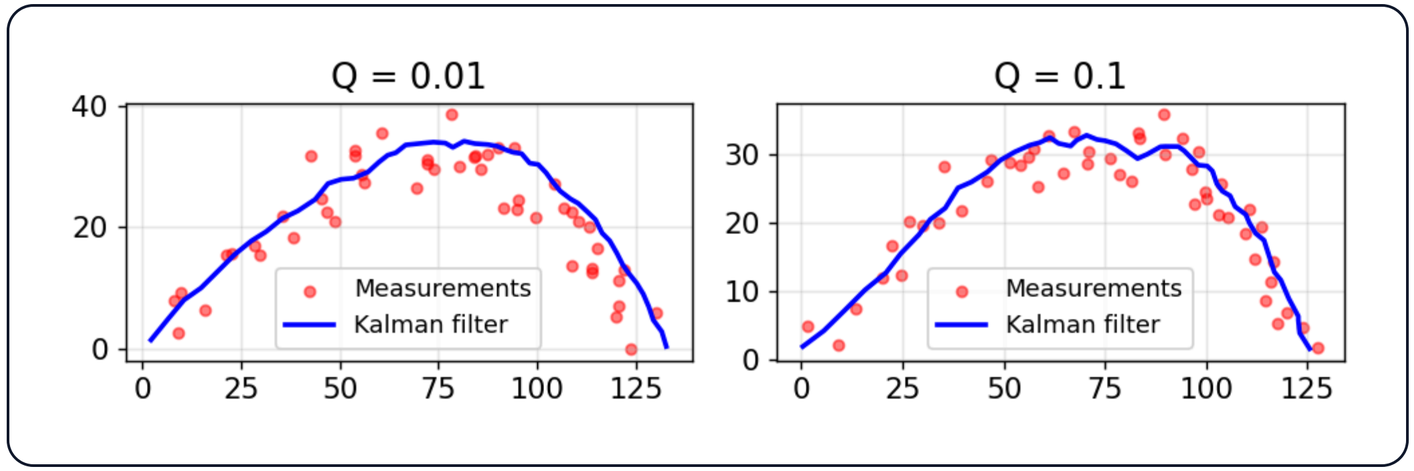
```python
def plot_ball_with_q(q, r=1., noise=0.3):
    x, y, theta, v0, dt = 0., 1., 35., 50., 1/10.
    g = np.array([[-9.8]])
    ball = BaseballPath(x0=x, y0=y, launch_angle_deg=theta,
                        velocity_ms=v0, noise=[noise, noise])
    f1 = ball_kf(x, y, theta, v0, dt, r=r, q=q)
    xs, ys = [], []
    while f1.x[2] > 0:
        x, y = ball.update(dt)
        z = np.array([[x, y]]).T
        f1.update(z)
        xs.append(f1.x[0]); ys.append(f1.x[2])
        f1.predict(u=g)
        p1 = plt.scatter(x, y, c='r', marker='.', s=75, alpha=0.5)
    p2, = plt.plot(xs, ys, lw=2, color='b')
    plt.legend([p1, p2], ['Measurements', 'Kalman filter'])
    plt.title('Q = {}'.format(q))
plt.subplot(121); plot_ball_with_q(0.01)
plt.subplot(122); plot_ball_with_q(0.1)
```



Noisy Measurements

- 같은 방법을 측정 잡음 3 m 의 데이터에 적용, 출력이 매우 나쁨, 측정 비중이 커진 필터가 잡음을 그대로 따라감
- Q, R 을 이론값보다 키워 약한 비선형을 가릴 수는 있지만 준최적, 시험 데이터에만 맞춘 필터는 실제 데이터에서 실패 가능
- **조건**: R = 3, 측정 잡음 3 m, 왼쪽: Q = 0.01, 오른쪽: Q = 0.1

```
plt.subplot(121)
plot_ball_with_q(0.01, r=3, noise=3.)
plt.subplot(122)
plot_ball_with_q(0.1, r=3, noise=3.)
```



핵심: 비선형 문제에 선형 Kalman filter 를 억지로 적용한 사례, 비선형 필터 기법이 필요한 이유