Localization for Autonomous Navigation

Chapter 10. The Unscented Kalman Filter

Dept. Intelligent Systems & Robots

Prof. SungTae Moon



Contents

- Sigma Points - Sampling from a Distribution
- A Quick Example
- Choosing Sigma Points
- The Unscented Transform
- The Unscented Kalman Filter
- Van der Merwe's Scaled Sigma Point Algorithm
- Using the UKF
- Tracking an Airplane
- Effects of Sensor Error and Geometry
- Exercise: Explain Filter Performance
- Implementation of the UKF
- Batch Processing
- Smoothing the Results
- Choosing the Sigma Parameters
- Robot Localization - A Fully Worked Example
- Discussion

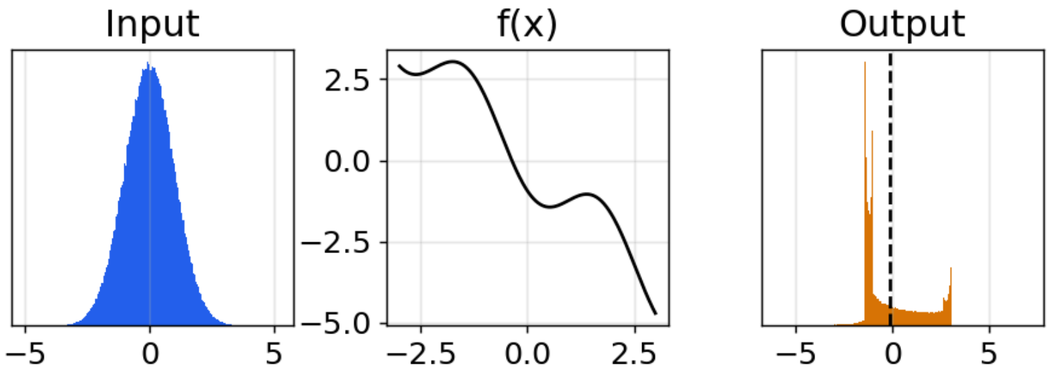
Nonlinear Systems

- 비선형 함수 f(x) = cos(4(x/2 + 0.7)) - 1.3x 에 $\mathcal{N}(0, 1)$ 표본 500,000 개를 통과시켜 히스토그램 작성
- 출력은 Gaussian 이 아닌 뾰족한 봉우리 모양, 출력의 평균과 표준편차로 근사 Gaussian 계산 가능
- 레이더 slant range 의 제곱근 계산, 공기 저항을 받는 공처럼 측정과 process 모두 비선형일 수 있음
- **조건**: 입력 $\mathcal{N}(0, 1)$, 표본 500,000 개, 구간 300 개

```python
from numpy.random import normal
data = normal(loc=0., scale=1., size=500000)
def f(x):
    return (np.cos(4*(x/2 + 0.7))) - 1.3*x

plots.plot_nonlinear_func(data, f)
```

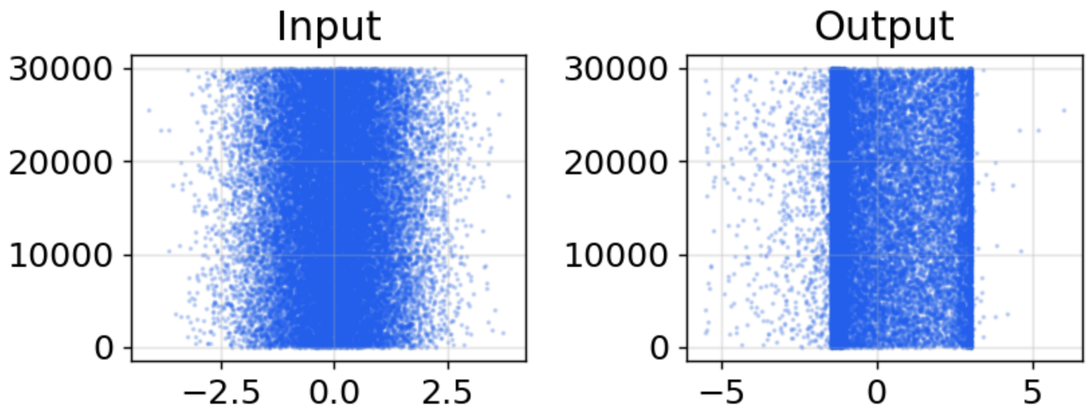
```
output mean=-0.126, std=1.554
```



Input and Output Samples

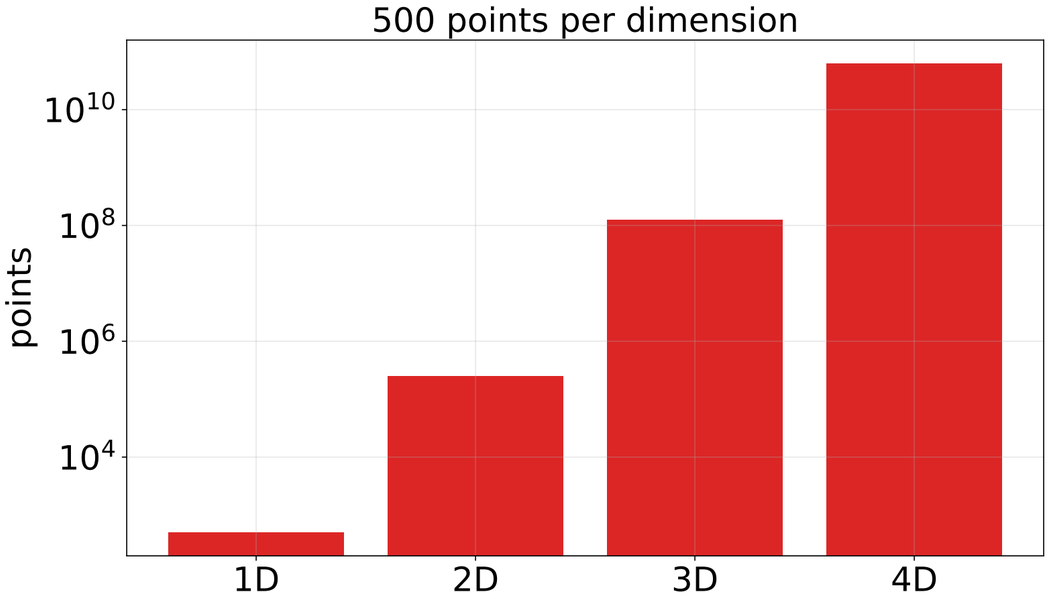
- 같은 표본 중 30,000 개를 함수 통과 전과 후로 나눠 산점도로 표시
- 입력은 평균 0 주변에 흩어진 white noise, 출력은 두 개의 띠와 그 사이 점들이 있는 구조
- 띠 바깥에도 점이 흩어져 있고 음수 쪽에 훨씬 많음, 출력 분포는 Gaussian 이 아님
- **조건**: 입력 $\mathcal{N}(0, 1)$, 표본 30,000 개, 세로축은 표본 번호

```
N = 30000
plt.subplot(121)
plt.scatter(data[:N], range(N), alpha=.2, s=1)
plt.title('Input')
plt.subplot(122)
plt.title('Output')
plt.scatter(f(data[:N]), range(N), alpha=.2, s=1);
```



Monte Carlo Approach

- **Monte Carlo**: 매 갱신마다 많은 점을 비선형 함수에 통과시키고 결과의 평균과 분산 계산
- **사용 예**: Ensemble filter, particle filter
- **장점**: 특별한 지식, 닫힌 형태의 해 불필요, 점이 충분하면 어떤 함수에도 정확
- **문제**: 500,000 개로도 출력이 매끄럽지 않음, 필요한 점 수는 차원의 거듭제곱으로 증가
- **UKF**: sigma point 를 결정론적으로 골라 계산량을 크게 줄임

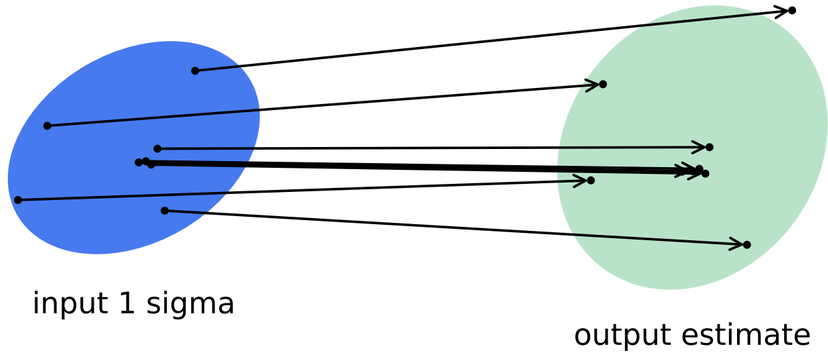


$$500^1 = 500, \quad 500^2 = 250{,}000, \quad 500^3 = 125{,}000{,}000$$

> **핵심**: 무작위 표본은 차원이 늘수록 계산량이 폭발, 적은 수의 점을 잘 고르는 방법이 필요

Sigma Points - Sampling from a Distribution

- **2D 공분산 타원**: 그리기 쉬워 2 차원으로 설명, 임의 차원으로 확장 가능
- **방법**: 첫 공분산 타원에서 무작위 점을 뽑아 비선형 함수로 이동
- **추정**: 이동한 점들의 평균과 공분산을 새 확률 분포의 추정으로 사용
- **그림**: 왼쪽 1 σ 타원과 표본 점, 오른쪽 반투명 타원은 이동한 점들의 추정



$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 32 & 15 \\ 15 & 40 \end{bmatrix}$$

$$\bar{x} = x + y, \quad \bar{y} = 0.1x^2 + y^2$$

Linearized Mean

- $\mathcal{N}(0, [[32, 15], [15, 40]])$ 에서 10,000 개 표본을 뽑아 비선형 함수 (x + y, $0.1x^2 + y^2$) 에 통과
- 빨간 삼각형은 평균만 함수에 넣은 선형화 평균, 파란 별은 표본들로 계산한 실제 평균
- y 방향 차이가 40 이상, 한 점에서 선형화하는 방식은 큰 오차를 만든다는 증거
- **조건**: 평균 (0, 0), 공분산 [[32, 15], [15, 40]], 표본 10,000 개

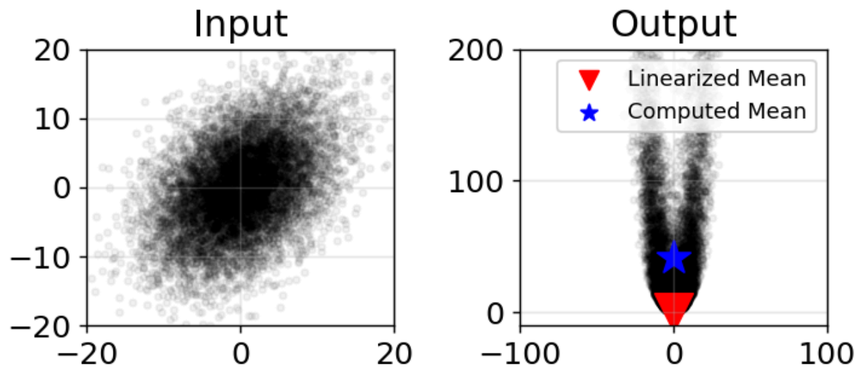
```python
from numpy.random import multivariate_normal

def f_nonlinear_xy(x, y):
    return np.array([x + y, .1*x**2 + y*y])

mean = (0., 0.)
p = np.array([[32., 15.], [15., 40.]])
# Compute linearized mean
mean_fx = f_nonlinear_xy(*mean)

#generate random points
xs, ys = multivariate_normal(mean=mean, cov=p, size=10000).T
plots.plot_monte_carlo_mean(xs, ys, f_nonlinear_xy,
                            mean_fx, 'Linearized Mean');
```

```
Difference in mean x=-0.004, y=41.690
```

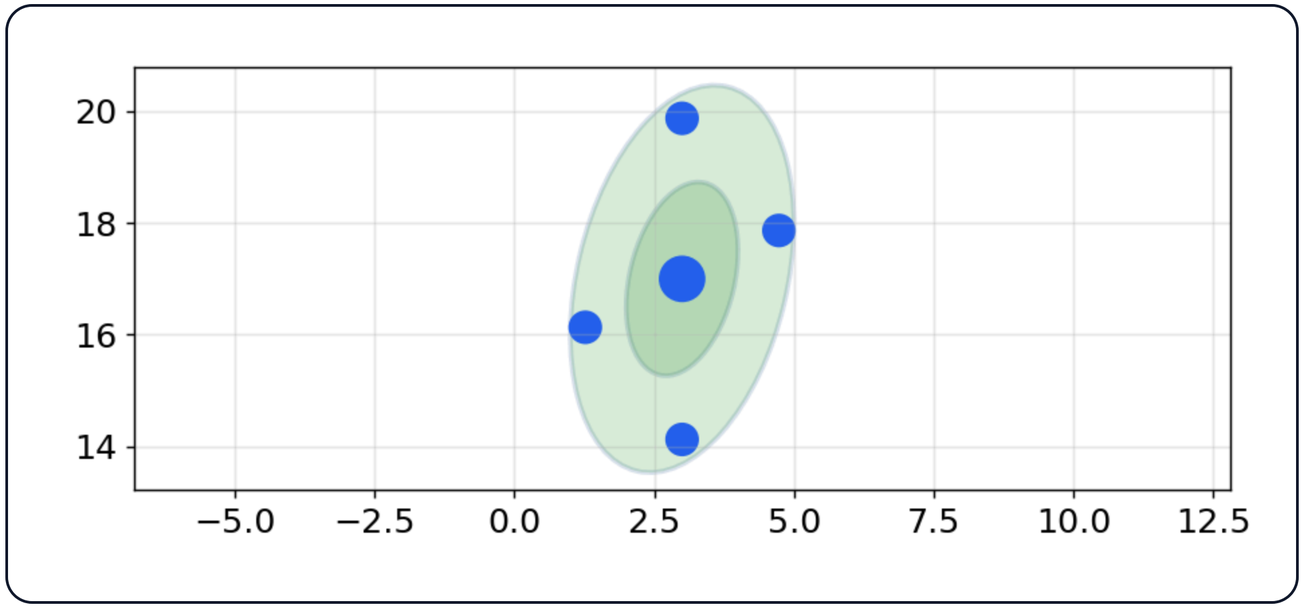


Julier Sigma Points

- sigma point 를 만드는 여러 알고리즘 중 하나인 JulierSigmaPoints 로 2 차원 sigma point 생성
- 점의 크기는 가중치, 평균 (3, 17) 주변의 5 개 점이 500,000 개 무작위 점만큼 또는 그 이상으로 동작
- **조건**: n = 2, κ = 1, 평균 (3, 17), 공분산 [[1, 0.5], [0.5, 3]], 녹색 타원은 1, 2 σ

```python
from filterpy.kalman import JulierSigmaPoints

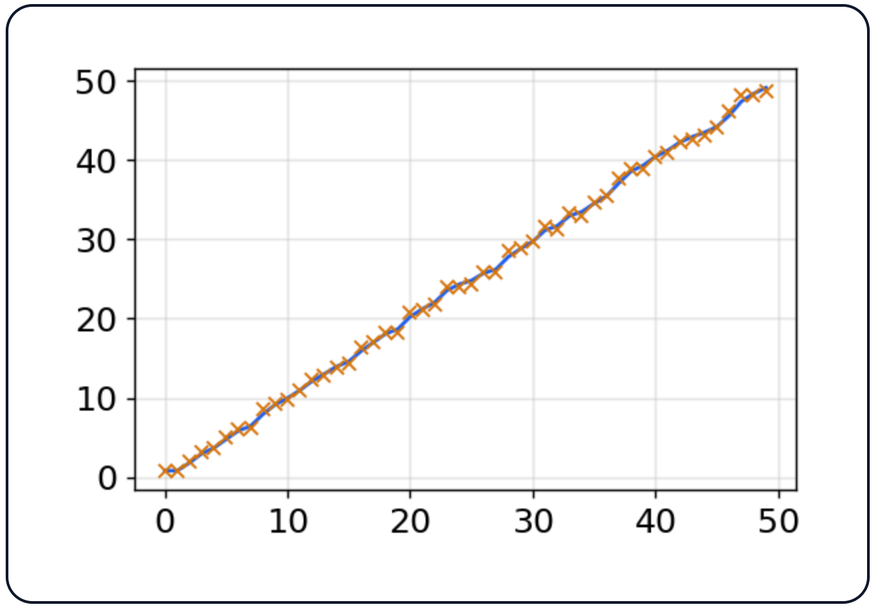
sigmas = JulierSigmaPoints(n=2, kappa=1)
plots.plot_sigmas(sigmas, x=[3, 17],
                  cov=[[1, .5], [.5, 3]])
```



A Quick Example

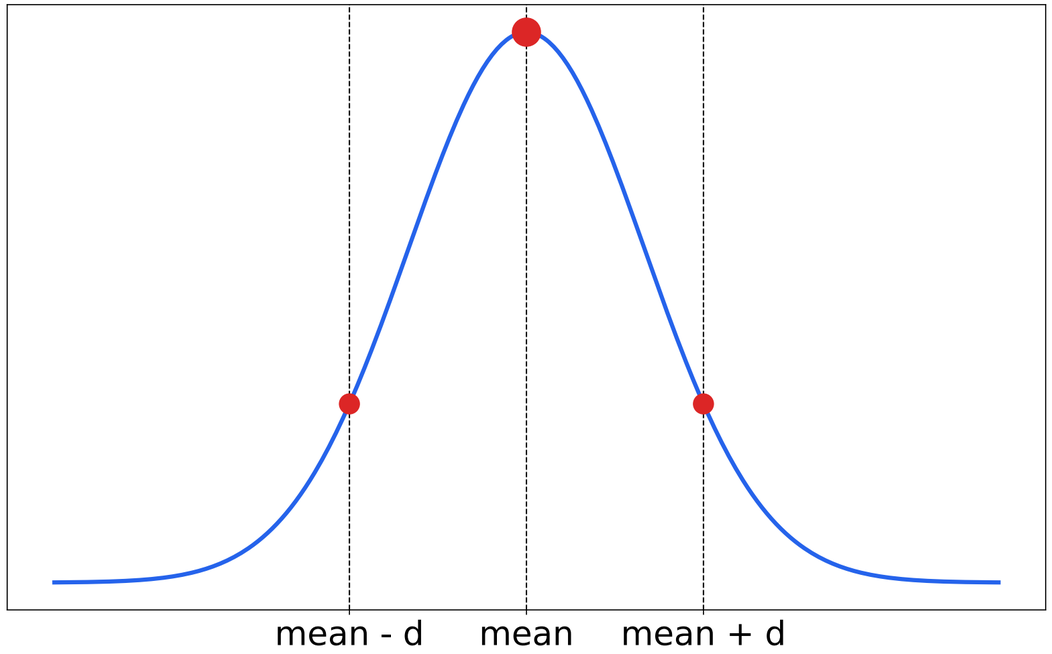
- 상태 [x, $\dot{x}$] 의 1 차원 등속 추적, 행렬 F, H 대신 함수 fx(), hx() 를 필터에 전달, 나머지 설계는 동일
- fx() 를 행렬 곱이 아닌 식으로 작성, 같은 자리에 임의의 비선형 함수도 넣을 수 있음
- **조건**: Julier sigma points, 측정 z = i + $\mathcal{N}(0, 0.5^2)$, 50 단계, P = 10 I, R = 0.5, Q 분산 0.03

```python
def fx(x, dt):
    xout = np.empty_like(x)
    xout[0] = x[1] * dt + x[0]
    xout[1] = x[1]
    return xout
def hx(x):
    return x[:1] # return position [x]
ukf = UnscentedKalmanFilter(dim_x=2, dim_z=1, dt=1., hx=hx, fx=fx, points=sigmas)
ukf.P *= 10
ukf.R *= .5
ukf.Q = Q_discrete_white_noise(2, dt=1., var=0.03)
zs, xs = [], []
for i in range(50):
    z = i + randn()*.5
    ukf.predict()
    ukf.update(z)
    xs.append(ukf.x[0])
    zs.append(z)
plt.plot(xs); plt.plot(zs, marker='x', ls='');
```



Choosing Sigma Points

- **목표**: 함수에 대한 사전 지식 없이 모든 함수에 쓰는 일반 알고리즘, 가장 적은 점의 수
- **기준**: 항등 함수 f(x) = x 에서 입력과 출력이 같아야 함, 아니면 필터 발산
- **1 개**: 평균 그대로면 선형 Kalman filter, 평균 + 델타면 항등 함수에서 발산
- **2 개**: 평균과 다른 한 점, 비대칭이 생겨 항등 함수를 만족시키기 어려움
- **3 개**: 평균과 양쪽에 하나씩, Gaussian 의 대칭성 유지

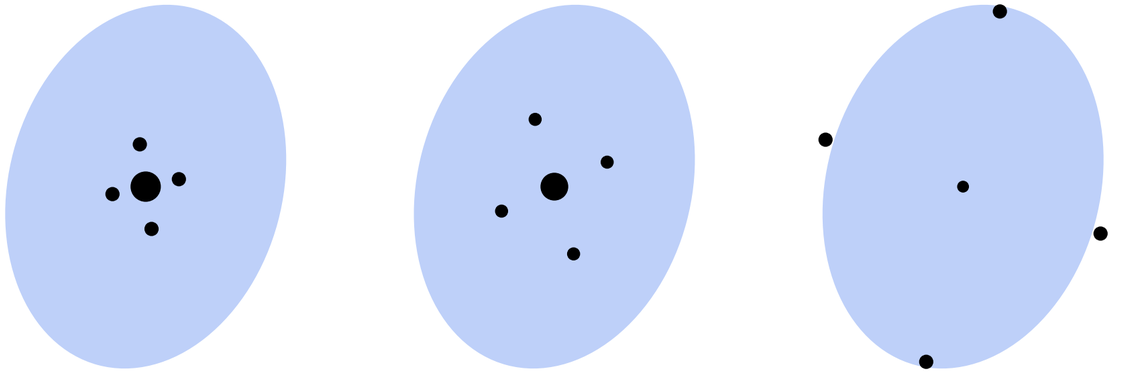


> **핵심**: 차원당 3 개의 점, 평균과 그 양쪽 대칭 위치에서 시작

Weights and Constraints

$$1 = \sum_i w_i^m \qquad 1 = \sum_i w_i^c \qquad \mu = \sum_i w_i^m f(\mathcal{X}_i) \qquad \Sigma = \sum_i w_i^c (f(\mathcal{X})_i - \mu)(f(\mathcal{X})_i - \mu)^\mathsf{T}$$

- **가중 평균**: 비선형이 강하면 중심점 가중치를 키우거나 바깥 점 가중치를 키움
- **해의 유일성 없음**: w0 를 줄이면 w1, w2 를 키워 보상, 평균이 sigma point 일 필요도 없음
- **가까운 점**: 국소 효과를 표본, 비선형이 강한 문제에 유리
- **먼 점**: 비국소 효과와 non-Gaussian 거동 표본, 작은 가중치로 영향 조절



- **그림**: 같은 타원에 대한 세 가지 sigma point 선택, 점 크기는 가중치

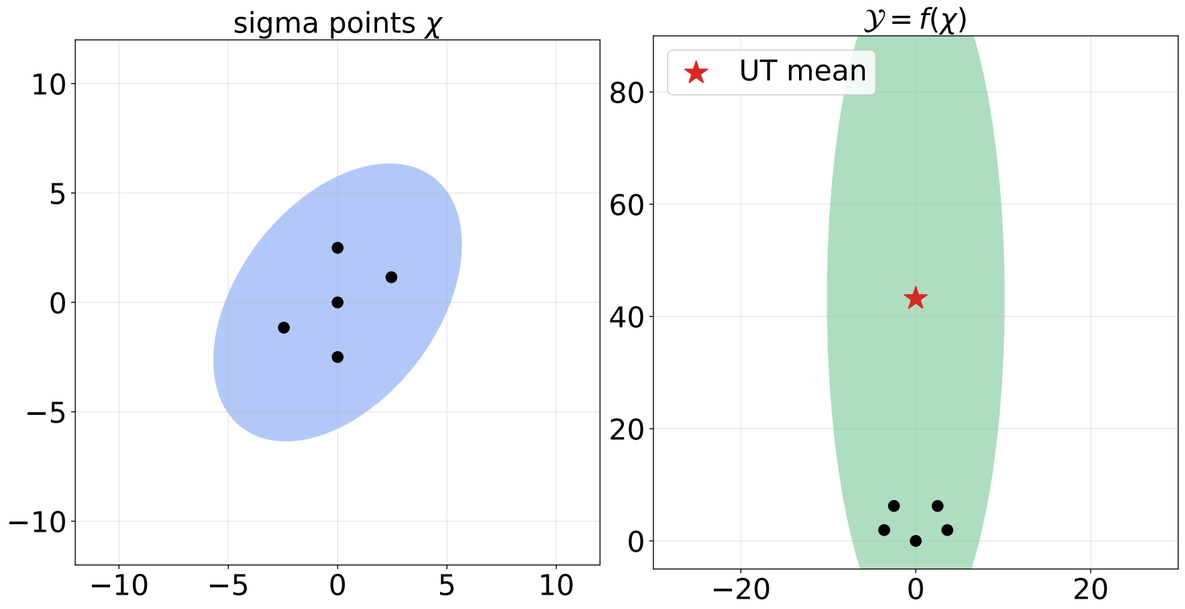
The Unscented Transform

- **변환**: sigma point 를 비선형 함수에 통과, 변환된 점들의 평균과 공분산이 새 추정
- **결과**: 임의의 분포에서 뽑은 점을 임의의 비선형 함수에 통과시켜 Gaussian 을 얻음
- **그림**: 왼쪽 sigma point, 오른쪽 변환된 점과 UT 평균, 공분산(녹색)

$$\mathcal{Y} = f(\chi)$$

$$\mu = \sum_{i=0}^{2n} w_i^m \mathcal{Y}_i$$

$$\Sigma = \sum_{i=0}^{2n} w_i^c (\mathcal{Y}_i - \mu)(\mathcal{Y}_i - \mu)^\mathsf{T}$$

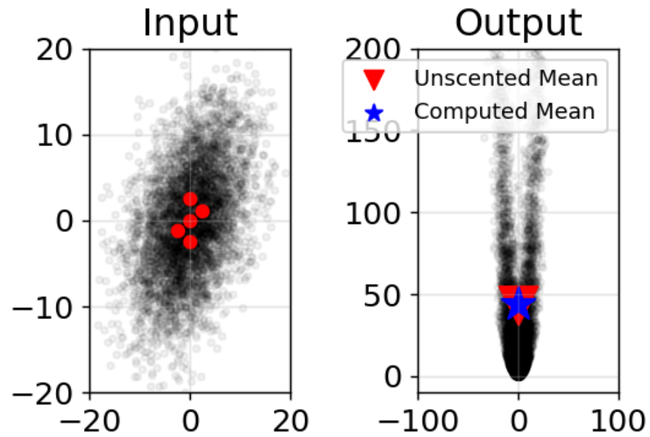


Accuracy of the Unscented Transform

- 같은 비선형 함수에 sigma point 5 개(빨간 점)만 통과시키고 unscented transform 으로 평균 계산
- 평균 오차가 x 약 -0.1, y 약 0.5 로 선형화의 40 이상보다 훨씬 작음, 점은 함수를 모르고 생성
- **조건**: MerweScaledSigmaPoints n = 2, α 0.3, β 2, κ 0.1, 비교용 표본 5,000 개

```python
from filterpy.kalman import unscented_transform, MerweScaledSigmaPoints
mean = (0., 0.)
p = np.array([[32., 15], [15., 40.]])
# create sigma points and weights
points = MerweScaledSigmaPoints(n=2, alpha=.3, beta=2., kappa=.1)
sigmas = points.sigma_points(mean, p)
### pass through nonlinear function
sigmas_f = np.empty((5, 2))
for i in range(5):
    sigmas_f[i] = f_nonlinear_xy(sigmas[i, 0], sigmas[i ,1])
### use unscented transform to get new mean and covariance
ukf_mean, ukf_cov = unscented_transform(sigmas_f, points.Wm, points.Wc)
np.random.seed(100)
xs, ys = multivariate_normal(mean=mean, cov=p, size=5000).T
plots.plot_monte_carlo_mean(xs, ys, f_nonlinear_xy, ukf_mean, 'Unscented Mean')
ax = plt.gcf().axes[0]
ax.scatter(sigmas[:,0], sigmas[:,1], c='r', s=30);
```

```
Difference in mean x=-0.097, y=0.549
```



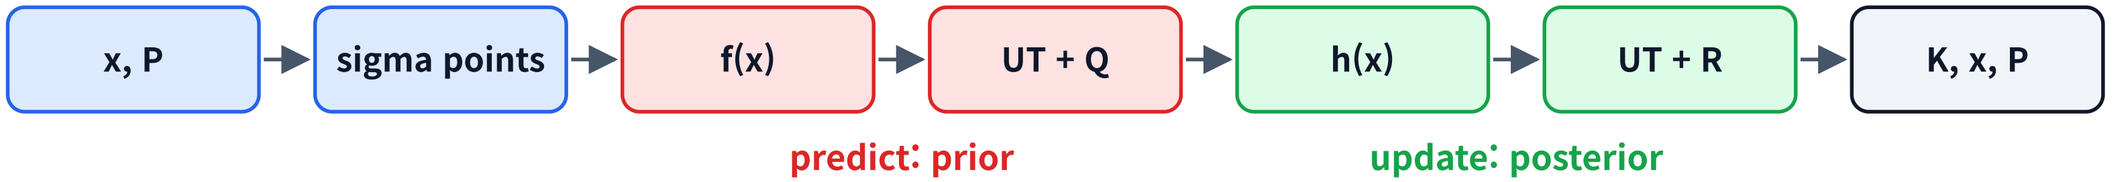
Predict Step

- **sigma point**: process 모델 f() 가 비선형이므로 x, P 에서 sigma point 와 가중치 생성
- **prior**: 각 sigma point 를 f(x, dt) 로 시간 전진, 변환된 점 집합이 prior

$$\chi = \text{sigma-function}(\mathbf{x}, \mathbf{P})$$
$$W^m, W^c = \text{weight-function}(n, \text{params})$$
$$\mathcal{Y} = f(\chi, \Delta t)$$

$$\bar{\mathbf{x}} = \sum_{i=0}^{2n} w_i^m \mathcal{Y}_i$$
$$\bar{\mathbf{P}} = \sum_{i=0}^{2n} w_i^c (\mathcal{Y}_i - \bar{\mathbf{x}})(\mathcal{Y}_i - \bar{\mathbf{x}})^\mathsf{T} + \mathbf{Q}$$

Kalman	Unscented
	$\mathcal{Y} = f(\chi)$
$\bar{\mathbf{x}} = \mathbf{F}\mathbf{x}$	$\bar{\mathbf{x}} = \sum w^m \mathcal{Y}$
$\bar{\mathbf{P}} = \mathbf{F}\mathbf{P}\mathbf{F}^\mathsf{T} + \mathbf{Q}$	$\bar{\mathbf{P}} = \sum w^c (\mathcal{Y} - \bar{\mathbf{x}})(\mathcal{Y} - \bar{\mathbf{x}})^\mathsf{T} + \mathbf{Q}$



Update Step

- **측정 공간**: prior sigma point 를 h() 로 측정 공간에 변환
- **Kalman gain**: 교차 공분산을 측정 공분산으로 나눈 비율

$$\mathcal{Z} = h(\mathcal{Y})$$

$$\boldsymbol{\mu}_z = \sum_{i=0}^{2n} w_i^m \mathcal{Z}_i$$

$$\mathbf{P}_z = \sum_{i=0}^{2n} w_i^c (\mathcal{Z}_i - \boldsymbol{\mu}_z)(\mathcal{Z}_i - \boldsymbol{\mu}_z)^\mathsf{T} + \mathbf{R}$$

$$\mathbf{y} = \mathbf{z} - \boldsymbol{\mu}_z$$

$$\mathbf{P}_{xz} = \sum_{i=0}^{2n} w_i^c (\mathcal{Y}_i - \bar{\mathbf{x}})(\mathcal{Z}_i - \boldsymbol{\mu}_z)^\mathsf{T}$$

$$\mathbf{K} = \mathbf{P}_{xz}\mathbf{P}_z^{-1} \approx \frac{\text{belief in state}}{\text{belief in measurement}}$$

$$\mathbf{x} = \bar{\mathbf{x}} + \mathbf{K}\mathbf{y}$$

$$\mathbf{P} = \bar{\mathbf{P}} - \mathbf{K}\mathbf{P}_\mathbf{z}\mathbf{K}^\mathsf{T}$$

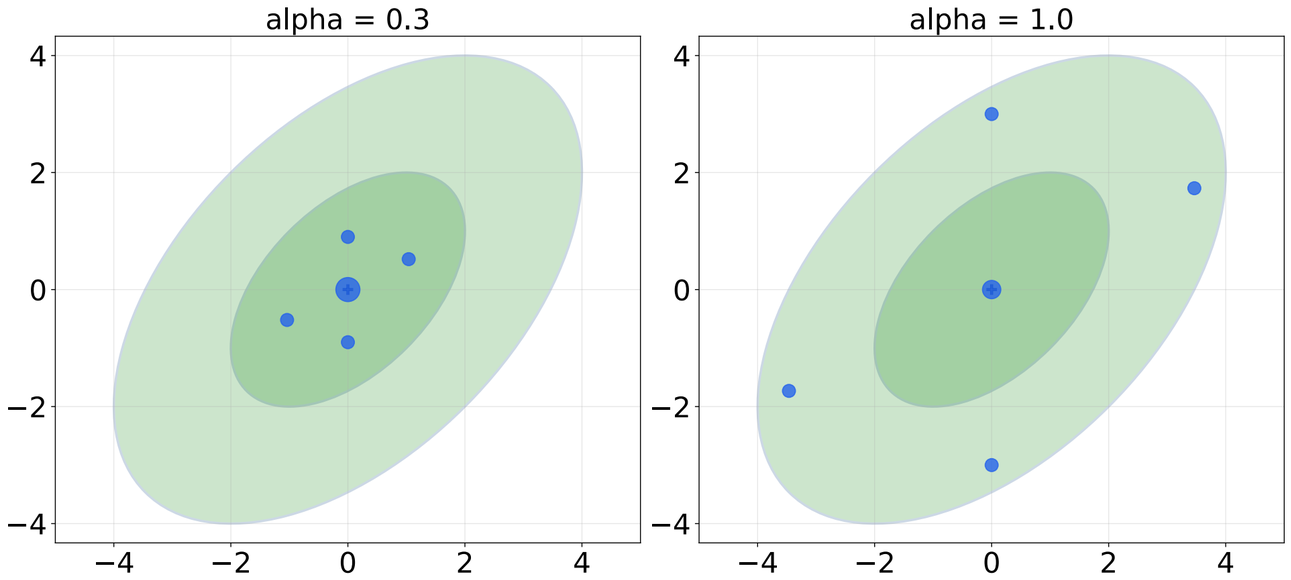
> **핵심**: 선형 대수는 조금 다르지만 같은 Bayesian 알고리즘, 예측하고 측정하고 둘 사이를 고름

Kalman Filter and Unscented Kalman Filter

	Kalman Filter	Unscented Kalman Filter
Predict	$\bar{\mathbf{x}} = \mathbf{F}\mathbf{x}$	$\mathcal{Y} = f(\chi), \quad \bar{\mathbf{x}} = \sum w^m \mathcal{Y}$
	$\bar{\mathbf{P}} = \mathbf{F}\mathbf{P}\mathbf{F}^\mathsf{T} + \mathbf{Q}$	$\bar{\mathbf{P}} = \sum w^c (\mathcal{Y} - \bar{\mathbf{x}})(\mathcal{Y} - \bar{\mathbf{x}})^\mathsf{T} + \mathbf{Q}$
Update	$\mathbf{y} = \mathbf{z} - \mathbf{H}\bar{\mathbf{x}}$	$\mathcal{Z} = h(\mathcal{Y}), \quad \boldsymbol{\mu}_z = \sum w^m \mathcal{Z}, \quad \mathbf{y} = \mathbf{z} - \boldsymbol{\mu}_z$
	$\mathbf{S} = \mathbf{H}\bar{\mathbf{P}}\mathbf{H}^\mathsf{T} + \mathbf{R}$	$\mathbf{P}_z = \sum w^c (\mathcal{Z} - \boldsymbol{\mu}_z)(\mathcal{Z} - \boldsymbol{\mu}_z)^\mathsf{T} + \mathbf{R}$
	$\mathbf{K} = \bar{\mathbf{P}}\mathbf{H}^\mathsf{T}\mathbf{S}^{-1}$	$\mathbf{K} = \left[\sum w^c (\mathcal{Y} - \bar{\mathbf{x}})(\mathcal{Z} - \boldsymbol{\mu}_z)^\mathsf{T}\right] \mathbf{P}_z^{-1}$
	$\mathbf{x} = \bar{\mathbf{x}} + \mathbf{K}\mathbf{y}$	$\mathbf{x} = \bar{\mathbf{x}} + \mathbf{K}\mathbf{y}$
	$\mathbf{P} = (\mathbf{I} - \mathbf{K}\mathbf{H})\bar{\mathbf{P}}$	$\mathbf{P} = \bar{\mathbf{P}} - \mathbf{K}\mathbf{P}_z\mathbf{K}^\mathsf{T}$

Van der Merwe's Scaled Sigma Point Algorithm

- **표준**: 2005 년 무렵부터 연구와 산업에서 주로 쓰는 sigma point 알고리즘
- **장점**: 다양한 문제에서 잘 동작, 성능과 정확도의 균형
- **파라미터**: α, β, κ 로 sigma point 의 분포와 가중치 조절
- **그림**: 1, 2 표준편차 타원 위의 sigma point, 점 크기는 가중치
- **관찰**: α 가 크면 점이 퍼지고 중심 가중치는 커지며 나머지는 작아짐



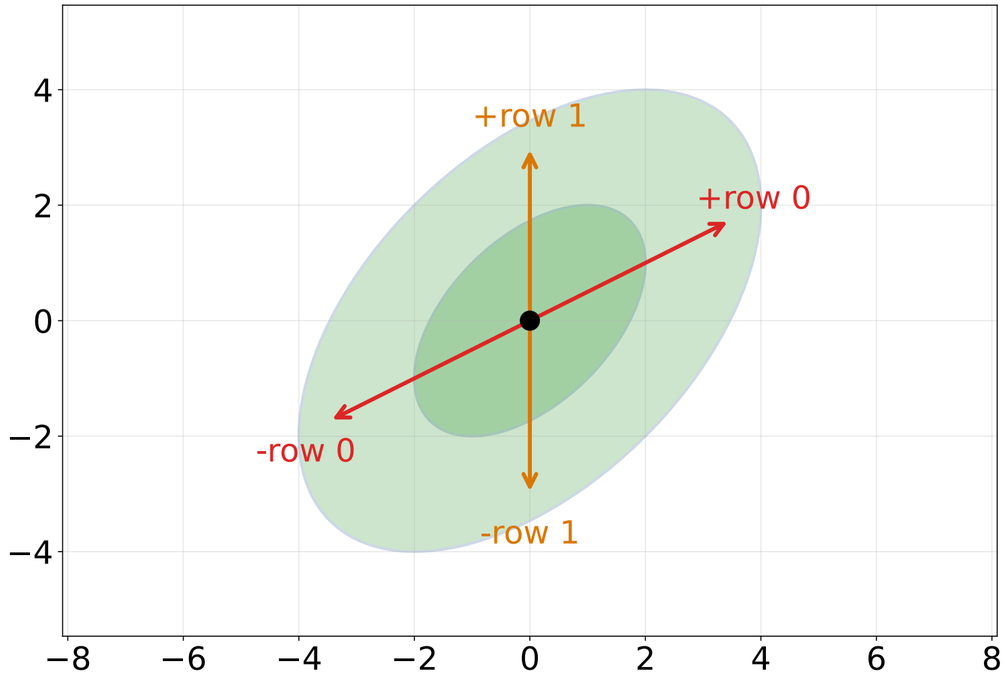
> **핵심**: 평균에서 멀리 있는 점일수록 작은 가중치, 직관과 일치하는 선택

Sigma Point Computation

$$\chi_0 = \mu \qquad \lambda = \alpha^2(n+\kappa) - n$$

$$\chi_i = \begin{cases} \mu + \left[\sqrt{(n+\lambda)\Sigma}\right]_i & i = 1 \dots n \\ \mu - \left[\sqrt{(n+\lambda)\Sigma}\right]_{i-n} & i = (n+1) \dots 2n \end{cases}$$

- **첫 점**: 입력의 평균, 타원 중심
- **n**: 상태 x 의 차원
- **나머지**: 공분산에 상수를 곱해 제곱근을 구하고 평균에 더하고 빼서 대칭 유지
- **첨자 i**: 행렬의 i 번째 행 벡터, 그림의 화살표

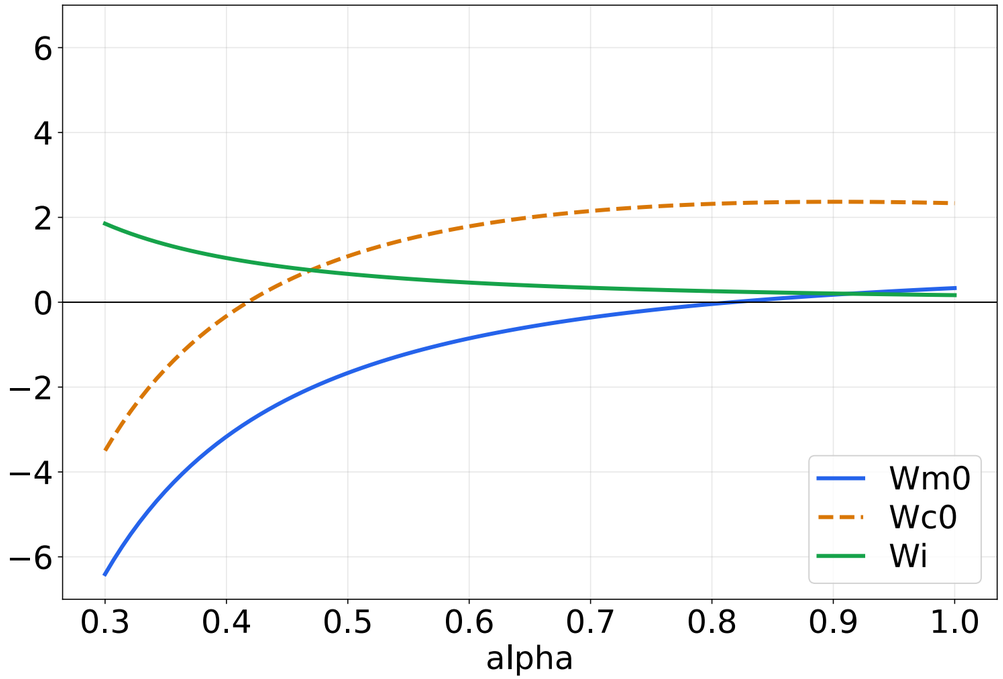


Weight Computation

$$W_0^m = \frac{\lambda}{n+\lambda} \qquad W_0^c = \frac{\lambda}{n+\lambda} + 1 - \alpha^2 + \beta$$

$$W_i^m = W_i^c = \frac{1}{2(n+\lambda)} \quad i = 1 \dots 2n$$

- **두 가중치**: 평균용 Wm 과 공분산용 Wc, 중심점만 서로 다름
- **퍼짐**: sigma point 는 공분산 제곱근에 비례, 대략 $\pm 1\sigma$ 에 배율을 곱한 위치
- **차원**: 분모의 n 때문에 차원이 높을수록 점이 퍼지고 가중치는 작아짐
- **주의**: 가중치 합이 1 이 아니거나 음수인 것은 정상
- **그림**: n = 2, κ = 1, β = 2 에서 α 에 따른 가중치



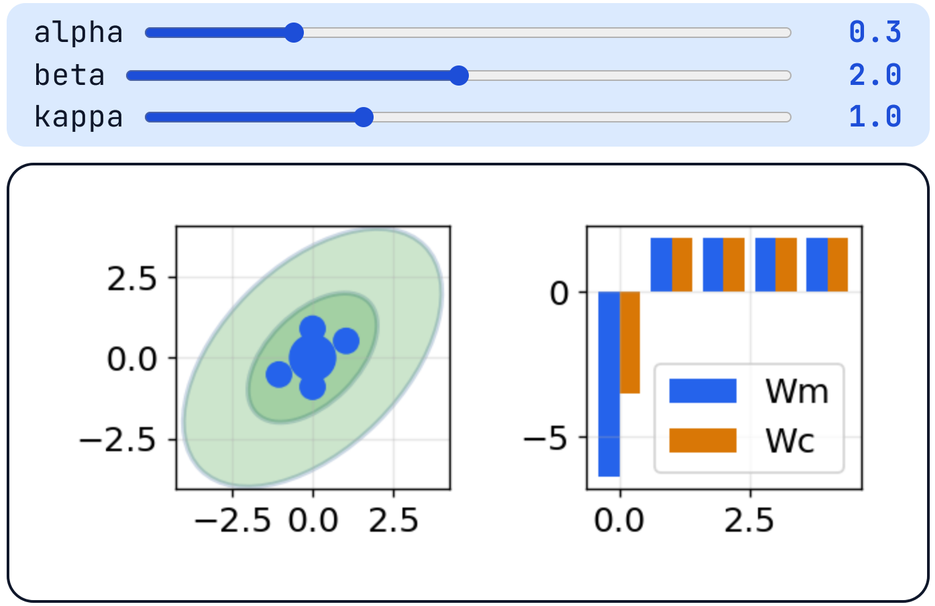
Reasonable Choices for the Parameters

- 권장값 β = 2, κ = 3 - n, $0 < \alpha \leq 1$, 슬라이더로 바꿔 sigma point(왼쪽)와 가중치(오른쪽) 관찰
- α 가 크면 점이 바깥으로 퍼지고 중심 가중치 증가, β 는 중심점의 공분산 가중치 Wc0 만 바꿈
- **조건**: n = 2, 평균 (0, 0), 공분산 [[4, 2], [2, 4]], 녹색 타원은 1, 2 σ, 점 크기는 |Wm|

```python
from ipywidgets import interact, FloatSlider

def plot_merwe(alpha, beta, kappa):
    x, P = np.array([0., 0.]), np.array([[4., 2.], [2., 4.]])
    points = MerweScaledSigmaPoints(2, alpha, beta, kappa)
    s, w = points.sigma_points(x, P), np.abs(points.Wm)
    plt.subplot(121)
    plot_covariance_ellipse(x, P, std=[1, 2], facecolor='g', alpha=0.2)
    plt.scatter(s[:, 0], s[:, 1], s=w / w.min() * 100, zorder=3)
    plt.subplot(122)
    plt.bar(np.arange(5) - .2, points.Wm, .4, label='Wm')
    plt.bar(np.arange(5) + .2, points.Wc, .4, label='Wc')
    plt.legend()

interact(plot_merwe,
         alpha=FloatSlider(value=.3, min=.1, max=1., step=.05),
         beta=FloatSlider(value=2., min=0., max=4., step=.5),
         kappa=FloatSlider(value=1., min=0., max=3., step=.5));
```



Using the UKF

- **목표**: 이미 아는 2 차원 등속 추적 문제를 선형 KF 와 UKF 로 풀고 같은 점과 다른 점 비교
- **설계**: x, F, H, R, Q 지정, 선형 문제에서 UKF 도 선형 KF 와 같은 최적 결과
- **센서**: 위치만 측정, x, y 모두 오차 σ = 0.3 m, process noise 는 discrete white noise 모델

$$\mathbf{x} = \begin{bmatrix} x & \dot{x} & y & \dot{y} \end{bmatrix}^\mathsf{T} \qquad \mathbf{F} = \begin{bmatrix} 1 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & \Delta t \\ 0 & 0 & 0 & 1 \end{bmatrix} \qquad \mathbf{H} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

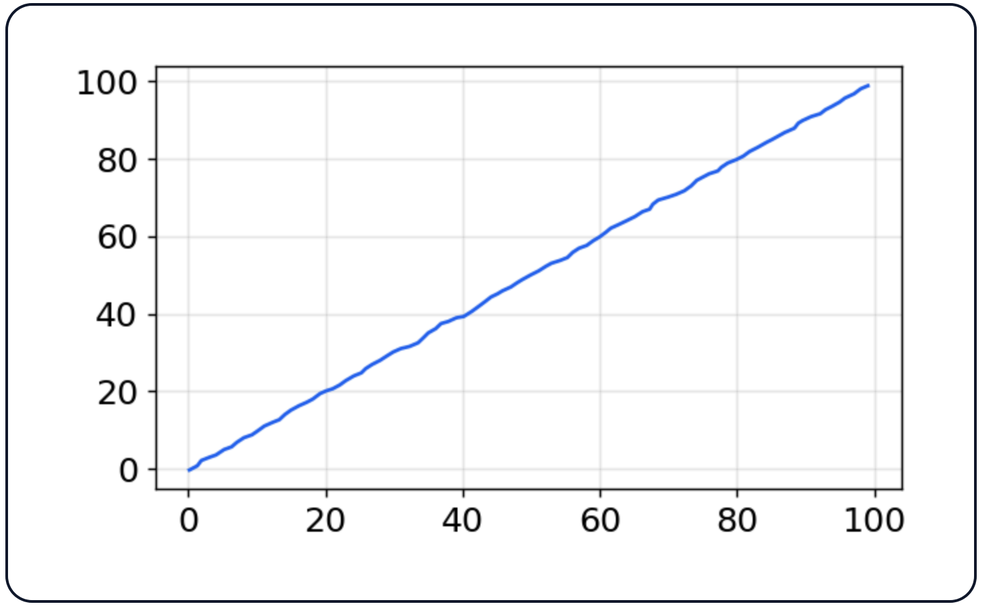
$$\mathbf{R} = \begin{bmatrix} 0.3^2 & 0 \\ 0 & 0.3^2 \end{bmatrix} \qquad \mathbf{Q} = \begin{bmatrix} \frac{1}{4}\Delta t^4 & \frac{1}{2}\Delta t^3 \\ \frac{1}{2}\Delta t^3 & \Delta t^2 \end{bmatrix} \sigma^2 \qquad x_k = x_{k-1} + \dot{x}_{k-1}\Delta t$$

> **차이**: UKF 는 행렬 F, H 대신 상태 전이 함수 f(x, dt) 와 측정 함수 h(x) 를 받음

Linear Kalman Filter

- x, y 가 매 초 1 m 씩 증가하는 대각선 이동을 위치 센서로 측정하고 선형 KF 로 batch 처리
- 선형 문제의 기준 해, 다음 슬라이드의 UKF 결과와 비교하는 데 사용
- **조건**: σ = 0.3 m, dt = 1 s, Q 분산 0.02, 측정 100 개, seed 1234

```python
from filterpy.kalman import KalmanFilter
from filterpy.common import Q_discrete_white_noise
std_x, std_y = .3, .3
dt = 1.0
np.random.seed(1234)
kf = KalmanFilter(4, 2)
kf.x = np.array([0., 0., 0., 0.])
kf.R = np.diag([std_x**2, std_y**2])
kf.F = np.array([[1, dt, 0, 0], [0, 1, 0, 0],
                 [0, 0, 1, dt], [0, 0, 0, 1]])
kf.H = np.array([[1, 0, 0, 0], [0, 0, 1, 0]])
kf.Q[0:2, 0:2] = Q_discrete_white_noise(2, dt=1, var=0.02)
kf.Q[2:4, 2:4] = Q_discrete_white_noise(2, dt=1, var=0.02)
zs = [np.array([i + randn()*std_x,
                i + randn()*std_y]) for i in range(100)]
xs, _, _, _ = kf.batch_filter(zs)
plt.plot(xs[:, 0], xs[:, 2]);
```



Unscented Kalman Filter

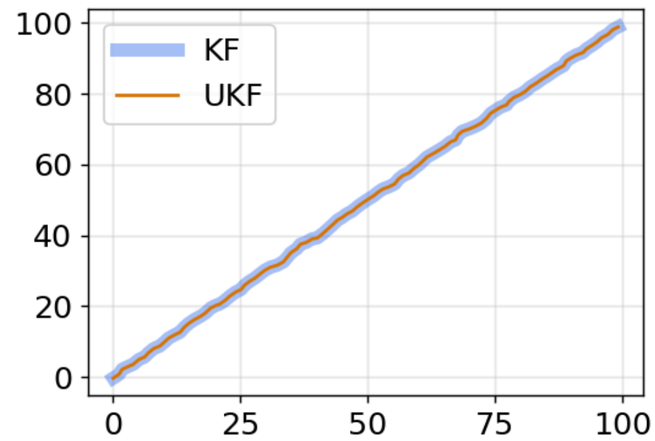
- 같은 측정을 f_cv(), h_cv() 함수와 MerweScaledSigmaPoints 로 만든 UKF 로 처리
- 두 궤적이 겹치고 KF 와의 차이 표준편차가 0.013 m, 선형 문제에서 사실상 같은 해
- **조건**: n = 4, α 0.1, β 2, κ 1, R = 0.09 I, Q 분산 0.02, f_cv() 는 F 행렬 곱, h_cv() 는 x[[0, 2]]

```
sigmas = MerweScaledSigmaPoints(4, alpha=.1, beta=2., kappa=1.)
ukf = UKF(dim_x=4, dim_z=2, fx=f_cv, hx=h_cv, dt=dt, points=sigmas)
ukf.x = np.array([0., 0., 0., 0.])
ukf.R = np.diag([0.09, 0.09])
ukf.Q[0:2, 0:2] = Q_discrete_white_noise(2, dt=1, var=0.02)
ukf.Q[2:4, 2:4] = Q_discrete_white_noise(2, dt=1, var=0.02)

uxs = []
for z in zs:
    ukf.predict()
    ukf.update(z)
    uxs.append(ukf.x.copy())
uxs = np.array(uxs)

plt.plot(xs[:, 0], xs[:, 2], lw=6, alpha=.4, label='KF')
plt.plot(uxs[:, 0], uxs[:, 2], label='UKF'); plt.legend()
print('UKF standard deviation {:.3f} meters'.format(np.std(uxs - xs)))
```

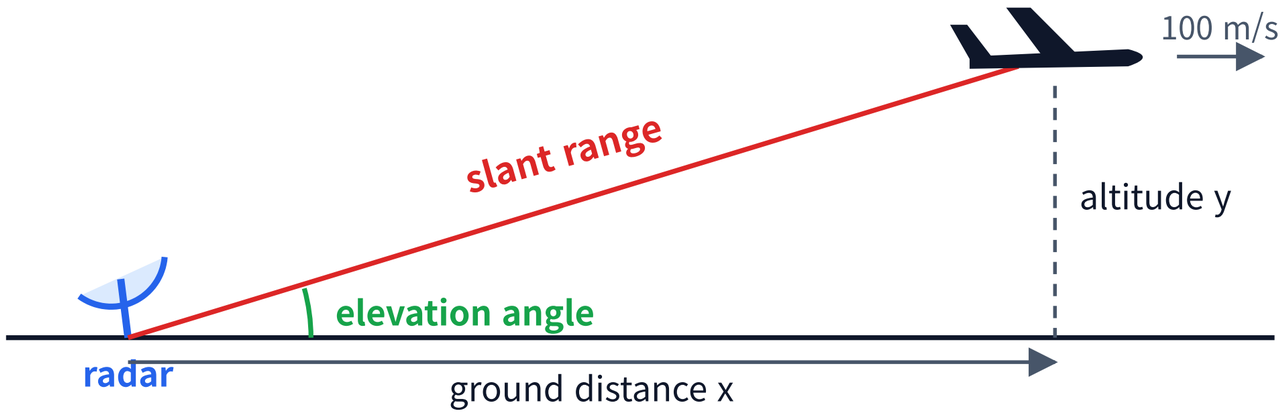
```
UKF standard deviation 0.013 meters
```



Tracking an Airplane

- **레이더**: 전파를 쏘고 반사파가 돌아오는 시간으로 slant range, 안테나 이득으로 각도 계산
- **2 차원**: 지상 거리와 고도만 추적, 각 차원이 독립이므로 일반성 유지
- **측정**: slant range 와 지면 기준 elevation angle, 모두 비선형

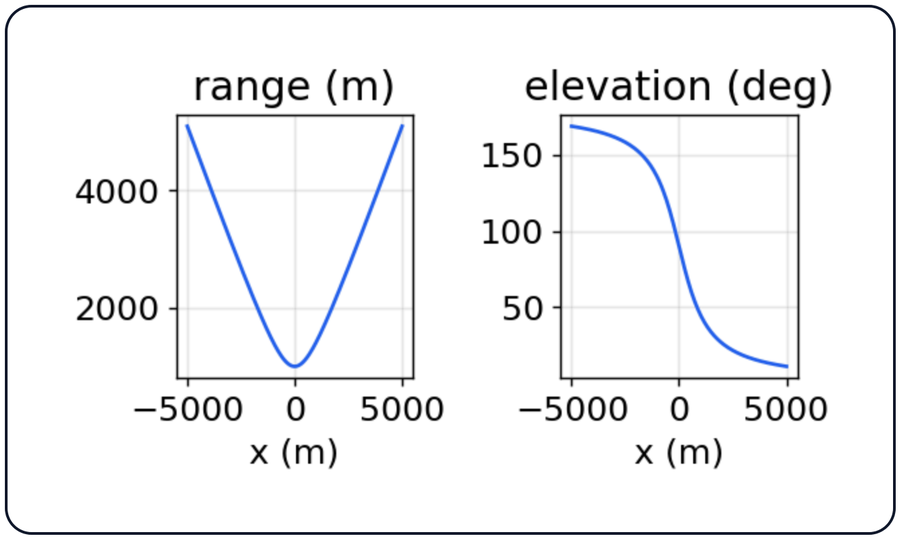
$$\mathbf{x} = \begin{bmatrix} x \\ \dot{x} \\ y \end{bmatrix} = \begin{bmatrix} \text{distance} \\ \text{velocity} \\ \text{altitude} \end{bmatrix} \qquad \bar{\mathbf{x}} = \begin{bmatrix} 1 & \Delta t & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \mathbf{x}$$



Measurement Function

- f_radar() 는 일정 고도 등속 비행의 선형 전이, h_radar() 는 상태를 거리와 고도각으로 변환
- 고도 1000 m 에서 x 를 바꾸며 h_radar() 출력을 그리면 거리와 각도 모두 x 에 대해 비선형
- 각도는 모듈러 값, 359 도와 1 도의 차이는 2 도이므로 지금은 각이 0 근처를 지나지 않게 배치
- **조건**: 레이더 (0, 0), 고도 1000 m, x = -5 ~ 5 km

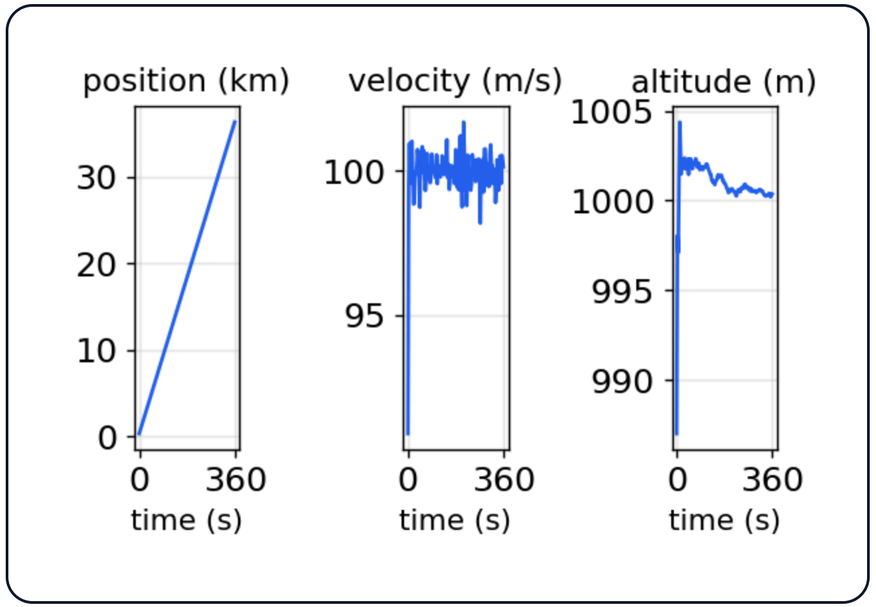
```python
def f_radar(x, dt):
    F = np.array([[1, dt, 0], [0, 1, 0], [0, 0, 1]], dtype=float)
    return np.dot(F, x)
def h_radar(x):
    dx = x[0] - h_radar.radar_pos[0]
    dy = x[2] - h_radar.radar_pos[1]
    slant_range = math.sqrt(dx**2 + dy**2)
    elevation_angle = math.atan2(dy, dx)
    return [slant_range, elevation_angle]
h_radar.radar_pos = (0, 0)
xs = np.linspace(-5000, 5000, 200)
zs = np.array([h_radar([x, 100., 1000.]) for x in xs])
plt.subplot(121); plt.plot(xs, zs[:, 0])
plt.title('range (m)'); plt.xlabel('x (m)')
plt.subplot(122); plt.plot(xs, np.degrees(zs[:, 1]))
plt.title('elevation (deg)'); plt.xlabel('x (m)');
```



Radar Tracking

- RadarStation 은 거리와 고도각에 잡음을 더해 보고, ACSim 은 속도에 작은 잡음이 있는 등속 비행
- 레이더 바로 위 고도 1000 m 에서 100 m/s 로 비행, 위치, 속도, 고도 추정이 안정적으로 수렴
- **조건**: 측정 주기 3 s, 거리 σ 5 m, 각도 σ 0.5 도, 초기 x = (0, 90, 1100), seed 200

```python
dt = 3. # 3 seconds between readings
range_std = 5 # meters
elevation_angle_std = math.radians(0.5)
points = MerweScaledSigmaPoints(n=3, alpha=.1, beta=2., kappa=0.)
kf = UKF(3, 2, dt, fx=f_radar, hx=h_radar, points=points)
kf.Q[0:2, 0:2] = Q_discrete_white_noise(2, dt=dt, var=0.1)
kf.Q[2,2] = 0.1
kf.R = np.diag([range_std**2, elevation_angle_std**2])
kf.x = np.array([0., 90., 1100.])
kf.P = np.diag([300**2, 30**2, 150**2])
np.random.seed(200)
radar = RadarStation((0, 0), range_std, elevation_angle_std)
ac, time, xs = ACSim(ac_pos, (100, 0), 0.02), np.arange(0, 360 + dt, dt), []
for _ in time:
    r = radar.noisy_reading(ac.update(dt))
    kf.predict()
    kf.update([r[0], r[1]])
    xs.append(kf.x)
plots.plot_radar(xs, time)
```

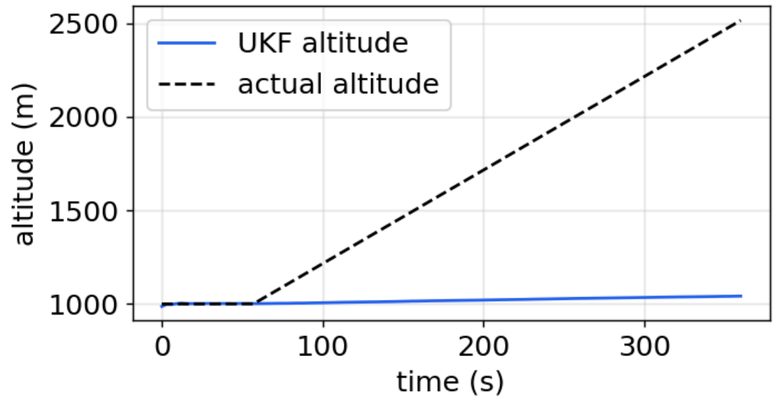


Tracking Maneuevering Aircraft

- 같은 필터로 1 분 뒤부터 분당 300 m 로 상승하는 항공기를 추적, 실선(UKF 고도)이 점선(실제)을 못 따라감
- 상태에 상승률이 없어 고도가 일정하다고 믿는 모델, 설계 수정이 필요
- **조건**: t ≥ 60 s 에서 상승률 5 m/s, 측정 주기 3 s, 360 s 동안 추적

```python
kf.x = np.array([0., 90., 1100.])
kf.P = np.diag([300**2, 30**2, 150**2])
ac = ACSim(ac_pos, (100, 0), 0.02)
np.random.seed(200)
time = np.arange(0, 360 + dt, dt)
xs, ys = [], []
for t in time:
    if t >= 60:
        ac.vel[1] = 300/60 # 300 meters/minute climb
    r = radar.noisy_reading(ac.update(dt))
    ys.append(ac.pos[1])
    kf.predict()
    kf.update([r[0], r[1]])
    xs.append(kf.x)
plots.plot_altitude(xs, time, ys)
print('Actual altitude: {:.1f}'.format(ac.pos[1]))
print('UKF altitude   : {:.1f}'.format(xs[-1][2]))
```

```
Actual altitude: 2515.6
UKF altitude   : 1042.1
```



Add Climb Rate to the State

- **수정**: 상태에 상승률을 추가, 상태 전이는 여전히 선형
- **그대로**: 측정 함수는 그대로, 상태 차원이 바뀌므로 Q 만 4 x 4 블록으로 변경

$$\mathbf{x} = \begin{bmatrix} x \\ \dot{x} \\ y \\ \dot{y} \end{bmatrix} = \begin{bmatrix} \text{distance} \\ \text{velocity} \\ \text{altitude} \\ \text{climb rate} \end{bmatrix} \qquad \bar{\mathbf{x}} = \begin{bmatrix} 1 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & \Delta t \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ \dot{x} \\ y \\ \dot{y} \end{bmatrix} \qquad \mathbf{Q} = \begin{bmatrix} \mathbf{Q}_x & 0 \\ 0 & \mathbf{Q}_y \end{bmatrix}$$

> **핵심**: 필터가 거동을 따라가지 못하면 그 거동을 설명하는 상태 변수가 빠졌는지 먼저 확인

Constant Velocity UKF

- 상승률을 포함한 4 상태 전이 f_cv_radar() 와 필터 생성 함수 cv_UKF(), R 은 표준편차 행렬의 제곱
- 결과는 생성된 필터의 Q, 지상 방향과 고도 방향의 2 x 2 블록 두 개가 대각선에 위치
- **조건**: dt 3 s, n = 4, α 0.1, β 2, κ -1, Q 분산 0.1

```python
def f_cv_radar(x, dt):
    """ state transition function for a constant velocity aircraft"""
    F = np.array([[1, dt, 0, 0], [0, 1, 0, 0],
                  [0, 0, 1, dt], [0, 0, 0, 1]], dtype=float)
    return np.dot(F, x)
dt = 3.
def cv_UKF(fx, hx, R_std):
    points = MerweScaledSigmaPoints(n=4, alpha=.1, beta=2., kappa=-1.)
    kf = UKF(4, len(R_std), dt, fx=fx, hx=hx, points=points)
    kf.Q[0:2, 0:2] = Q_discrete_white_noise(2, dt=dt, var=0.1)
    kf.Q[2:4, 2:4] = Q_discrete_white_noise(2, dt=dt, var=0.1)
    kf.R = np.diag(R_std)
    kf.R = np.dot(kf.R, kf.R) # square to get variance
    kf.x = np.array([0., 90., 1100., 0.])
    kf.P = np.diag([300**2, 3**2, 150**2, 3**2])
    return kf
kf_cv = cv_UKF(f_cv_radar, h_radar, R_std=[range_std, elevation_angle_std])
print(kf_cv.Q)
```

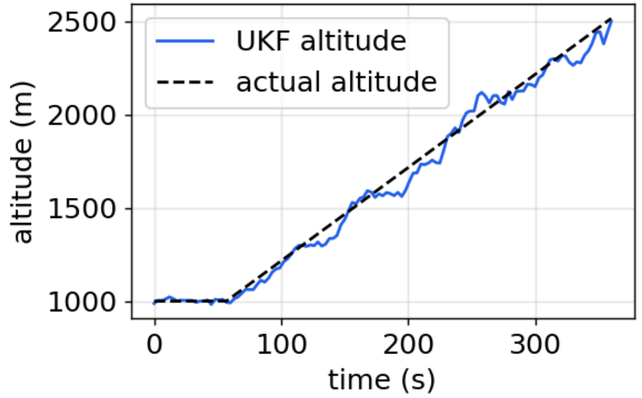
```
[[2.025 1.35  0.    0.   ]
 [1.35  0.9   0.    0.   ]
 [0.    0.    2.025 1.35 ]
 [0.    0.    1.35  0.9  ]]
```

Tracking the Climb

- 상승률을 포함한 4 상태 cv_UKF 로 같은 상승 비행을 다시 추적
- 고도 추정에 잡음이 늘었지만 최종 고도가 실제 2515 m 에 가깝게 추적
- **조건**: t ≥ 60 s 에서 상승률 5 m/s, P = $\mathrm{diag}(300^2, 3^2, 150^2, 3^2)$, seed 200

```python
np.random.seed(200)
ac = ACSim(ac_pos, (100, 0), 0.02)
kf_cv = cv_UKF(f_cv_radar, h_radar, R_std=[range_std, elevation_angle_std])
time = np.arange(0, 360 + dt, dt)
xs, ys = [], []
for t in time:
    if t >= 60:
        ac.vel[1] = 300/60 # 300 meters/minute climb
    r = radar.noisy_reading(ac.update(dt))
    ys.append(ac.pos[1])
    kf_cv.predict()
    kf_cv.update([r[0], r[1]])
    xs.append(kf_cv.x)
plots.plot_altitude(xs, time, ys)
print('Actual altitude: {:.1f}'.format(ac.pos[1]))
print('UKF altitude   : {:.1f}'.format(xs[-1][2]))
```

```
Actual altitude: 2515.6
UKF altitude   : 2500.1
```

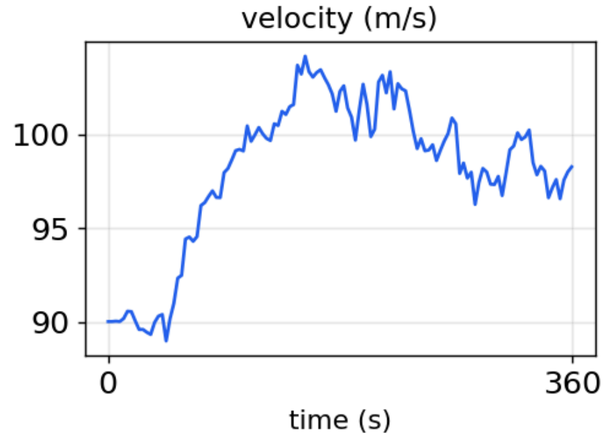


Sensor Fusion

- Doppler 속도 센서와의 sensor fusion 효과를 보기 위해 먼저 레이더만 쓰는 필터의 속도 정확도 측정
- 거리 오차를 500 m 로 키운 레이더만으로 추정한 속도, 수렴 구간 10 개를 뺀 표준편차 계산
- **조건**: 거리 σ 500 m, 각도 σ = math.degrees(0.5), 측정 주기 3 s, 360 s

```python
range_std = 500.
elevation_angle_std = math.degrees(0.5)
np.random.seed(200)
radar = RadarStation((0, 0), range_std, elevation_angle_std)
ac = ACSim(ac_pos, (100, 0), 0.02)
kf_sf = cv_UKF(f_cv_radar, h_radar, R_std=[range_std, elevation_angle_std])
time = np.arange(0, 360 + dt, dt)
xs = []
for _ in time:
    ac.update(dt)
    r = radar.noisy_reading(ac.pos)
    kf_sf.predict()
    kf_sf.update([r[0], r[1]])
    xs.append(kf_sf.x)
xs = np.asarray(xs)
plots.plot_radar(xs, time, plot_x=False, plot_vel=True, plot_alt=False)
print('Velocity std {:.1f} m/s'.format(np.std(xs[10:, 1])))
```

```
Velocity std 3.4 m/s
```

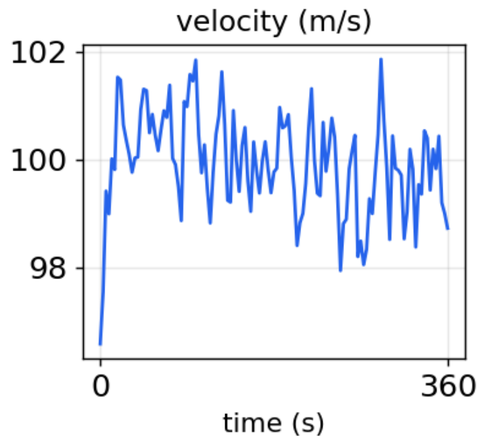


Doppler Velocity

- Doppler 센서가 x, y 속도를 2 m/s 로 측정, h_vel() 은 거리와 각도에 상태의 두 속도를 더해 4 개 값 반환
- 레이더만 쓸 때보다 속도 추정의 표준편차가 크게 감소, 서로 다른 정보를 주는 센서의 결합 효과
- **조건**: 속도 σ 2 m/s, 거리 σ 500 m, 앞 슬라이드와 같은 레이더, 항공기, seed 200

```python
def h_vel(x):
    dx = x[0] - h_vel.radar_pos[0]
    dz = x[2] - h_vel.radar_pos[1]
    slant_range = math.sqrt(dx**2 + dz**2)
    elevation_angle = math.atan2(dz, dx)
    return slant_range, elevation_angle, x[1], x[3]
h_vel.radar_pos = (0, 0)
vel_std = 2.
kf_sf2 = cv_UKF(f_cv_radar, h_vel, R_std=[range_std, elevation_angle_std, vel_std, vel_std])
xs = []
for t in time:
    r = radar.noisy_reading(ac.update(dt))
    vx = ac.vel[0] + randn()*vel_std   # simulated doppler
    vz = ac.vel[1] + randn()*vel_std
    kf_sf2.predict()
    kf_sf2.update([r[0], r[1], vx, vz])
    xs.append(kf_sf2.x)
plots.plot_radar(xs, time, plot_x=False, plot_vel=True, plot_alt=False)
print('Velocity std {:.1f} m/s'.format(np.std(np.asarray(xs)[10:, 1])))
```

```
Velocity std 0.9 m/s
```



Complementary Sensors

GPS

- 초당 1 회 정도의 비교적 정확한 위치
- 속도 추정은 부정확
- 느린 갱신

Inertial system

- 50 Hz 의 매우 정확한 속도
- 위치 추정은 시간이 지나면 크게 틀어짐
- 빠른 갱신

- **Complementary filter**: 빠른 관성 속도를 GPS 갱신 사이에 적분해 높은 주기의 정확한 위치와 속도 생성
- **직교하는 강점**: 한 센서의 약점이 다른 센서의 강점, 두 정보가 서로 겹치지 않음
- **자율주행**: GNSS, IMU, 휠 오도메트리처럼 서로의 약점을 보완하는 센서 조합이 위치인식의 기본 구조

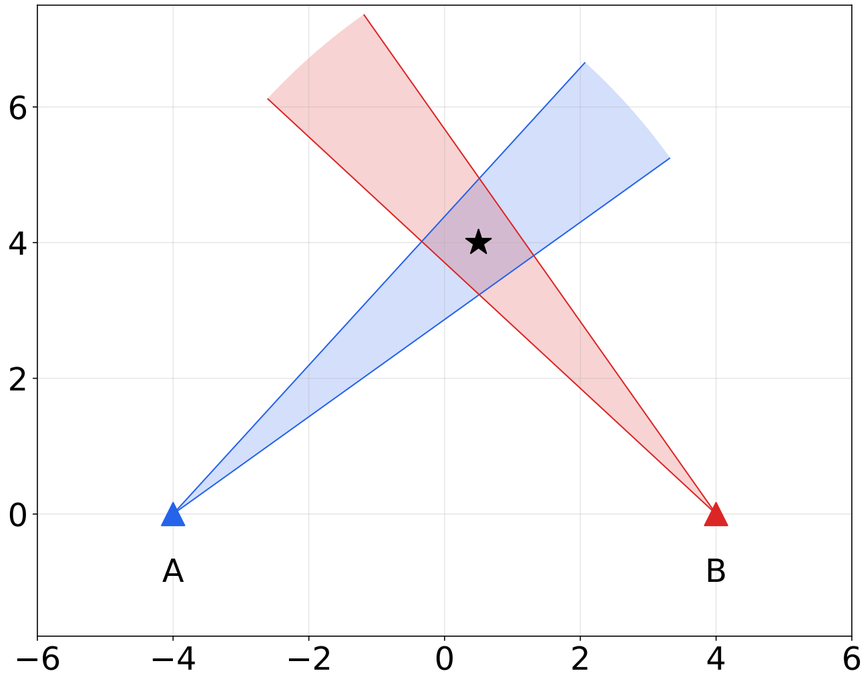
> **핵심**: 강점과 약점이 서로 직교하는 센서를 결합하면 어느 한 센서보다 좋은 추정

Multiple Position Sensors

- **VOR**: GPS 이전 항공기 항법, 지상 국 방향(radial)만 알려 주는 bearing 센서
- **수동 방식**: 두 국의 radial 교차점을 지도에서 찾음, 정확도 낮음
- **Kalman filter**: 두 bearing 측정으로 훨씬 정확한 위치 추정
- **그림**: 부채꼴 폭은 센서 잡음 3 σ, 항공기는 두 영역의 교차 부분에 존재
- **모델**: 등속 모델, 행렬 곱 대신 위치를 직접 갱신

$$\text{bearing} = \tan^{-1}\frac{y_t - y_s}{x_t - x_s}$$

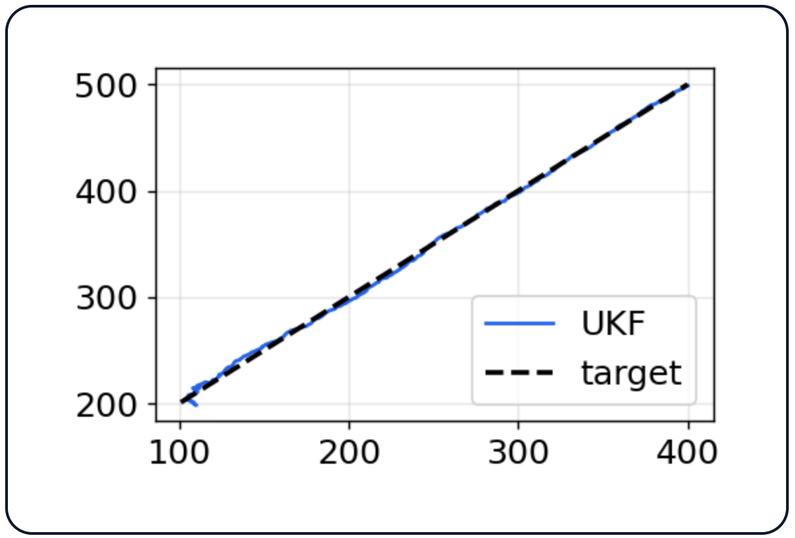
$$x \leftarrow x + \dot{x}\Delta t, \quad y \leftarrow y + \dot{y}\Delta t$$



Two Bearing Sensors

- A(-400, 0), B(400, 0) 두 bearing 센서로 (100, 200) 에서 대각선으로 움직이는 목표물 추적
- 시작 부분은 오차가 크지만 곧 수렴해 점선(실제 경로)을 잘 따라감
- plot_straight_line_target() 은 목표물을 매 단계 (1, 1) m 이동, 두 bearing 에 잡음 추가
- **조건**: bearing σ 0.5 도, Q 분산 1, dt 0.1 s, P = 1000 I, 300 단계, seed 123

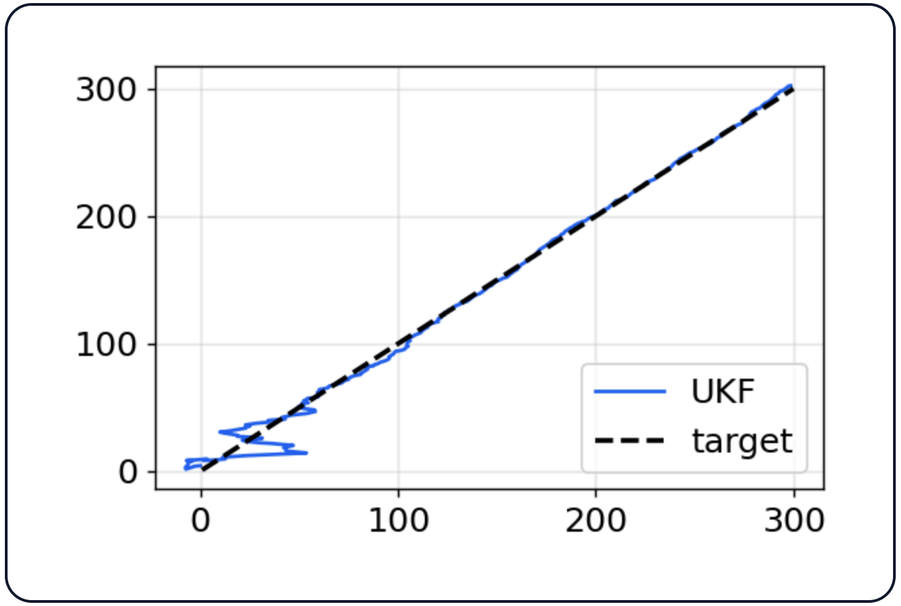
```python
def moving_target_filter(pos, std_noise, Q, dt=0.1, kappa=0.0):
    points = MerweScaledSigmaPoints(n=4, alpha=.1, beta=2., kappa=kappa)
    f = UKF(dim_x=4, dim_z=2, dt=dt, hx=hx_VOR, fx=fx_VOR, points=points)
    f.x = np.array([pos[0], 1., pos[1], 1.])
    q = Q_discrete_white_noise(2, dt, Q)
    f.Q[0:2, 0:2] = q
    f.Q[2:4, 2:4] = q
    f.R *= std_noise**2
    f.P *= 1000
    return f
np.random.seed(123)
target_pos = [100, 200]
std_noise = math.radians(0.5)
f = moving_target_filter(target_pos, std_noise, Q=1.0)
plot_straight_line_target(f, std_noise)
plt.legend(loc=4);
```



Angle Nonlinearity

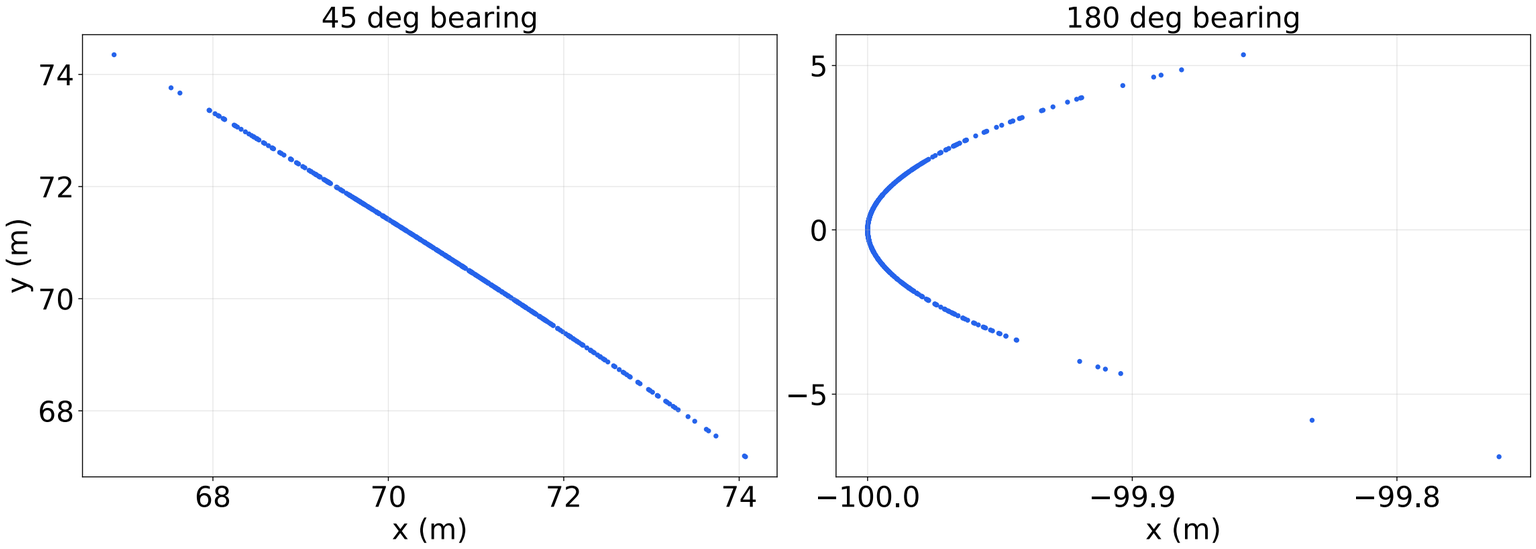
- 목표물을 두 센서 사이 (0, 0) 에서 출발, B 에서 본 각이 π 근처라 residual 이 0 대신 거의 2π 가 되는 문제
- 시작 부분 추정이 크게 흔들림, residual 계산 함수를 따로 지정해야 해결
- **조건**: 목표물 (0, 0) 출발, seed 0, 나머지 조건 동일

```python
def plot_straight_line_target(f, std_noise):
    xs, txs = [], []
    for i in range(300):
        target_pos[0] += 1 + randn()*0.0001
        target_pos[1] += 1 + randn()*0.0001
        txs.append((target_pos[0], target_pos[1]))
        z = measurement(sa_pos, sb_pos, target_pos)
        z[0] += randn() * std_noise
        z[1] += randn() * std_noise
        f.predict()
        f.update(z)
        xs.append(f.x)
    xs, txs = np.asarray(xs), np.asarray(txs)
    plt.plot(xs[:, 0], xs[:, 2], label='UKF')
    plt.plot(txs[:, 0], txs[:, 1], ls='--', lw=2, c='k', label='target')
np.random.seed(0)
target_pos = [0, 0]
f = moving_target_filter(target_pos, std_noise, Q=1.0)
plot_straight_line_target(f, std_noise)
plt.legend(loc=4);
```



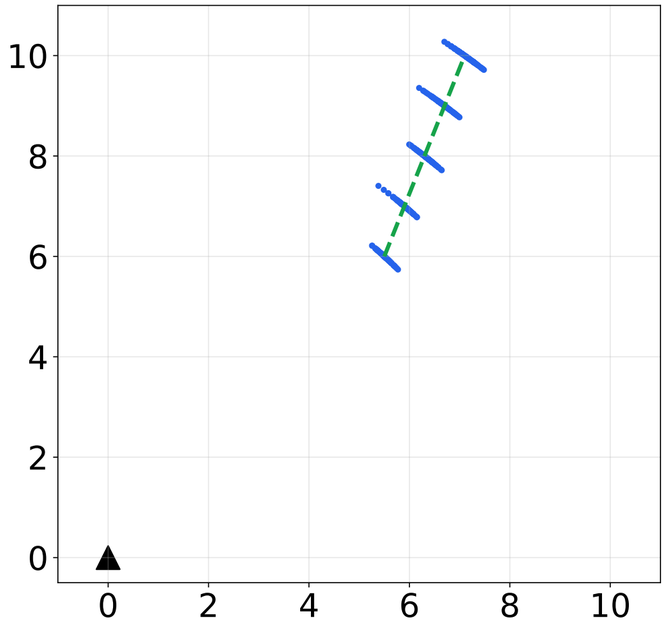
Effects of Sensor Error and Geometry

- **기하**: 센서와 목표물의 배치가 만드는 물리적 한계, 필터 설계로 극복하기 어려움
- **평행한 radial**: 작은 각도 오차가 매우 큰 거리 오차로
- **비선형**: x 축과 y 축의 오차 비율이 실제 bearing 에 따라 달라짐
- **그림**: 거리 100 m 의 1 도 σ bearing 오차, 45 도와 180 도



One Sensor

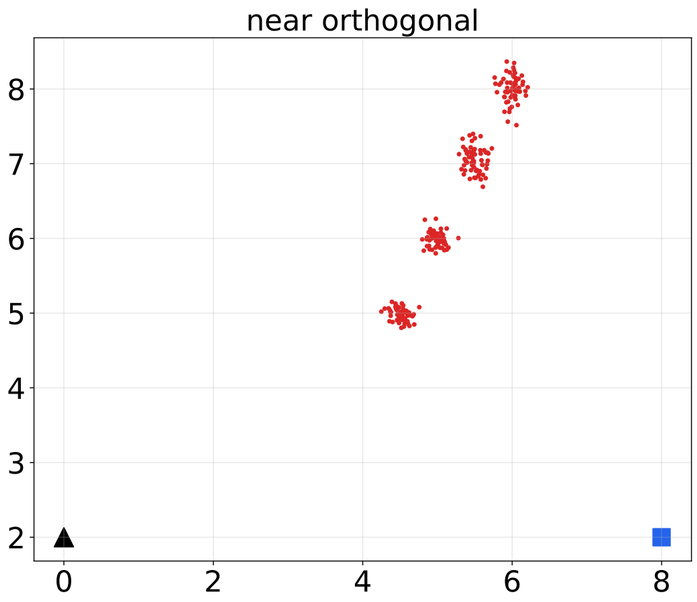
- **질문**: 작은 각도 오차가 큰 위치 오차를 만드는데 UKF 가 잘 동작한 이유
- **움직이는 목표**: 측정 하나는 오차가 크지만 연속 측정은 오른쪽 위로의 뚜렷한 추세
- **Kalman gain**: 측정 함수로 오차 분포를 반영, 45 도 선 방향 오차는 낮추고 수직 방향은 신뢰
- **측정 수**: 그림은 위치마다 측정 100 개, 필터는 갱신마다 1 개만 받으므로 녹색 점선만큼 맞추지는 못함
- **거리 정보 없음**: 1000 km 밖에 작은 P 로 초기화하면 1 도가 17.5 km, 수렴 불가

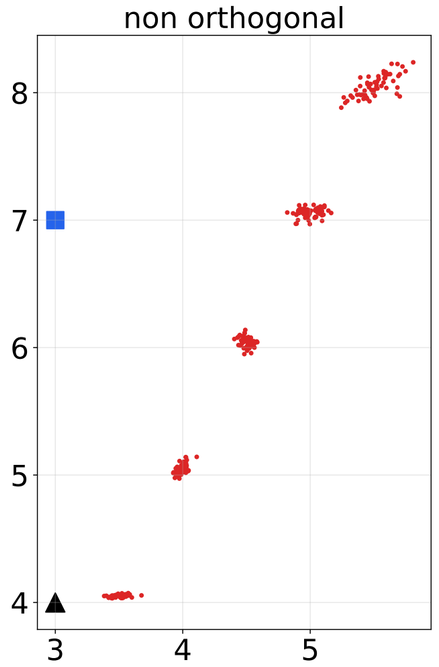


> **핵심**: 필터는 움직임 모델과 측정 오차의 방향을 함께 이용, 단일 측정보다 훨씬 정확

Two Sensors

- **두 번째 센서**: 두 bearing 의 교차로 거리 정보를 얻음, 배치에 따라 오차 모양이 달라짐
- **그림 표기**: 두 센서(삼각형, 사각형), 두 잡음 bearing 의 교차점을 빨간 점으로
- **직교 배치**: x 모양 교차, 센서 B 의 y 좌표에 가까워질수록 길쭉한 타원
- **비직교 배치**: 한 센서 바로 옆에서 출발해 다른 센서를 지나감, 교차가 비직교라 오차가 넓게 퍼짐



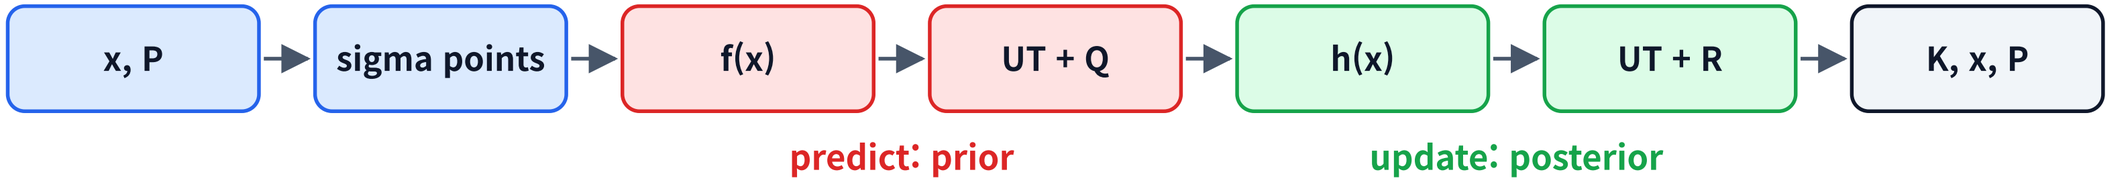


Implementation of the UKF

- **구현**: 식을 코드로 옮기는 연습, weights, sigma points, predict, update 순서
- **저장**: sigma point 를 행으로 저장, i 번째 점을 sigmas[i] 로 참조
- **크기**: 2n + 1 행, n 열, n = 3 이면 7 행 3 열

$$\text{weights} = \begin{bmatrix} w_0 & w_1 & \dots & w_{2n} \end{bmatrix}$$

$$\text{sigmas} = \begin{bmatrix} \mathcal{X}_{0,0} & \mathcal{X}_{0,1} & \dots & \mathcal{X}_{0,n-1} \\ \mathcal{X}_{1,0} & \mathcal{X}_{1,1} & \dots & \mathcal{X}_{1,n-1} \\ \vdots & \vdots & \ddots & \vdots \\ \mathcal{X}_{2n,0} & \mathcal{X}_{2n,1} & \dots & \mathcal{X}_{2n,n-1} \end{bmatrix}$$



Weights

- Van der Merwe 가중치 식을 NumPy 로 구현, lambda 는 예약어라 lambda_ 로 표기
- 직접 계산한 Wm, Wc 가 MerweScaledSigmaPoints 의 값과 일치하는지 확인
- 작은 α 에서는 중심 가중치가 큰 음수, 합은 1 이어도 개별 값은 1 을 넘을 수 있음
- **조건**: n = 2, α 0.1, β 2, κ 1

```python
def merwe_weights(n, alpha, beta, kappa):
    lambda_ = alpha**2 * (n + kappa) - n
    Wc = np.full(2*n + 1,  1. / (2*(n + lambda_)))
    Wm = np.full(2*n + 1,  1. / (2*(n + lambda_)))
    Wc[0] = lambda_ / (n + lambda_) + (1. - alpha**2 + beta)
    Wm[0] = lambda_ / (n + lambda_)
    return Wm, Wc

Wm, Wc = merwe_weights(2, .1, 2., 1.)
points = MerweScaledSigmaPoints(n=2, alpha=.1, beta=2., kappa=1.)
print('Wm', Wm, np.allclose(Wm, points.Wm))
print('Wc', Wc, np.allclose(Wc, points.Wc))
print('sum Wm', Wm.sum())
```

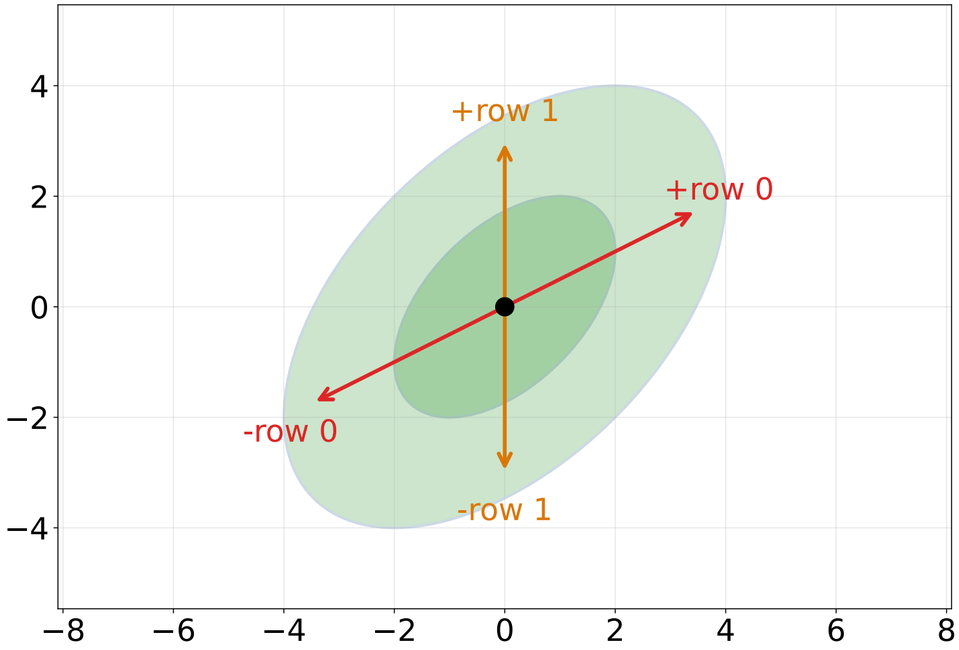
```
Wm [-65.6667  16.6667  16.6667  16.6667
16.6667] True
Wc [-62.6767  16.6667  16.6667  16.6667
16.6667] True
sum Wm 1.000000000000007
```

Matrix Square Root

$$\mathcal{X}_0 = \mu \qquad \mathcal{X}_i = \mu \pm \left[\sqrt{(n+\lambda)\Sigma}\right]_i \qquad \Sigma = \mathbf{S}\mathbf{S}^\mathsf{T}$$

$$\mathbf{A} = \mathbf{L}\mathbf{L}^\mathsf{T} = \mathbf{U}^\mathsf{T}\mathbf{U}$$

- **제곱근**: 유일한 정의 없음, SS = Σ 를 만족하는 S 가 한 가지 정의
- **선택**: S 와 그 전치의 곱이 Σ 가 되는 S, 수치적으로 계산이 쉬움
- **Cholesky**: 대칭 양의 정부호 행렬을 삼각 행렬과 그 전치로 분해
- **scipy**: scipy.linalg.cholesky() 는 기본으로 상삼각 행렬 U 반환
- **행 단위**: U 의 행을 sigma point 에 사용(그림의 화살표), 하삼각 결과를 쓰는 구현은 열 단위



Sigma Points

- Cholesky 로 $(n+\lambda)\mathbf{P}$ 의 제곱근 U 를 구하고 평균에 U 의 각 행을 더하고 빼서 sigma point 생성
- 상삼각 U 에 대해 $\mathbf{U}^{\mathsf{T}}$ U 가 원래 행렬을 복원, 직접 만든 점이 FilterPy 결과와 일치
- **조건**: P = [[1, 0.1], [0.1, 1]], 평균 (0, 0), α 0.1, κ 1

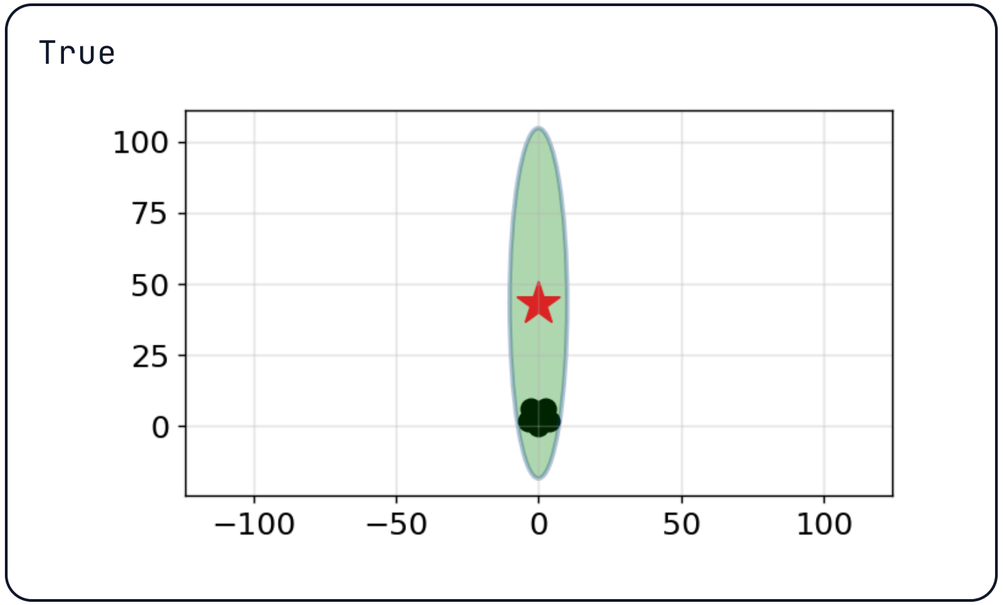
```python
import scipy.linalg
a = np.array([[2., .1], [.1, 3]])
s = scipy.linalg.cholesky(a)
print("cholesky:"); print(s)
print(np.allclose(np.dot(s.T, s), a))
def sigma_points(X, P, alpha, kappa):
    n = len(X)
    lambda_ = alpha**2 * (n + kappa) - n
    sigmas = np.zeros((2*n+1, n))
    U = scipy.linalg.cholesky((n+lambda_)*P) # sqrt
    sigmas[0] = X
    for k in range(n):
        sigmas[k+1]   = X + U[k]
        sigmas[n+k+1] = X - U[k]
    return sigmas
P = np.array([[1., .1], [.1, 1]])
sigmas = sigma_points(np.array([0., 0.]), P, alpha=.1, kappa=1.)
points = MerweScaledSigmaPoints(n=2, alpha=.1, beta=2., kappa=1.)
print("sigmas:"); print(sigmas)
print(np.allclose(sigmas, points.sigma_points([0., 0.], P)))
```

```
cholesky:
[[1.4142 0.0707]
 [0.     1.7306]]
True
sigmas:
[[ 0.       0.    ]
 [ 0.1732   0.0173]
 [ 0.       0.1723]
 [-0.1732 -0.0173]
 [ 0.     -0.1723]]
True
```

Unscented Transform

- np.dot(Wm, sigmas) 로 가중 평균, np.outer(y, y) 로 yy^{T} 를 누적해 공분산, 직접 만든 함수로 비선형 변환
- 별(평균)과 타원(공분산)이 FilterPy 의 unscented_transform 결과와 일치
- **조건**: f(x, y) = (x + y, $0.1x^2 + y^2$), 평균 (0, 0), P = [[32, 15], [15, 40]], α 0.3, κ 0.1

```python
def my_unscented_transform(sigmas, Wm, Wc, Q):
    x = np.dot(Wm, sigmas)
    kmax, n = sigmas.shape
    P = np.zeros((n, n))
    for k in range(kmax):
        y = sigmas[k] - x
        P += Wc[k] * np.outer(y, y)
    P += Q
    return x, P
P = np.array([[32., 15], [15., 40.]])
sigmas = sigma_points(np.array([0., 0.]), P, alpha=.3, kappa=.1)
Wm, Wc = merwe_weights(2, .3, 2., .1)
sigmas_f = np.array([f_nonlinear_xy(*s) for s in sigmas])
x, Pf = my_unscented_transform(sigmas_f, Wm, Wc, np.zeros((2, 2)))
print(np.allclose(x, unscented_transform(sigmas_f, Wm, Wc)[0]))
plt.scatter(sigmas_f[:, 0], sigmas_f[:, 1], s=80, c='k')
plot_covariance_ellipse(x, Pf, facecolor='g', alpha=0.3)
plt.scatter(*x, marker='*', s=400, c='C3');
```



Predict Step

- 필터의 행렬과 벡터를 저장하는 클래스, predict() 는 sigma point 를 f 에 통과시키고 UT 로 prior 계산
- 등속 모델에서 1 초 예측, 위치가 속도만큼 이동하고 위치 분산이 커짐
- **조건**: x = (0, 1, 0, 1), P = I, Q = I, dt 1 s, α 0.1, β 2, κ 1

```python
class MyUKF:
    def __init__(self, dim_x, dim_z, dt, fx, hx, alpha, beta, kappa):
        self._dim_x, self._dim_z, self._dt = dim_x, dim_z, dt
        self.fx, self.hx = fx, hx
        self.Wm, self.Wc = merwe_weights(dim_x, alpha, beta, kappa)
        self._num_sigmas = 2*dim_x + 1
        self.x, self.P = np.zeros(dim_x), np.eye(dim_x)
        self.Q, self.R = np.eye(dim_x), np.eye(dim_z)
        self.sigmas_f = np.zeros((self._num_sigmas, dim_x))
        self.sigmas_h = np.zeros((self._num_sigmas, dim_z))
    def predict(self, sigma_points_fn):
        # calculate sigma points for given mean and covariance
        sigmas = sigma_points_fn(self.x, self.P)
        for i in range(self._num_sigmas):
            self.sigmas_f[i] = self.fx(sigmas[i], self._dt)
        self.xp, self.Pp = my_unscented_transform(self.sigmas_f, self.Wm, self.Wc, self.Q)
ukf = MyUKF(4, 2, 1., f_cv, h_cv, .1, 2., 1.)
ukf.x = np.array([0., 1., 0., 1.])
ukf.predict(lambda x, P: sigma_points(x, P, .1, 1.))
print('xp:', ukf.xp); print('Pp:'); print(ukf.Pp)
```

```
xp: [1. 1. 1. 1.]
Pp:
[[ 3.  1. -0. -0.]
 [ 1.  2.  0.  0.]
 [-0.  0.  3.  1.]
 [-0.  0.  1.  2.]]
```

Update Step

- update() 는 prior sigma point 를 h 로 측정 공간에 옮기고 UT, 교차 공분산 Pxz, gain K 계산
- 앞 슬라이드의 prior (1, 1, 1, 1) 에 측정 (1.2, 0.9) 를 반영, 위치가 측정 쪽으로 이동하고 분산 감소
- **조건**: prior 는 앞 슬라이드의 xp, Pp, R = I, 측정 z = (1.2, 0.9)

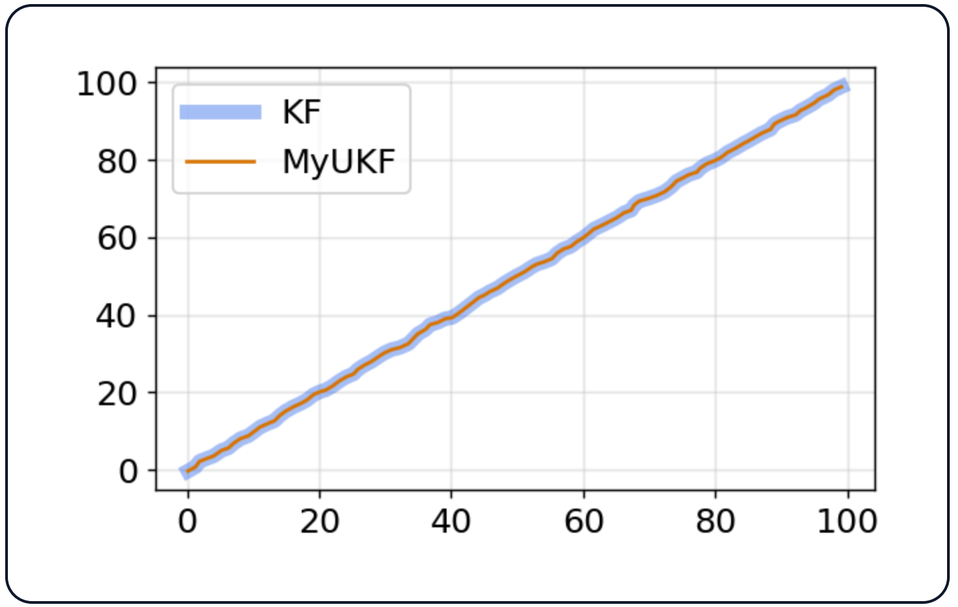
```python
from numpy.linalg import inv
def update(self, z):
    sigmas_f, sigmas_h = self.sigmas_f, self.sigmas_h
    # transform sigma points into measurement space
    for i in range(self._num_sigmas):
        sigmas_h[i] = self.hx(sigmas_f[i])
    # mean and covariance of prediction passed through UT
    zp, Pz = my_unscented_transform(sigmas_h, self.Wm, self.Wc, self.R)
    # compute cross variance of the state and the measurements
    Pxz = np.zeros((self._dim_x, self._dim_z))
    for i in range(self._num_sigmas):
        Pxz += self.Wc[i] * np.outer(sigmas_f[i] - self.xp, sigmas_h[i] - zp)
    K = np.dot(Pxz, inv(Pz)) # Kalman gain
    self.x = self.xp + np.dot(K, z - zp)
    self.P = self.Pp - np.dot(K, Pz).dot(K.T)
MyUKF.update = update
ukf.update(np.array([1.2, .9]))
print('x:', ukf.x); print('P diag:', ukf.P.diagonal())
```

```
x: [1.1333 1.0667 0.9333 0.9667]
P diag: [1.6667 1.6667 1.6667 1.6667]
```

Running the Filter

- 직접 구현한 MyUKF 로 10.7 의 대각선 이동 측정을 처리하고 선형 KF 결과와 비교
- 두 궤적이 겹침, 식을 그대로 옮긴 30 줄 남짓의 코드로 동작하는 UKF 완성
- **조건**: 같은 측정 zs, R = 0.09 I, Q 는 선형 KF 와 동일, α 0.1, β 2, κ 1

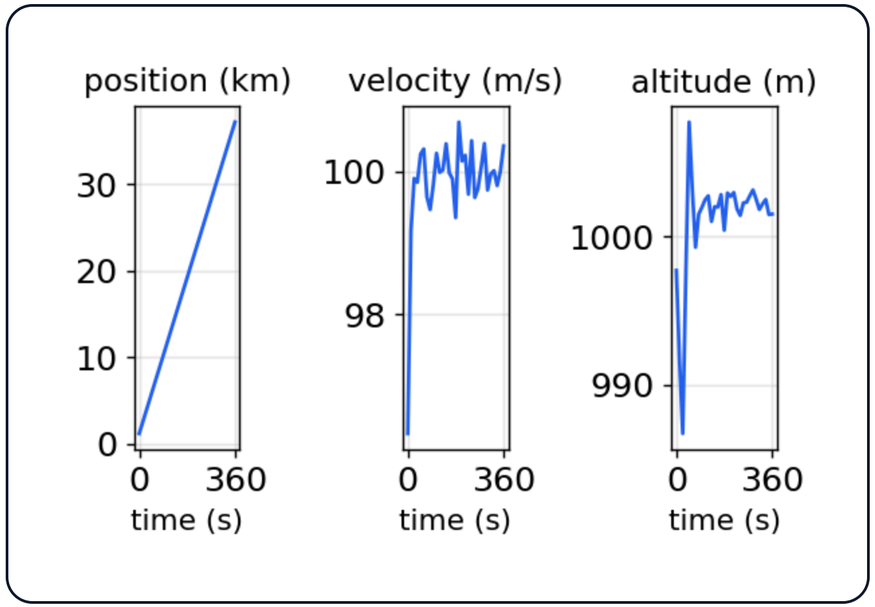
```
ukf = MyUKF(4, 2, 1., f_cv, h_cv, .1, 2., 1.)
ukf.R, ukf.Q, ukf.P = np.diag([.09, .09]), kf.Q, np.eye(4)
mxs = []
for z in zs:
    ukf.predict(lambda x, P: sigma_points(x, P, .1, 1.))
    ukf.update(z)
    mxs.append(ukf.x)
mxs = np.array(mxs)
plt.plot(xs[:, 0], xs[:, 2], lw=6, alpha=.4, label='KF')
plt.plot(mxs[:, 0], mxs[:, 2], label='MyUKF'); plt.legend();
```



Batch Processing

- 이미 모은 측정 배열을 batch_filter() 에 넣어 한 번에 처리, 모든 단계의 추정 xs 와 공분산 covs 반환
- 레이더 추적 문제를 12 초 주기 측정으로 batch 처리, 위치, 속도, 고도 추정
- **조건**: dt 12 s, 거리 σ 5 m, 각도 σ 0.5 도, 초기 x = (0, 90, 1100), seed 200

```python
dt = 12. # 12 seconds between readings
range_std = 5 # meters
bearing_std = math.radians(0.5)
points = MerweScaledSigmaPoints(n=3, alpha=.1, beta=2., kappa=0.)
kf = UKF(3, 2, dt, fx=f_radar, hx=h_radar, points=points)
kf.Q[0:2 ,0:2] = Q_discrete_white_noise(2, dt=dt, var=0.1)
kf.Q[2, 2] = 0.1
kf.R = np.diag([range_std**2, bearing_std**2])
kf.x = np.array([0., 90., 1100.])
kf.P = np.diag([300**2, 30**2, 150**2])
radar = RadarStation((0, 0), range_std, bearing_std)
ac = ACSim(ac_pos, (100, 0), 0.02)
np.random.seed(200)
t = np.arange(0, 360 + dt, dt)
zs = [radar.noisy_reading(ac.update(dt)) for _ in t]
xs, covs = kf.batch_filter(zs)
plots.plot_radar(xs, t)
```

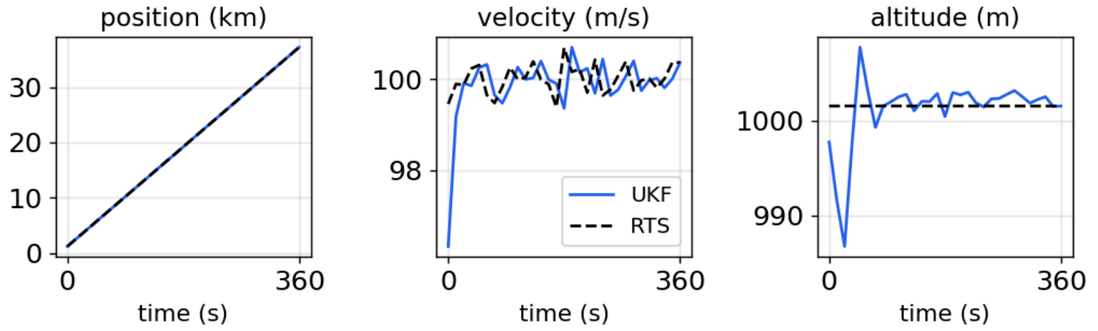


Smoothing the Results

- 차가 직진 중 왼쪽으로 꺾는 듯한 잡음 측정, 필터는 잡음인지 회전 시작인지 판단할 수 없음
- 사후 처리라면 이후 측정으로 판단 가능, batch 결과를 RTS smoother 로 뒤에서부터 보정
- 위치 개선은 작지만 속도는 개선되고 고도는 크게 개선, 사후 처리가 가능하면 항상 사용 권장
- **조건**: 앞 슬라이드의 batch 결과 xs, covs, 출력은 마지막 5 개 점의 위치 차이

```
1 Ms, P, K = kf.rts_smoother(xs, covs)
2 plots.plot_rts_output(xs, Ms, t)
```

```
Difference in position in meters:
[-1.4166 -0.2815  1.2679 -1.2405 -2.1863]
```



Choosing the Sigma Parameters

- n = 1, β = 2, κ = 3 - n 에서 α 를 바꿔 출력, α 1: 점 0, ± 3, λ = 2, 가중치 0.67, 0.17, 0.17
- α 200: ± 600 으로 100 표준편차 이상 떨어짐, 평균 가중치는 1, 나머지는 0 에 가까움
- **조건**: 평균 0, 분산 3

```
plots.print_sigmas(mean=0, cov=3, alpha=1)
plots.print_sigmas(mean=0, cov=3, alpha=200)
```

```
sigmas:       [ 0.  3. -3.]
mean weights: [0.6667 0.1667 0.1667]
cov weights:  [2.6667 0.1667 0.1667]
lambda: 2.0
sum cov 2.9999999999999996
sigmas:       [   0.  600. -600.]
mean weights: [1. 0. 0.]
cov weights:  [-39996.      0.      0.]
lambda: 119999.0
sum cov -39996.00000000001
```

Very Small Alpha

- 권장 범위 $0 < \alpha \leq 1$ 의 작은 값 10^{-3} 으로 sigma point 와 가중치 확인
- 점이 평균에 거의 붙고 가중치가 $\pm 10^{6}$ 규모, 그래도 공분산 가중치의 합은 유한
- **조건**: 평균 0, 분산 13, α 0.001, κ 0

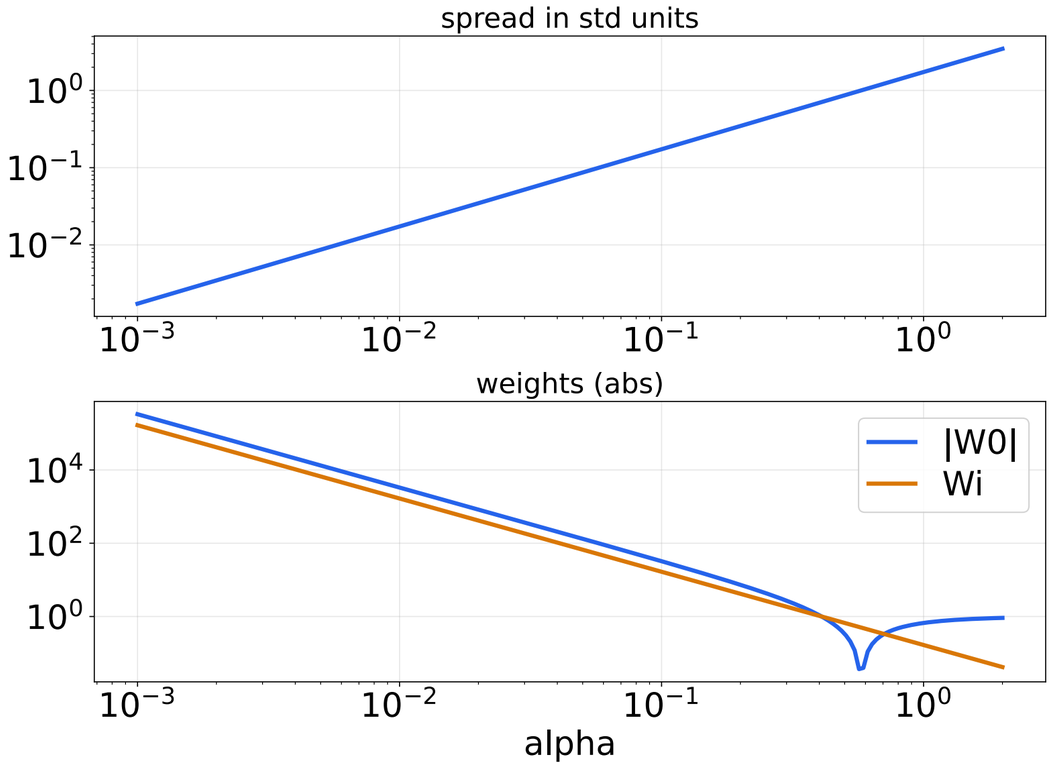
```
1 plots.print_sigmas(mean=0, cov=13, alpha=.001, kappa=0)
```

```
sigmas:       [ 0.      0.0036 -0.0036]
mean weights: [-999999.  500000.  500000.]
cov weights:  [-999996.  500000.  500000.]
lambda: -0.999999
sum cov 3.9999989999923855
```

Effect of the Parameters

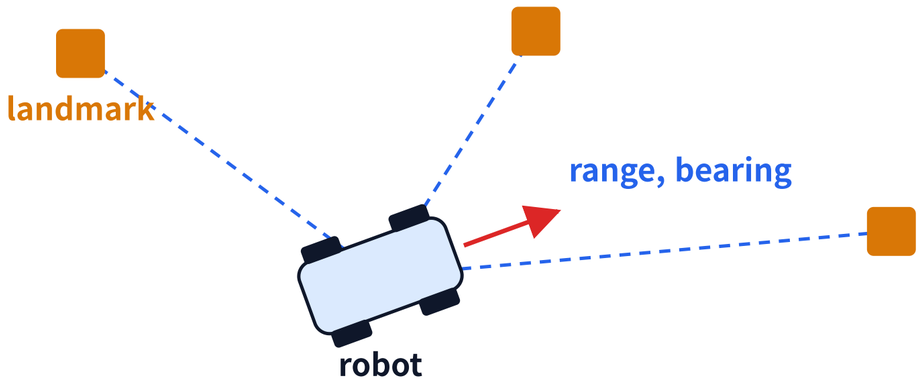
$$\mathcal{X}_i = 0 \pm \sqrt{(1+2)\cdot 3} = \pm 3$$
$$W_0 = \frac{\lambda}{n+\lambda}, \quad W_i = \frac{1}{2(n+\lambda)}$$

- λ **증가**: 평균 가중치는 1 로, 나머지는 0 으로 접근, 공분산 크기와 무관
- **꼬리가 두꺼운 분포**: 꼬리를 표본하도록 점을 넓게 퍼뜨리는 것이 합리적
- **꼬리가 거의 없는 분포**: 실제 데이터가 없는 영역을 피해 점을 평균 가까이
- **그림**: n = 1, κ = 2 에서 α 에 따른 점의 퍼짐과 가중치, 먼 점일수록 작은 가중치



Robot Localization

- **문제**: 알려진 landmark 를 센서로 감지하며 움직이는 로봇의 위치 추정
- **예**: 나무, 건물을 인식하는 자율주행차, 로봇 청소기, 물류 창고 로봇
- **운동**: 자동차와 같은 4 바퀴, 앞바퀴를 꺾어 뒤 차축 중심으로 회전, 비선형
- **센서**: landmark 까지의 대략적인 거리와 bearing, 제곱근과 삼각함수로 비선형
- **선택**: process, 측정 모델 모두 비선형, 둘 다 다루는 UKF 가 적합

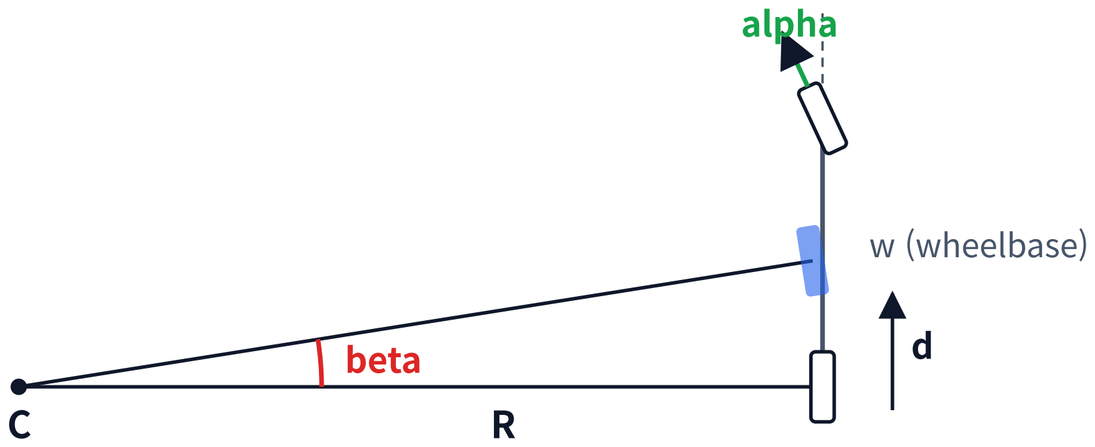


> **핵심**: 실제 문제의 설계 과정, 모델 선택부터 각도 처리까지 하나씩 해결

Robot Motion Model

- **조향**: 앞바퀴가 향하는 방향으로 앞부분이 이동, 뒷바퀴를 중심으로 회전
- **복잡성**: 미끄러짐, 타이어 특성, 안쪽과 바깥 바퀴의 회전 반경 차이
- **bicycle model**: 저속 로봇에서 잘 동작하는 단순 모델
- **그림**: 짧은 시간 뒤 뒷바퀴(파란색)가 반경 R 의 원을 따라 β 만큼 회전

$$\beta = \frac{d}{w}\tan(\alpha) \qquad R = \frac{d}{\beta} \qquad d = v\Delta t$$



Pose After the Turn

- **짧은 시간**: 반경 R 의 원을 따라 회전한다고 근사, 회전 중심 C

$$C_x = x - R\sin(\theta)$$
$$C_y = y + R\cos(\theta)$$
$$\bar{x} = C_x + R\sin(\theta + \beta)$$
$$\bar{y} = C_y - R\cos(\theta + \beta)$$
$$\bar{\theta} = \theta + \beta$$

- **C 대입**: 이전 자세와 회전각만으로 새 자세 계산

$$\bar{x} = x - R\sin(\theta) + R\sin(\theta + \beta)$$
$$\bar{y} = y + R\cos(\theta) - R\cos(\theta + \beta)$$
$$\bar{\theta} = \theta + \beta$$

> **핵심**: 조향 모델의 세부보다 운동 모델이 비선형이라는 점이 중요, 필터가 이를 다뤄야 함

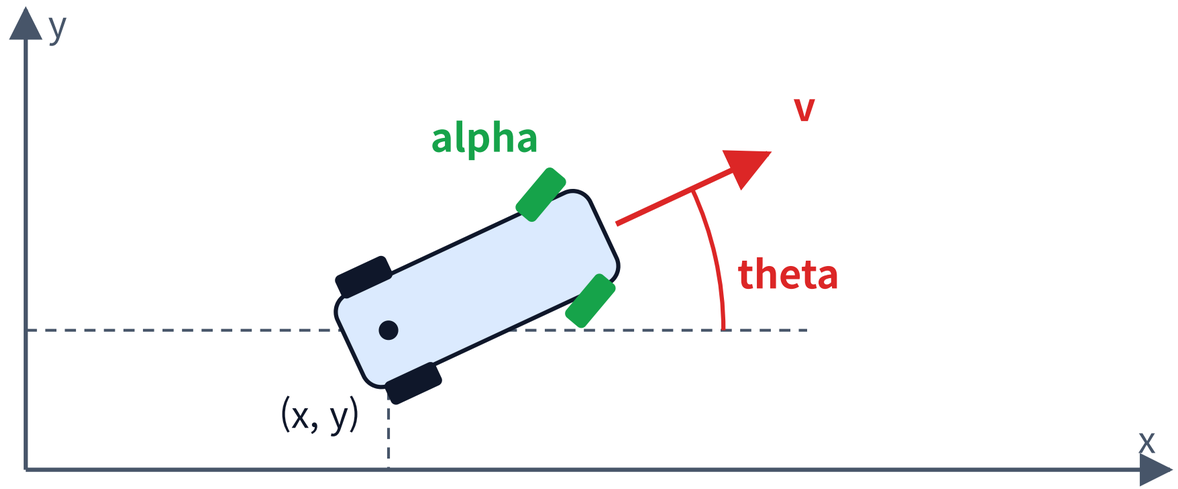
Design the State Variables

- **상태**: 로봇의 위치와 방향, 속도까지 넣으면 수학이 더 어려워짐
- **제어 입력**: 명령 속도 v 와 조향각 α

$$\mathbf{x} = \begin{bmatrix} x & y & \theta \end{bmatrix}^\mathsf{T} \qquad \mathbf{u} = \begin{bmatrix} v & \alpha \end{bmatrix}^\mathsf{T}$$

- **system model**: 비선형 운동 모델과 white noise

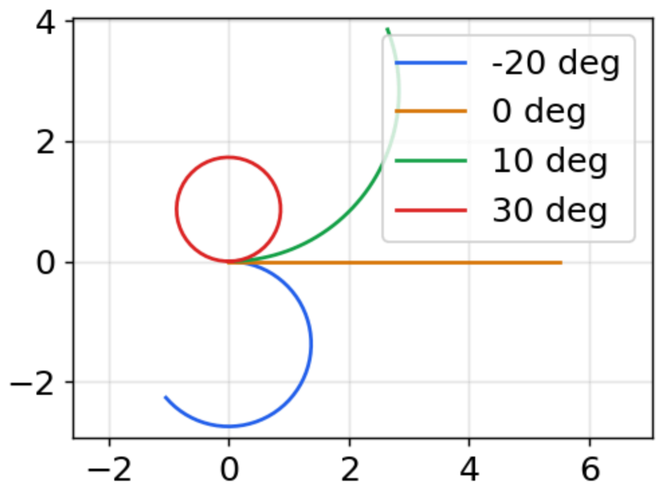
$$\bar{\mathbf{x}} = \mathbf{x} + f(\mathbf{x}, \mathbf{u}) + \mathcal{N}(0, \mathbf{Q})$$



Design the System Model

- bicycle model 을 move(x, dt, u, wheelbase) 로 구현, 같은 속도에 조향각만 바꿔 50 단계 이동
- 조향각에 따라 원호 반경이 달라지는 비선형 운동, dt 가 크거나 강한 비선형이면 Runge Kutta 필요
- **조건**: v 1.1 m/s, dt 0.1 s, wheelbase 0.5 m, 조향각 -20, 0, 10, 30 도

```python
def move(x, dt, u, wheelbase):
    hdg = x[2]
    vel = u[0]
    steering_angle = u[1]
    dist = vel * dt
    if abs(steering_angle) > 0.001: # is robot turning?
        beta = (dist / wheelbase) * tan(steering_angle)
        r = wheelbase / tan(steering_angle) # radius
        sinh, sinhb = sin(hdg), sin(hdg + beta)
        cosh, coshb = cos(hdg), cos(hdg + beta)
        return x + np.array([-r*sinh + r*sinhb, r*cosh - r*coshb, beta])
    else: # moving in straight line
        return x + np.array([dist*cos(hdg), dist*sin(hdg), 0])
for steer in (-20, 0, 10, 30):
    track = [np.array([0., 0., 0.])]
    for _ in range(50):
        track.append(move(track[-1], 0.1, [1.1, np.radians(steer)], 0.5))
    plt.plot(*np.array(track)[:, :2].T, label='{} deg'.format(steer))
plt.axis('equal'); plt.legend();
```

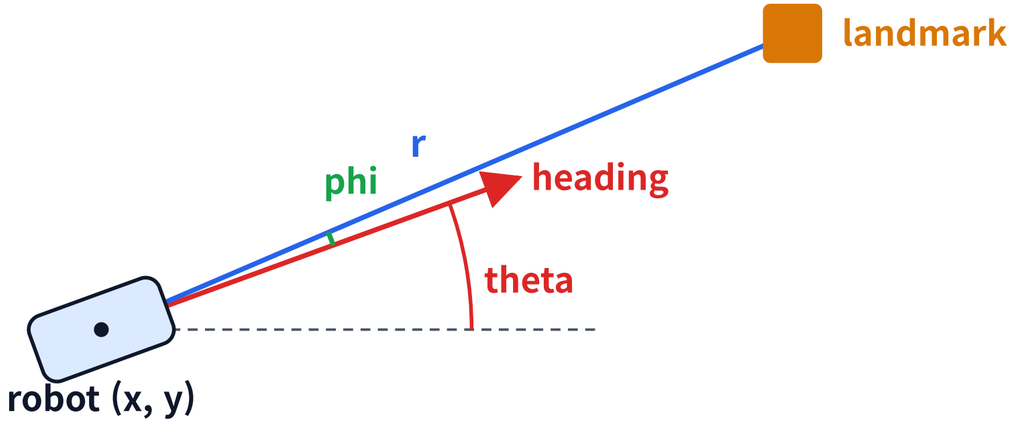


Design the Measurement Model

- **센서**: 알려진 여러 위치(landmark)까지의 잡음 섞인 거리와 bearing
- **bearing**: 로봇 방향 기준이므로 landmark 방향 각에서 로봇 방향 θ 를 뺌

$$r = \sqrt{(p_x - x)^2 + (p_y - y)^2}$$

$$\phi = \tan^{-1}\left(\frac{p_y - y}{p_x - x}\right) - \theta$$

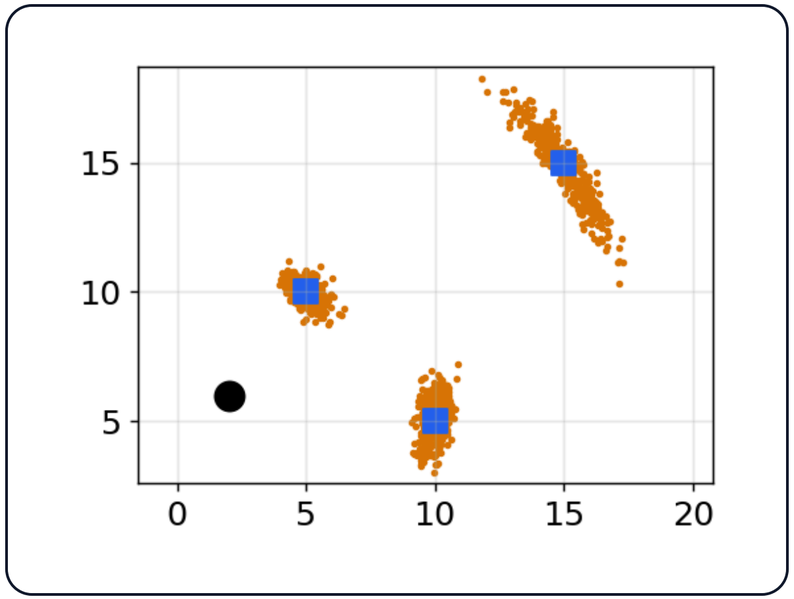


$$\mathbf{z} = h(\mathbf{x}, \mathbf{P}) + \mathcal{N}(0, R) = \begin{bmatrix} \sqrt{(p_x - x)^2 + (p_y - y)^2} \\ \tan^{-1}\left(\frac{p_y - y}{p_x - x}\right) - \theta \end{bmatrix} + \mathcal{N}(0, R)$$

Design Measurement Noise

- 거리와 bearing 잡음은 독립, R = $\mathrm{diag}(\sigma^2_{\text{range}}, \sigma^2_{\text{bearing}})$ 를 landmark 수만큼 반복
- sense() 로 로봇 (2, 6) 에서 측정 400 회, 측정을 landmark 위치로 되돌리면 멀수록 옆으로 긴 원호
- **조건**: 거리 σ 0.3 m, bearing σ 0.1 rad, 로봇 방향 0.3 rad, landmarks (5, 10), (10, 5), (15, 15)

```python
def sense(sim_pos, landmarks, sigma_range, sigma_bearing):
    x, y = sim_pos[0], sim_pos[1]
    z = []
    for lmark in landmarks:
        dx, dy = lmark[0] - x, lmark[1] - y
        d = sqrt(dx**2 + dy**2) + randn()*sigma_range
        bearing = atan2(lmark[1] - y, lmark[0] - x)
        a = normalize_angle(bearing - sim_pos[2] + randn()*sigma_bearing)
        z.extend([d, a])
    return z
pos = np.array([2., 6., .3])
landmarks = np.array([[5, 10], [10, 5], [15, 15]])
zs = np.array([sense(pos, landmarks, 0.3, 0.1) for _ in range(400)])
d, a = zs[:, 0::2], zs[:, 1::2] + pos[2]
plt.scatter(pos[0] + d*np.cos(a), pos[1] + d*np.sin(a), s=4, c='C1')
plt.scatter(landmarks[:, 0], landmarks[:, 1], marker='s', s=100)
plt.scatter(pos[0], pos[1], s=150, c='k'); plt.axis('equal');
```

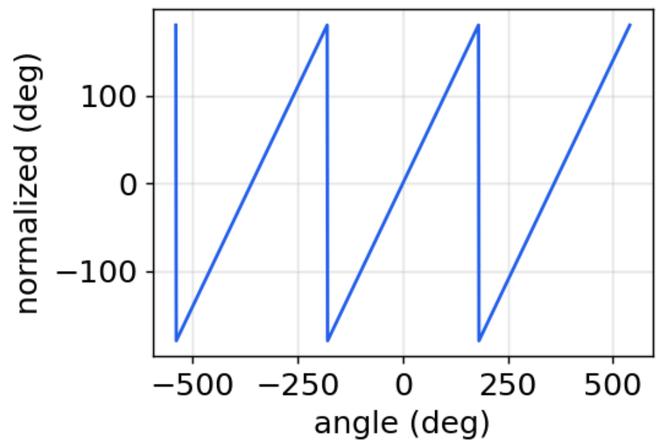


Angle Residual

- 측정 1 도, h(x) 359 도이면 단순 뺄셈은 -358 도, normalize_angle() 로 $[-\pi, \pi)$ 정규화해 2 도
- 측정은 index 1, 3, 5, ..., 상태는 index 2 가 각도, 그래프는 정규화 결과의 톱니 모양
- **조건**: 측정 형식 [dist_1, bearing_1, dist_2, bearing_2, ...], 상태 [x, y, θ], 입력 -540 ~ 540 도

```python
def normalize_angle(x):
    x = x % (2 * np.pi)    # force in range [0, 2 pi)
    if x > np.pi:          # move to [-pi, pi)
        x -= 2 * np.pi
    return x
def residual_h(a, b):
    y = a - b
    # data in format [dist_1, bearing_1, dist_2, bearing_2,...]
    for i in range(0, len(y), 2):
        y[i + 1] = normalize_angle(y[i + 1])
    return y
def residual_x(a, b):
    y = a - b
    y[2] = normalize_angle(y[2])
    return y
print(np.degrees(normalize_angle(np.radians(1-359))))
angles = np.arange(-540, 541)
plt.plot(angles, [np.degrees(normalize_angle(np.radians(a))) for a in angles])
plt.xlabel('angle (deg)'); plt.ylabel('normalized (deg)');
```

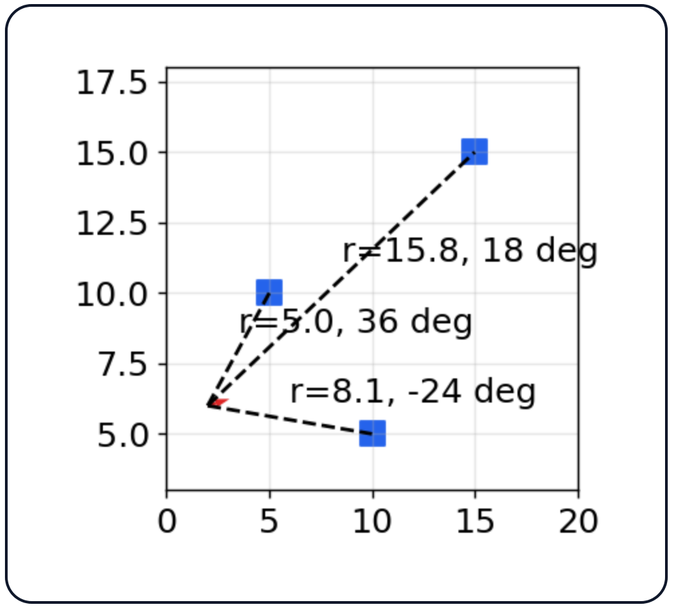
```
1.9999999999999774
```



Measurement Function

- Hx() 는 landmark 배열을 받아 [dist_1, bearing_1, dist_2, bearing_2, ...] 반환, 개수가 바뀌어도 동작
- 로봇 (2, 6), 방향 0.3 rad(빨간 화살표) 에서 세 landmark 까지의 거리와 bearing 을 그림에 표시
- **조건**: landmarks (5, 10), (10, 5), (15, 15), bearing 은 $[-\pi, \pi)$ 로 정규화

```python
def Hx(x, landmarks):
    """ takes a state variable and returns the measurement
    that would correspond to that state. """
    hx = []
    for lmark in landmarks:
        px, py = lmark
        dist = sqrt((px - x[0])**2 + (py - x[1])**2)
        angle = atan2(py - x[1], px - x[0])
        hx.extend([dist, normalize_angle(angle - x[2])])
    return np.array(hx)
x = np.array([2., 6., .3])
landmarks = np.array([[5, 10], [10, 5], [15, 15]])
z = Hx(x, landmarks)
for (px, py), d, a in zip(landmarks, z[0::2], z[1::2]):
    plt.plot([x[0], px], [x[1], py], 'k--')
    plt.text((x[0]+px)/2, (x[1]+py)/2 + .6, 'r={:.1f}, {:.0f} deg'.format(d, np.degrees(a)))
plt.scatter(landmarks[:, 0], landmarks[:, 1], marker='s', s=100)
plt.quiver(x[0], x[1], cos(x[2]), sin(x[2]), color='C3')
plt.xlim(0, 20); plt.ylim(3, 18);
```

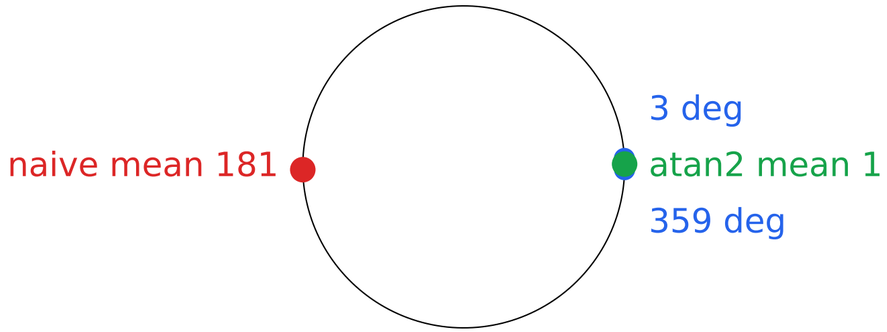


Mean of Angles

- **문제**: unscented transform 은 상태와 측정 벡터의 평균을 계산, 둘 다 각도를 포함
- **예**: 359 도와 3 도의 평균은 1 도가 직관적이지만 단순 산술 평균은 181 도
- **해결**: sin 과 cos 의 평균으로 atan2 를 계산하는 원형 평균

$$\bar{\theta} = \operatorname{atan2}\left(\frac{\sum_{i=1}^{n} \sin\theta_i}{n}, \frac{\sum_{i=1}^{n} \cos\theta_i}{n}\right)$$

- **UKF 에 전달**: x_mean_fn 은 상태 평균, z_mean_fn 은 측정 평균 함수



state_mean and z_mean

- 가중치 Wm 으로 sin, cos 의 가중합을 구해 atan2 로 각도 평균, 위치와 거리는 일반 가중 평균
- 각도 179 도와 -179 도인 두 점의 평균, 단순 가중합은 0 도, state_mean 은 180 도로 올바른 값
- **조건**: 두 점, 가중치 (0.5, 0.5), NumPy 삼각함수와 dot 이 배열 단위로 동작해 반복문보다 빠름

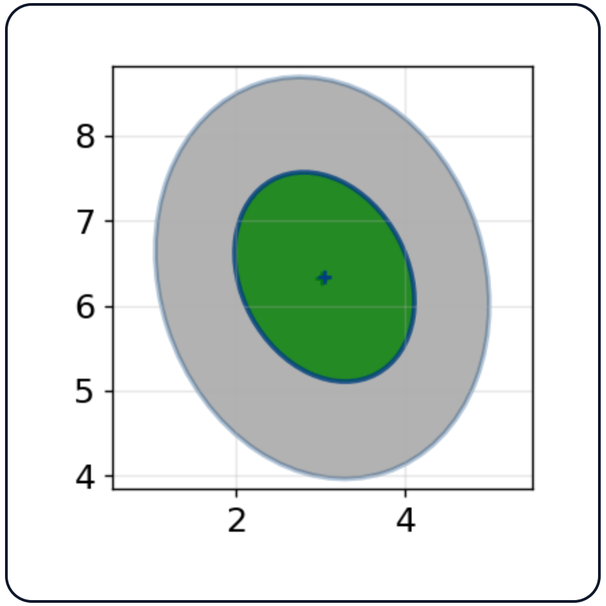
```python
def state_mean(sigmas, Wm):
    x = np.zeros(3)
    sum_sin = np.sum(np.dot(np.sin(sigmas[:, 2]), Wm))
    sum_cos = np.sum(np.dot(np.cos(sigmas[:, 2]), Wm))
    x[0] = np.sum(np.dot(sigmas[:, 0], Wm))
    x[1] = np.sum(np.dot(sigmas[:, 1], Wm))
    x[2] = atan2(sum_sin, sum_cos)
    return x
def z_mean(sigmas, Wm):
    z_count = sigmas.shape[1]
    x = np.zeros(z_count)
    for z in range(0, z_count, 2):
        sum_sin = np.sum(np.dot(np.sin(sigmas[:, z+1]), Wm))
        sum_cos = np.sum(np.dot(np.cos(sigmas[:, z+1]), Wm))
        x[z] = np.sum(np.dot(sigmas[:,z], Wm))
        x[z+1] = atan2(sum_sin, sum_cos)
    return x
sigmas = np.array([[0., 0., np.radians(179)], [2., 2., np.radians(-179)]])
print('naive:     ', np.degrees(np.dot([.5, .5], sigmas)[2]))
print('state_mean:', np.degrees(state_mean(sigmas, np.array([.5, .5]))[2]))
```

```
naive:      0.0
state_mean: 180.0
```

Building the Filter

- sigma point 와 UKF 에 residual, 평균 함수 전달, move() 와 Hx() 의 추가 인자는 keyword 로 전달
- 한 번의 predict(회색) 로 커진 6 σ 타원이 update(녹색) 후 크게 줄어듦
- **조건**: x = (2, 6, 0.3), P = $\mathrm{diag}(0.1, 0.1, 0.05)$, Q = 0.0001 I, α 0.00001, 잡음 없는 측정

```python
def make_ukf(landmarks, sigma_range, sigma_bearing):
    points = MerweScaledSigmaPoints(n=3, alpha=.00001, beta=2, kappa=0, subtract=residual_x)
    ukf = UKF(dim_x=3, dim_z=2*len(landmarks), fx=move, hx=Hx, dt=dt, points=points,
              x_mean_fn=state_mean, z_mean_fn=z_mean,
              residual_x=residual_x, residual_z=residual_h)
    ukf.x = np.array([2, 6, .3])
    ukf.P = np.diag([.1, .1, .05])
    ukf.R = np.diag([sigma_range**2, sigma_bearing**2]*len(landmarks))
    ukf.Q = np.eye(3)*0.0001
    return ukf
dt, wheelbase, u = 1.0, 0.5, [1.1, .01]
landmarks = np.array([[5, 10], [10, 5], [15, 15]])
ukf = make_ukf(landmarks, sigma_range=0.3, sigma_bearing=0.1)
ukf.predict(u=u, wheelbase=wheelbase)
plot_covariance_ellipse(ukf.x[:2], ukf.P[:2, :2], std=6, facecolor='k', alpha=0.3)
z = Hx(move(np.array([2, 6, .3]), dt, u, wheelbase), landmarks)
ukf.update(z, landmarks=landmarks)
plot_covariance_ellipse(ukf.x[:2], ukf.P[:2, :2], std=6, facecolor='g', alpha=0.8)
```

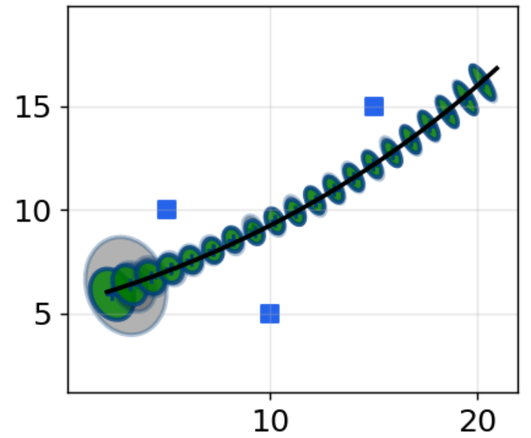


UKF Robot Localization

- 시뮬레이션은 dt/step 간격으로 10 배 촘촘히, UKF 는 step 번마다 한 번, 측정은 sense() 로 생성
- 회색은 prior, 녹색은 posterior 의 6 σ 타원, 측정 후 불확실성이 매우 작음
- **조건**: landmark 3 개, 명령 (1.1 m/s, 0.01 rad) 200 회, 거리 σ 0.3 m, bearing σ 0.1 rad, dt 1 s

```python
def run_localization(cmds, landmarks, sigma_range, sigma_bearing, ellipse_step=1, step=10):
    ukf = make_ukf(landmarks, sigma_range, sigma_bearing)
    sim_pos, track = ukf.x.copy(), []
    for i, u in enumerate(cmds):
        sim_pos = move(sim_pos, dt/step, u, wheelbase)
        track.append(sim_pos)
        if i % step == 0:
            ukf.predict(u=u, wheelbase=wheelbase)
            if i % ellipse_step == 0:
                plot_covariance_ellipse(ukf.x[:2], ukf.P[:2, :2], std=6, facecolor='k', alpha=0.3)
            ukf.update(sense(sim_pos, landmarks, sigma_range, sigma_bearing), landmarks=landmarks)
            if i % ellipse_step == 0:
                plot_covariance_ellipse(ukf.x[:2], ukf.P[:2, :2], std=6, facecolor='g', alpha=0.8)
    track = np.array(track)
    plt.plot(track[:, 0], track[:, 1], color='k', lw=2)
    plt.scatter(landmarks[:, 0], landmarks[:, 1], marker='s', s=60)
    return ukf
ukf = run_localization([np.array([1.1, .01])] * 200, landmarks, sigma_range=0.3, sigma_bearing=0.1)
print('Final P:', ukf.P.diagonal())
```

```
Final P: [0.0092 0.0188 0.0007]
```



Design Process

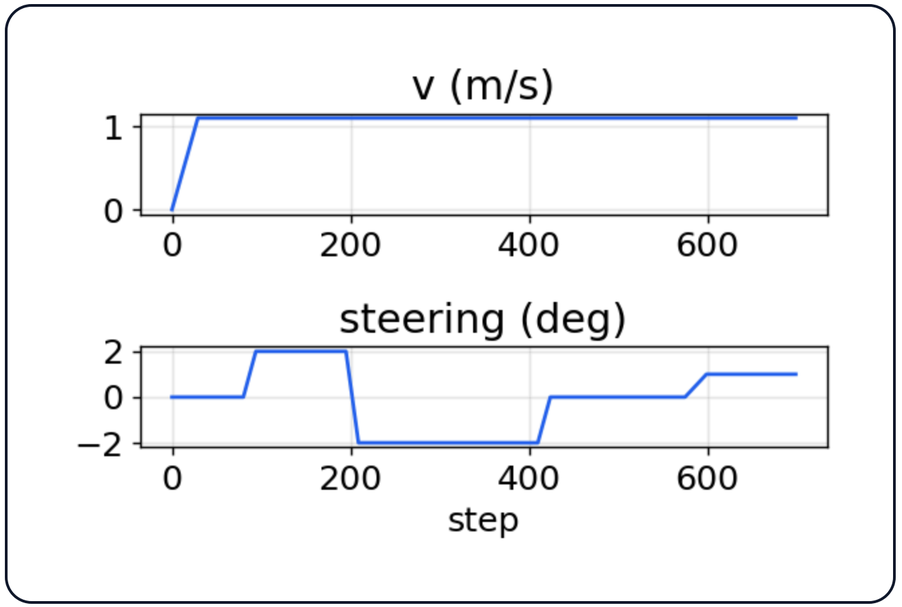
- **설계 순서**: 미리 정한 landmark 로 기본 UKF 를 먼저 동작시키고 질문을 하나씩 해결
- **질문 1**: 다른 landmark 가 보이면? 측정 함수가 landmark 배열을 받도록 변경
- **질문 2**: 각도의 residual 은? 각도 정규화 함수 작성
- **질문 3**: 각도들의 평균은? 원형 평균 구현
- **시뮬레이션 10 Hz**: Runge Kutta 없이 운동 방정식을 적분하므로 작은 시간 간격으로 정확도 확보
- **UKF 1 Hz**: 임베디드 시스템의 제한된 계산 능력, 필요한 만큼만 필터 실행

> **핵심**: 처음부터 완벽한 설계는 없음, 할 수 있는 부분을 만들고 질문을 하나씩 해결

Steering Commands

- 속도와 조향각이 변하지 않는 앞의 시뮬레이션은 비현실적, linspace 로 변하는 조향 명령 생성
- 정지에서 가속 후 직진, 좌회전, 우회전, 다시 좌회전하는 명령 시퀀스를 그래프로 확인
- **조건**: turn(v, t0, t1, steps) 는 조향각을 t0 에서 t1 도까지 steps 단계로 변화, 최대 속도 1.1 m/s

```python
def turn(v, t0, t1, steps):
    return [[v, a] for a in np.linspace(np.radians(t0), np.radians(t1), steps)]
# accelerate from a stop
cmds = [[v, .0] for v in np.linspace(0.001, 1.1, 30)]
cmds.extend([cmds[-1]]*50)
# turn left
v = cmds[-1][0]
cmds.extend(turn(v, 0, 2, 15))
cmds.extend([cmds[-1]]*100)
#turn right
cmds.extend(turn(v, 2, -2, 15))
cmds.extend([cmds[-1]]*200)
cmds.extend(turn(v, -2, 0, 15))
cmds.extend([cmds[-1]]*150)
cmds.extend(turn(v, 0, 1, 25))
cmds.extend([cmds[-1]]*100)
cmds = np.array(cmds)
ax1 = plt.subplot(211); plt.plot(cmds[:, 0]); plt.title('v (m/s)')
plt.subplot(212, sharex=ax1); plt.plot(np.degrees(cmds[:, 1]))
plt.title('steering (deg)'); plt.xlabel('step');
```

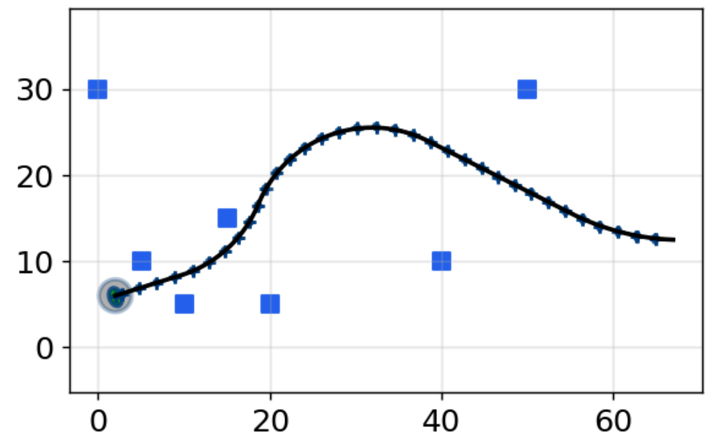


Steering the Robot

- 더 멀리 이동하므로 landmark 를 7 개로 늘리고 dt 0.1 s 마다 UKF 실행
- 불확실성이 매우 빠르게 작아져 6 σ 타원조차 거의 보이지 않음
- **조건**: landmark 7 개, 명령 700 회, step 1, 타원은 20 단계마다, 거리 σ 0.3 m, bearing σ 0.1 rad

```python
landmarks = np.array([[5, 10], [10, 5], [15, 15], [20, 5],
                      [0, 30], [50, 30], [40, 10]])
dt, wheelbase = 0.1, 0.5
ukf = run_localization(cmds, landmarks, sigma_range=0.3,
                       sigma_bearing=0.1, step=1, ellipse_step=20)
print('final covariance', ukf.P.diagonal())
```

```
final covariance [0.0013 0.0043 0.0004]
```

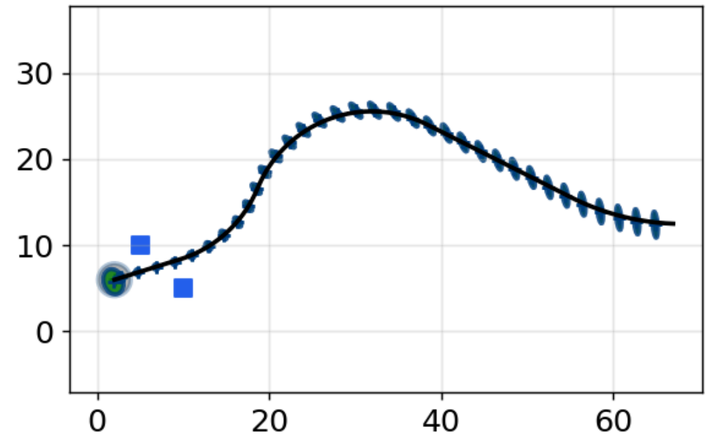


Two Landmarks

- 출발점 근처의 landmark 2 개만 제공해 오차를 키운 실험
- 로봇이 landmark 에서 멀어질수록 타원이 커지고 최종 공분산, 특히 y 분산이 증가
- **조건**: landmarks[0:2] = (5, 10), (10, 5), 나머지 조건 동일

```
landmarks = np.array([[5, 10], [10, 5], [15, 15], [20, 5],
                      [0, 30], [50, 30], [40, 10]])
dt, wheelbase = 0.1, 0.5
ukf = run_localization(cmds, landmarks[0:2], sigma_range=0.3,
                       sigma_bearing=0.1, step=1, ellipse_step=20)
print('final covariance', ukf.P.diagonal())
```

```
final covariance [0.0026 0.0656 0.0008]
```



Discussion

UKF

- 2n + 1 개 sigma point 와 f(x), h(x) 함수 작성
- 각도의 모듈러 연산 처리가 번거로운 부분
- 개념이 단순, 여러 점을 표본해 강한 비선형에서 정확

EKF

- 한 점에서 선형화해 선형 Kalman filter 에 통과
- 꽤 어려운 수학, 닫힌 해가 없으면 반복 해법
- UKF 가 최소한 비슷하고 보통 더 좋은 성능

- **권장**: UKF 부터 구현, 발산 시 큰 피해가 나는 시스템은 정교한 분석과 실험으로 필터 선택
- **사용한 UKF**: scaled unscented filter 를 Van der Merwe 방식으로 파라미터화한 형태
- **sigma point filter 계열**: 점을 고르고 가중하는 방식이 다른 여러 필터, SVD 를 쓰는 필터 등 다양

> **결론**: UKF 는 sigma point filter 의 한 형태, 비선형 위치인식 문제의 실용적인 출발점